Αριστοτελειο Πανεπιστημιο Θεσσαλονικης

Ανίχνευση Ανωμαλιών σε Αυτόνομους Πράκτορες Οδήγησης με χρήση World Models

Οικονόμου Κωνσταντίνος

Σχολή Θετικών Επιστημών
Τμήμα Πληροφορικής

Μάρτιος 2026

Αυτή η πτυχιακή κατατέθηκε για
την απόκτηση Πτυχίου Πληροφορικής

Copyright © 2026 Οικονόμου Κωνσταντίνος

Μάρτιος 2026.



Τμημα Πληροφορικης
Σχολή Θετικών Επιστημών
Αριστοτέλειο Πανεπιστήμιο Θεσσαλονίκης

Αριστοτελειο Πανεπιστημιο Θεσσαλονικης

Ανίχνευση Ανωμαλιών σε Αυτόνομους Πράκτορες Οδήγησης με χρήση World Models

Οικονόμου Κωνσταντίνος

Επιβλέπων Καθηγητής: Τέφας Αναστάσιος

Σχολή Θετικών Επιστημών
Τμήμα Πληροφορικής

Μάρτιος 2026

Ευχαριστίες

Θα ήθελα να ευχαριστήσω θερμά τον επιβλέποντα καθηγητή Τέφα Αναστάσιο για την καθοδήγηση και την υποστήριξη κατά τη διάρκεια της εκπόνησης της παρούσας εργασίας.

Επίσης ευχαριστώ τον υποψήφιο διδάκτορα Τοσίδη Παύλο-Απόστολο για τη συμβολή του στις τεχνικές συζητήσεις και τη βοήθεια στην υλοποίηση των πειραμάτων.

Περίληψη

Στις μέρες μας, όλο και περισσότερα συστήματα αυτόνομης οδήγησης κάνουν την εμφάνισή τους στις αγορές. Χαρακτηριστικά παραδείγματα αποτελούν η Tesla, τα RoboTaxi στο Σικάγο και στον Σαν Φρανσίσκο, καθώς και συνεργασίες ανάμεσα σε εταιρίες όπως η Ford με την Amazon, η Google και η AT&T, καθώς και η Toyota με τη Microsoft, μεταξύ πολλών άλλων [22]. Στόχος αυτών των συστημάτων είναι να φέρουν την πλήρη αυτονομία στην οδήγηση ένα βήμα πιο κοντά στην καθημερινότητα. Τέτοια συστήματα βασίζονται κατά κόρον στη σαφή αντίληψη του περιβάλλοντός τους. Η βαθιά ενισχυτική μάθηση έχει παράγει αρκετά ικανοποιητικά αποτελέσματα στον τομέα της ολοκληρωτικής (end-to-end) πλοήγησης· ωστόσο, το ερώτημα για το πώς θα έπρεπε ένας αυτόνομος πράκτορας να αντιδρά όταν έρχεται αντιμέτωπος με καταστάσεις εκτός του συνόλου εκπαίδευσής του παραμένει ανοιχτό. Η παρούσα πτυχιακή εργασία προτείνει και αναλύει ένα ζεύγος επιλογών για την ανίχνευση ανωμαλιών. Το ζεύγος αυτό βασίζεται σε ένα πλαίσιο το οποίο έχει χτιστεί με τον προσομοιωτή CARLA για τον αλγόριθμο DreamerV3, έναν αλγόριθμο που χρησιμοποιεί εσωτερικό μοντέλο του παρατηρήσιμου κόσμου για την εκπαίδευσή του.

Υλοποιούμε ένα ειδικά προσαρμοσμένο περιβάλλον Gymnasium για τον προσομοιωτή CARLA (έκδοση 0.9.15). Το περιβάλλον διαθέτει διακριτό χώρο ενεργειών και παρατήρηση μέσω σημασιολογικά τμηματοποιημένης ροής εικόνων από κάμερα τοποθετημένη στην οροφή ενός αυτοκινήτου (ego vehicle), καθώς και μια δομή ακολουθίας σημείων διαδρομής, όλα παρεχόμενα από τον προσομοιωτή. Έπειτα, ο αλγόριθμος εσωτερικού μοντέλου κόσμου DreamerV3 εκπαιδεύεται να ακολουθεί σημεία διαδρομής σε αστικό περιβάλλον υπό αναμενόμενες συνθήκες. Μόλις το μοντέλο συγκλίνει, "παγώνει" και το τρέχουμε σε μορφή αξιολόγησης, με εμπόδια τοποθετημένα σε τυχαία σημεία της διαδρομής.

Υλοποιούμε δύο συμπληρωματικές μεθόδους ανίχνευσης ανωμαλιών και στη συνέχεια συγκρίνουμε και αναλύουμε τα αποτελέσματά τους. Η πρώτη μέθοδος ενσωματώνει την πρόταση των Zollicoffer [38]: μία θεωρητικά βάσιμη πρόταση ανίχνευσης ανωμαλιών, η οποία χρησιμοποιεί ένα μεταβαλλόμενο όριο υπολογιζόμενο κατευθείαν από το αναδρομικό μοντέλο χώρου καταστάσεων (Recurrent State-Space Model - RSSM) του Dreamer. Η μέθοδος

αυτή υπολογίζει τρεις όρους απόκλισης Kullback-Leibler (KL-Divergence) ανάμεσα στις κατανομές πριν και μετά την παρατήρηση, με και χωρίς πρόσβαση στο εσωτερικό ιστορικό του αλγορίθμου. Με τον τρόπο αυτό παράγεται μια θεωρητικά υποκινούμενη μέθοδος κατωφλιού ανωμαλιών. Η δεύτερη μέθοδος αποτελείται από ένα συνελικτικό νευρωνικό δίκτυο (Convolutional Neural Network - CNN) δυαδικής ταξινόμησης (Binary Classifier). Το δίκτυο αυτό εκπαιδεύεται με ένα σύνολο δεδομένων ζευγών στιγμιοτύπων: της σημασιολογικά τμηματοποιημένης ροής εικόνων της κάμερας και των αντίστοιχων ανακατασκευασμένων αναπαραστάσεων της "φαντασίας" του αλγορίθμου Dreamer. Ως σήμα ανωμαλίας χρησιμοποιείται η διαφορά των ετικετών κλάσεων.

Και οι δύο μέθοδοι εξετάζονται και επαληθεύονται σε πραγματικό χρόνο μέσω του "παγωμένου" μοντέλου του πράκτορα Dreamer, σε επεισόδια που, όπως προαναφέραμε, εμφανίζουν στατικά εμπόδια σε τυχαία σημεία της διαδρομής. Αρχικά, οι δύο μέθοδοι αποτιμώνται ως ανιχνευτές: παράγουν ένα δυαδικό σήμα ανωμαλίας ανά χρονικό βήμα, το οποίο συγκρίνεται με την πραγματική παρουσία εμποδίου στη σκηνή, και τα αποτελέσματά τους παρουσιάζονται, αναλύονται και συγκρίνονται, αναδεικνύοντας δύο συμπληρωματικά σήματα: τοπική παρουσία εμποδίου και ολική μετατόπιση κατανομής. Στη συνέχεια, τα δύο σήματα ενοποιούνται σε ένα Σύστημα Παρατήρησης Ανωμαλιών δύο επιπέδων, το οποίο υλοποιείται ως επόπτης ασφαλείας κλειστού βρόχου με προοδευτική πέδηση: ο ταξινομητής οδηγεί την πέδηση, ενώ το όριο KL ρυθμίζει την εμπιστοσύνη που του αποδίδεται. Ο επόπτης αξιολογείται έναντι του ανεξέλεγκτου πράκτορα και καθεμιάς συνιστώσας χωριστά, σε 100 ανεξάρτητα επεισόδια ανά διαμόρφωση: με το μοναδικό όχημα-εμπόδιο εξαλείφει όλες τις συγκρούσεις και στα τρία σενάρια οδήγησης (έναντι 75–98 συγκρούσεων στα 100 επεισόδια χωρίς εποπτεία), σταματώντας στο καλά προσαρμοσμένο σενάριο σε διάμεση απόσταση 18 m από το εμπόδιο, ενώ η υποβάθμιση του στρώματος ασφαλείας υπό μετατόπιση κατανομής εκδηλώνεται ως πρόωρες στάσεις και όχι ως συγκρούσεις.

Λέξεις-κλειδιά: CARLA, Gymnasium, Ενισχυτική Μάθηση, DreamerV3, World Models, Ανίχνευση Ανωμαλιών, Σημασιολογική Τμηματοποίηση, Αυτόνομη Οδήγηση, Ενεργή Αντίληψη.

Abstract

Nowadays, an increasing number of autonomous driving systems are appearing on the market. Notable examples include Tesla, the RoboTaxi services in Chicago and San Francisco, and collaborations between companies such as Ford with Amazon, Google and AT&T, and Toyota with Microsoft, among many others [22]. The goal of these systems is to bring full driving autonomy one step closer to everyday life. Such systems rely heavily on a clear perception of their environment. Deep reinforcement learning has produced satisfactory results in the field of end-to-end navigation; however, the question of how an autonomous agent should react when facing situations outside its training distribution remains open. This thesis proposes and analyzes a pair of approaches for anomaly detection, built on a framework based on the CARLA simulator for the DreamerV3 algorithm, an algorithm that uses an internal world model for its training.

We implement a specially customized Gymnasium environment for the CARLA simulator (version 0.9.15). The environment features a discrete action space and observations through a semantically segmented image stream from a camera mounted on the roof of a vehicle (ego vehicle), along with a sequence of route waypoints, all provided by the simulator. The DreamerV3 world-model algorithm is then trained to follow waypoints in an urban environment under expected conditions. Once the model converges, it is ”frozen” and run in an evaluation mode with obstacles placed at random points along the route.

We implement two complementary anomaly detection methods and subsequently compare and analyze their results. The first method incorporates the proposal by Zollicoffer et al. [38]: a theoretically grounded anomaly detection approach that uses a variable threshold computed directly from Dreamer’s Recurrent State-Space Model (RSSM). This method computes three Kullback-Leibler divergence (KL-Divergence) terms between the distributions before and after observation, with and without access to the algorithm’s internal history, producing a theoretically motivated anomaly threshold method. The second method consists of a Convolutional Neural Network (CNN) binary classifier. This network is trained on a dataset of paired snapshots: the semantically segmented

camera image stream and the corresponding reconstructed representations of the Dreamer algorithm's "imagination". The difference between the class labels is used as the anomaly signal.

Both methods are tested and validated in real time through the "frozen" Dreamer agent model, in episodes that, as mentioned above, feature static obstacles at random points along the route. The two methods are first evaluated as detectors: they produce a binary anomaly signal at each time step, which is compared against the actual presence of an obstacle in the scene, and their results are presented, analyzed and compared, revealing two complementary signals: local obstacle presence and global distribution shift. The two signals are then unified into a two-tier Anomaly Observation System, implemented as a closed-loop safety supervisor with progressive braking: the classifier drives the brake, while the KL threshold regulates the trust placed in it. The supervisor is evaluated against the unsupervised agent and against each component in isolation, over 100 independent episodes per configuration: with the single vehicle obstacle it eliminates every collision in all three driving scenarios (against 75–98 collisions per 100 episodes without supervision), stopping in the well-fitted scenario at a median distance of 18 m from the obstacle, while the degradation of the safety layer under distribution shift manifests as premature stops rather than collisions.

Keywords: CARLA, Gymnasium, Reinforcement Learning, DreamerV3, World Models, Anomaly Detection, Semantic Segmentation, Autonomous Driving, Active Perception.

Περιεχόμενα

Ευχαριστίες ii

Περιεχόμενα vii

Κατάλογος σχημάτων xi

Κατάλογος πινάκων xiii

1 Εισαγωγή 1

1.1 Κίνητρο και σημασία του προβλήματος . . . 1
1.2 Στόχοι της έρευνας . . . 2
1.3 Συνεισφορές . . . 3
1.4 Δομή εργασίας . . . 4

2 Θεωρητικό Υπόβαθρο 5

2.1 Ενεργή Αντίληψη . . . 5
2.2 Αυτόνομη Οδήγηση: Αρχιτεκτονική και Προκλήσεις . . . 6
2.3 Αισθητήρες και Στοίβα Αντίληψης σε Αυτόνομα Οχήματα . . . 8
2.3.1 Τυπολογία Αισθητήρων . . . 8
2.3.2 Στοίβα Αντίληψης: Τέσσερις Κύριες Εργασίες . . . 9
2.3.3 Σημασιολογική Τμηματοποίηση και Παλέτα CityScapes . . . 9
2.4 Περιβάλλοντα Προσομοίωσης για Έρευνα Αυτόνομης Οδήγησης . . . 10
2.5 Θεωρητικό Πλαίσιο Ενισχυτικής Μάθησης . . . 11
2.5.1 Μαρκοβιανή Διαδικασία Απόφασης . . . 11
2.5.2 Απόκλιση Kullback-Leibler . . . 13
2.6 DreamerV3: Ενισχυτική Μάθηση με Μοντέλα Κόσμου . . . 15
2.6.1 Επισκόπηση . . . 15
2.6.2 Επαναλαμβανόμενο Μοντέλο Χώρου Καταστάσεων (RSSM) . . . 16

2.6.3 Στόχοι Εκπαίδευσης και Τεχνικές Ανθεκτικότητας 18
2.7 CarDreamer: Μοντέλα Κόσμου για Αυτόνομη Οδήγηση 19
2.8 Ανίχνευση Ανωμαλιών στην Ενισχυτική Μάθηση με Μοντέλα Κόσμου . . . 21
2.8.1 Ευρύτερο Πλαίσιο: Ανίχνευση Ανωμαλιών σε Αυτόνομη Οδήγηση . . 21
2.8.2 Διατύπωση του Προβλήματος 21
2.8.3 Προσέγγιση Οριοθέτησης μέσω Απόκλισης KL 22
2.9 Συνελικτικό Νευρωνικό Δίκτυο Δυαδικής Ταξινόμησης 24
2.9.1 Επισκόπηση Συνελικτικών Νευρωνικών Δικτύων 24
2.9.2 Δομικά Στοιχεία Αρχιτεκτονικής 24
2.9.3 Δυαδική Ταξινόμηση και Συνάρτηση Απώλειας 25

3 Αρχιτεκτονική Συστήματος και Υλοποίηση 26
3.1 Περιβάλλον CARLA συμβατό με Gymnasium 26
3.1.1 Φιλοσοφία Σχεδιασμού Περιβάλλοντος 26
3.1.2 Χώρος Παρατηρήσεων 27
3.1.3 Χώρος Ενεργειών 27
3.1.4 Διαχείριση Διαδρομής και Waypoints 28
3.1.5 Συνάρτηση Ανταμοιβής 28
3.1.6 Τερματισμός Επεισοδίων 29
3.2 Εκπαίδευση DreamerV3 με SheepRL 29
3.2.1 Πλαίσιο SheepRL 29
3.2.2 Παραμετροποίηση Υπερπαραμέτρων 30
3.2.3 Σενάρια Εκπαίδευσης 30
3.3 Δημιουργία Συνόλου Δεδομένων Ανωμαλιών 31
3.3.1 Στρατηγική Συλλογής 31
3.3.2 Διαχωρισμός Κανονικών και Ανώμαλων Βημάτων 31
3.3.3 Προεπεξεργασία Εικόνων 32
3.4 Υλοποίηση Ανίχνευσης Ανωμαλιών βάσει KL 32
3.4.1 Ενσωμάτωση στον Κώδικα DreamerV3 32
3.4.2 Δίοδος Πλήρους Ιστορικού 33
3.4.3 Δίοδος Κενού Ιστορικού 34
3.4.4 Υπολογισμός των Τριών KL Όρων 34
3.4.5 Κανόνας Ταξινόμησης Ανωμαλίας 35
3.5 Αρχιτεκτονική και Εκπαίδευση CNN Ταξινομητή 35
3.5.1 Είσοδος και Προεπεξεργασία 35
3.5.2 Αρχιτεκτονική Δικτύου 36
3.5.3 Σύνθεση Συνόλου Δεδομένων και Εκπαίδευση 36
3.5.4 Πρόβλεψη κατά την Αξιολόγηση 37
3.6 Βρόχος Αξιολόγησης Πραγματικού Χρόνου 38

3.6.1 Δομή Βρόχου . . . 38
3.6.2 Μετρικές Αξιολόγησης . . . 39
3.7 Σύστημα Παρατήρησης Ανωμαλιών σε Κλειστό Βρόχο . . . 39
3.7.1 Προοδευτική πέδηση με ανοχή κενών . . . 39
3.7.2 Ρύθμιση εμπιστοσύνης από το όριο KL . . . 40
3.7.3 Διαμορφώσεις και τερματισμός ασφαλούς στάσης . . . 40

4 Πειραματικά Αποτελέσματα και Ανάλυση 41
4.1 Επισκόπηση πειραμάτων και ορολογία . . . 41
4.2 Εκπαίδευση και σύγκλιση του DreamerV3 . . . 43
4.2.1 Σενάριο Σ1 - Στατική διαδρομή . . . 43
4.2.2 Σενάριο Σ2 - Τυχαία διαδρομή . . . 44
4.2.3 Σενάριο Σ3 - Τυχαίες πόλεις . . . 45
4.3 Εκπαίδευση του ταξινομητή CNN . . . 47
4.3.1 Επιλογή κατωφλίου απόφασης . . . 48
4.4 Πρωτόκολλο αξιολόγησης ανίχνευσης . . . 49
4.5 Αποτελέσματα P1 - Μοναδικό εμπόδιο . . . 50
4.6 Αποτελέσματα P2 - Τυχαία εμπόδια . . . 52
4.7 Συγκριτική ανάλυση των δύο μεθόδων . . . 55
4.7.1 Συγκεντρωτική σύγκριση . . . 55
4.7.2 Γιατί λειτουργεί ο ταξινομητής CNN . . . 56
4.7.3 Γιατί αποτυγχάνει το όριο KL . . . 56
4.7.4 Η ομαλή υποβάθμιση του ταξινομητή . . . 57
4.7.5 Σύνδεση με την εκπαίδευση του μοντέλου κόσμου . . . 57
4.8 Αξιολόγηση ασφάλειας κλειστού βρόχου . . . 58
4.8.1 Μοναδικό όχημα-εμπόδιο (P1) . . . 59
4.8.2 Το όριο KL ως αυτόνομος μηχανισμός . . . 60
4.8.3 Ρύθμιση εμπιστοσύνης δύο επιπέδων . . . 60
4.8.4 Ανάλυση ανά κλάση εμποδίου (P2) . . . 60
4.9 Σύνοψη ευρημάτων . . . 61

5 Συμπεράσματα 62
5.1 Βασικά συμπεράσματα . . . 63
5.2 Δύο ανιχνευτές, δύο διαφορετικά σήματα . . . 64
5.3 Προς ένα ενοποιημένο Σύστημα Παρατήρησης Ανωμαλιών . . . 64
5.4 Διαστρωμάτωση και μεταφερσιμότητα των ανιχνευτών . . . 66
5.5 Παρατήρηση επί της λανθάνουσας ανίχνευσης . . . 66
5.6 Περιορισμοί . . . 66
5.7 Μελλοντικές επεκτάσεις . . . 67

5.8 Επίλογος 68

Βιβλιογραφία **69**

Α΄ Ψευδοκώδικας Υλοποίησης **73**

Α΄.1 Περιβάλλον: αποκωδικοποίηση ενέργειας 73
Α΄.2 Συνάρτηση ανταμοιβής 73
Α΄.3 Ανίχνευση ανωμαλίας βάσει KL 75
Α΄.4 Προεπεξεργασία εικόνας 75
Α΄.5 Ανιχνευτές αληθούς ετικέτας 76
Α΄.6 Αρχιτεκτονική και εκπαίδευση του ταξινομητή CNN 77
Α΄.7 Βρόχος αξιολόγησης πραγματικού χρόνου 77
Α΄.8 Επόπτης ασφαλείας κλειστού βρόχου 77

Κατάλογος σχημάτων

4.1 Σ1 (Στατική διαδρομή): καμπύλες μέσης ανταμοιβής και μέσου μήκους επεισοδίου. Η μονοτονική άνοδος και ο κορεσμός κοντά στον μέγιστο χρονικό ορίζοντα δείχνουν πλήρη σύγκλιση και συνεπή ολοκλήρωση διαδρομής. . . . 43
4.2 Σ1 (Στατική διαδρομή): συνιστώσες της συνάρτησης απώλειας. Όλες οι απώλειες συγκλίνουν ομαλά. 44
4.3 Σ1 (Στατική διαδρομή): νόρμες βαθμίδων για actor, critic και μοντέλο κόσμου. Οι βαθμίδες παραμένουν φραγμένες (ευσταθής εκπαίδευση). 44
4.4 Σ2 (Τυχαία διαδρομή): μέση ανταμοιβή και μήκος επεισοδίου. Σύγκλιση με διακύμανση λόγω της διαφορετικής δυσκολίας κάθε διαδρομής. Η έντονη κόκκινη καμπύλη και στα δύο διαγράμματα είναι η εξομαλυμένη τάση (smoothed trend) και αναδεικνύει την άνοδο προς το πλατό σύγκλισης. 45
4.5 Σ2 (Τυχαία διαδρομή): συνιστώσες απώλειας. Συνεχιζόμενη πτωτική τάση. . 45
4.6 Σ2 (Τυχαία διαδρομή): νόρμες βαθμίδων actor/critic/μοντέλου κόσμου. . . 45
4.7 Σ3 (Τυχαίες πόλεις): η "πριονωτή" μορφή με τα διαδοχικά καταρρέοντα τμήματα αντικατοπτρίζει την εναλλαγή πόλης κάθε 20 επεισόδια. Η έντονη κόκκινη καμπύλη και στα δύο διαγράμματα είναι η εξομαλυμένη συνολική τάση· παραμένει σε χαμηλή ζώνη και *δεν* συγκλίνει στο πλατό των Σ1 - Σ2, σε συμφωνία με την ανοδική τάση των απωλειών ανακατασκευής. 46
4.8 Σ3 (Τυχαίες πόλεις): οι απώλειες ανακατασκευής (`observation`, `state`, `world_model`) *αυξάνονται*, ενώ η απώλεια ανταμοιβής μειώνεται· ένδειξη ότι ο πράκτορας εξακολουθεί να οδηγεί επαρκώς αν και η "φαντασία" του παύει να είναι πιστή. 46
4.9 Σ3 (Τυχαίες πόλεις): νόρμες βαθμίδων. Η αυξανόμενη νόρμα του μοντέλου κόσμου συμβαδίζει με την αδυναμία ανακατασκευής των διαφορετικών πόλεων. 47
4.10 Επιλογή του κατωφλίου απόφασης του ταξινομητή στο σύνολο επικύρωσης: κατανομή εξόδου, καμπύλη ROC και καμπύλη ακρίβειας-ανάκλησης. 49

4.11 P1 (Μοναδικό εμπόδιο), σενάριο Σ1: πίνακες σύγχυσης του ταξινομητή CNN και του ορίου KL. 50
4.12 P1 (Μοναδικό εμπόδιο), σενάριο Σ2: πίνακες σύγχυσης του ταξινομητή CNN (επάνω) και του ορίου KL (κάτω). Η ακρίβεια σημάνσεων του CNN υποχωρεί σε σχέση με το Σ1, ενώ το όριο KL εξακολουθεί να αστοχεί την πλειονότητα των ανωμαλιών. 51
4.13 P1 (Μοναδικό εμπόδιο), σενάριο Σ3: πίνακες σύγχυσης του ταξινομητή CNN (επάνω) και του ορίου KL (κάτω). Ο CNN διατηρεί τη διαχωριστικότητά του, ενώ το όριο KL σημαίνει τα περισσότερα καρέ ως ανωμαλία (πολύ υψηλά ψευδώς θετικά). 52
4.14 P2 (Τυχαία εμπόδια), σενάριο Σ1: πίνακες σύγχυσης του ταξινομητή CNN και του ορίου KL. 53
4.15 P2 (Τυχαία εμπόδια), σενάριο Σ2: πίνακες σύγχυσης του ταξινομητή CNN (επάνω) και του ορίου KL (κάτω). Η ανάκληση του CNN είναι υψηλότερη από ό,τι στο P1, καθώς η ετικέτα είναι ο ανεξάρτητος κλάσης τελεστής στον οποίο ο ταξινομητής εκπαιδεύτηκε, ενώ η ακρίβεια σημάνσεών του είναι χαμηλότερη, στο χαμηλότερο ποσοστό ανωμαλιών της μελέτης. 54
4.16 P2 (Τυχαία εμπόδια), σενάριο Σ3: πίνακες σύγχυσης του ταξινομητή CNN (επάνω) και του ορίου KL (κάτω). Το όριο KL σημαίνει σχεδόν τα πάντα ως ανωμαλία, με αποτέλεσμα πολύ υψηλά ψευδώς θετικά. 55
4.17 Σύγκριση ταξινομητή CNN έναντι ορίου KL ως προς (α′) F_1 και (β′) MCC, για τις έξι συνθήκες. Ο ταξινομητής υπερτερεί παντού· το όριο KL μένει κοντά στο μηδέν (τύχη) ως προς τον MCC. 56
4.18 Σύγκριση ως προς (α′) precision και (β′) recall. Η υψηλή ανάκληση του ταξινομητή σε συνδυασμό με ελεγχόμενη ακρίβεια σημάνσεων αντιπαραβάλλεται με τη δι-τροπική (αστοχία/υπερενεργοποίηση) συμπεριφορά του ορίου KL. . 56
4.19 Ομαλή υποβάθμιση του ταξινομητή CNN ως προς (α′) F_1 και (β′) MCC, καθώς αυξάνεται η δυσκολία του σεναρίου, για τις δύο ρυθμίσεις εμποδίων. Οι δύο καμπύλες βαθμολογούνται έναντι διαφορετικών τελεστών ετικέτας και σε πολύ διαφορετικά ποσοστά ανωμαλιών, οπότε συγκρίνεται η *τάση* τους και όχι οι απόλυτες τιμές τους. 58

Κατάλογος πινάκων

3.1 Υπερπαράμετροι εκπαίδευσης DreamerV3 30

4.1 Ποιοτική σύνοψη εκπαίδευσης DreamerV3 ανά σενάριο. 47
4.2 Εκπαίδευση του ταξινομητή CNN με διαχωρισμό κατά επεισόδια. 48
4.3 Πλήθος δειγμάτων (per-timestep) και ποσοστό ανωμαλιών ανά συνθήκη αξιολόγησης (100 επεισόδια/συνθήκη). 49
4.4 P1 (Μοναδικό εμπόδιο): πλήρεις μετρικές ανά σενάριο, με τους δύο ανιχνευτές παρατιθέμενους δίπλα-δίπλα (CNN = ταξινομητής, KL = όριο ανωμαλίας). Με **έντονη** γραφή σημειώνεται ο καλύτερος ανιχνευτής ανά μετρική (για FPR/FNR, καλύτερη είναι η χαμηλότερη τιμή). 51
4.5 P2 (Τυχαία εμπόδια): πλήρεις μετρικές ανά σενάριο, με τους δύο ανιχνευτές παρατιθέμενους δίπλα-δίπλα (CNN = ταξινομητής, KL = όριο ανωμαλίας). Με **έντονη** γραφή σημειώνεται ο καλύτερος ανιχνευτής ανά μετρική (για FPR/FNR, καλύτερη είναι η χαμηλότερη τιμή). 53
4.6 Αξιολόγηση ασφάλειας κλειστού βρόχου, ρύθμιση P1 (μοναδικό όχημα-εμπόδιο). 59
4.7 Αξιολόγηση ασφάλειας κλειστού βρόχου, ρύθμιση P2 (τυχαία εμπόδια). . . . 59

5.1 Εννοιολογική αντιπαραβολή των δύο ανιχνευτών. Οι δύο μέθοδοι μετρούν διαφορετικά σήματα και αποτυγχάνουν σε αντίθετα καθεστώτα. 65

1 Εισαγωγή

1.1 Κίνητρο και σημασία του προβλήματος

Η ανάπτυξη αυτόνομων οχημάτων (Autonomous Vehicles - AVs) σε περιβάλλον πραγματικού κόσμου αποτελεί μία από τις απαιτητικότερες προκλήσεις στον τομέα της σύγχρονης μηχανικής. Ένα πλήρως αυτόνομο όχημα πρέπει να διαθέτει αντίληψη του περιβάλλοντός του με την υψηλότερη δυνατή ακρίβεια και να ερμηνεύει περίπλοκες και δυναμικές σκηνές. Επιπλέον, πρέπει να σχεδιάζει ασφαλείς πορείες και να εκτελεί ενέργειες ελέγχου σε πραγματικό χρόνο, διαθέτοντας δικλείδες ασφαλείας που υπερβαίνουν τα όρια των συνθηκών κανονικής λειτουργίας κατά τη διάρκεια της εκπαίδευσης [22, 7]. Έχει σημειωθεί σημαντική πρόοδος όσον αφορά μεμονωμένα υπο-προβλήματα, όπως η ανίχνευση αντικειμένων, ο σχεδιασμός κινήσεων και η συγχώνευση αισθητήρων. Ωστόσο, η ενσωμάτωση αυτών των δυνατοτήτων σε ένα σταθερό και γενικεύσιμο σύστημα παραμένει ένα ανοιχτό ερευνητικό ζήτημα.

Το πρόβλημα αυτό έχει τις ρίζες του στην κατανομική ανθεκτικότητα (distributional robustness). Ένα βαθύ νευρωνικό δίκτυο που έχει εκπαιδευτεί σε ένα πεπερασμένο σύνολο οδηγικών σεναρίων αναπόφευκτα θα έρθει αντιμέτωπο με άγνωστες καταστάσεις κατά το στάδιο της πραγματικής λειτουργίας του. Τέτοιες καταστάσεις περιλαμβάνουν, για παράδειγμα, μη αναμενόμενους χρήστες του δρόμου, ακραίες καιρικές συνθήκες, οδικά εργοτάξια ή μηχανικές βλάβες. Σε κλασικές αρθρωτές αρχιτεκτονικές (pipelines), τέτοιου είδους

εκτός-κατανομής (out-of-distribution - OOD) γεγονότα μπορούν να αντιμετωπιστούν κατά το στάδιο της αντίληψης μέσω εξειδικευμένων μηχανισμών ανίχνευσης. Αντίθετα, σε συστήματα ολοκληρωτικής (end-to-end) μάθησης, η αντίληψη και ο σχεδιασμός διαδρομής βελτιστοποιούνται από κοινού. Στην περίπτωση αυτή, οι καταστάσεις σφάλματος είναι λιγότερο διακριτές και η ανάγκη για ένα ανεξάρτητο σύστημα επιτήρησης ασφαλείας καθίσταται εντονότερη.

Η ενισχυτική μάθηση με μοντέλα κόσμου, όπως για παράδειγμα το DreamerV3 [16], προσφέρει ένα εξαιρετικό παράδειγμα μελλοντικής εφαρμογής αυτόνομης οδήγησης. Ο πράκτορας μαθαίνει έναν συμπιεσμένο λανθάνοντα χώρο (latent space) του κόσμου και τον χρησιμοποιεί για να φαντάζεται μελλοντικές πορείες. Στη συνέχεια, βελτιστοποιεί την πολιτική εκπαίδευσής του αποκλειστικά βάσει αυτής της διαδικασίας φαντασίας. Το εσωτερικό αυτό μοντέλο κόσμου αποτελεί ένα πιθανοτικό μοντέλο εκμάθησης των δυναμικών μεταβάσεων του περιβάλλοντος. Η βασική έννοια που εξερευνάται στην παρούσα πτυχιακή εργασία είναι ο βαθμός απόκλισης της φανταζόμενης εσωτερικής κατάστασης από το πραγματικό περιβάλλον που αντιλαμβάνεται ο πράκτορας μέσω των αισθητήρων του. Η απόκλιση αυτή χρησιμοποιείται για την ανίχνευση ανωμαλιών (anomalies), δηλαδή καταστάσεων εκτός του συνόλου εκπαίδευσης (OOD).

Η παρούσα πτυχιακή εργασία αναπτύσσει ένα ολοκληρωμένο σύστημα ανίχνευσης ανώμαλων καταστάσεων βασισμένο σε μοντέλα εσωτερικού κόσμου για σενάρια αυτόνομης οδήγησης. Το σύστημα υλοποιείται στον προσομοιωτή αστικής οδήγησης CARLA και βασίζεται στον αλγόριθμο DreamerV3. Αναπτύσσονται και συγκρίνονται δύο ξεχωριστές προσεγγίσεις ανίχνευσης. Η πρώτη είναι μία θεωρητικά θεμελιωμένη μέθοδος που χρησιμοποιεί τον εσωτερικό λανθάνοντα χώρο (latent space) του αναδρομικού μοντέλου χώρου καταστάσεων (RSSM) του Dreamer. Η δεύτερη είναι μία προσέγγιση επικεντρωμένη στα δεδομένα, η οποία χρησιμοποιεί ένα συνελικτικό νευρωνικό δίκτυο δυαδικής ταξινόμησης (CNN Binary Classifier), εκπαιδευμένο σε ζεύγη πραγματικών και φανταζόμενων παρατηρήσεων.

1.2 Στόχοι της έρευνας

Η συγκεκριμένη πτυχιακή εργασία επιδιώκει να επιλύσει τα εξής ερευνητικά ζητήματα:

- Σχεδιασμό και υλοποίηση ενός περιβάλλοντος τύπου Gymnasium στον προσομοιωτή CARLA έκδοσης 0.9.15, ικανού να υποστηρίξει την εκπαίδευση του αλγορίθμου DreamerV3, το οποίο περιλαμβάνει σημασιολογικά τμηματοποιημένη (semantically segmented) παρατήρηση, σχεδιασμό και πλοήγηση διαδρομής μέσω σημείων πορείας (waypoints), καθώς και μία σύνθετη συνάρτηση ανταμοιβών (reward function).
- Εκπαίδευση ενός πράκτορα με τον αλγόριθμο DreamerV3 σε τρία διαφορετικά σενάρια (στατική διαδρομή και στατικό περιβάλλον, τυχαία διαδρομή και στατικό περιβάλλον,

τυχαία διαδρομή και τυχαίο περιβάλλον), με σκοπό τη συστηματική και επιτυχή ολοκλήρωση της διαδρομής υπό κανονικές συνθήκες οδήγησης.

- Υλοποίηση της πρότασης ανίχνευσης ανωμαλιών [38] εσωτερικά στον κώδικα του αλγορίθμου DreamerV3, για τον υπολογισμό μεταβαλλόμενου κατωφλίου (threshold) βασισμένου σε όρους KL-Divergence σε πραγματικό χρόνο κατά τη διάρκεια της αξιολόγησης.

- Δημιουργία ενός συνόλου δεδομένων κανονικών και ανώμαλων καταστάσεων, βασισμένου σε ζεύγη σημασιολογικά τμηματοποιημένων εικόνων (semantically segmented) παρατήρησης μέσω της κάμερας του πράκτορα και φανταζόμενων εικόνων που παράγονται από τον αλγόριθμο DreamerV3.

- Σχεδιασμό και υλοποίηση ενός συνελικτικού νευρωνικού δικτύου δυαδικής ταξινόμησης (CNN Binary Classifier) και, στη συνέχεια, εκπαίδευσή του με το σύνολο δεδομένων που δημιουργήθηκε.

- Επέκταση του κύκλου αξιολόγησης του αλγορίθμου DreamerV3 και εξαγωγή δεδομένων των δύο μεθόδων σε πραγματικό χρόνο με χρήση των ίδιων σεναρίων, καθώς και σύγκριση των αποτελεσμάτων τους.

- Ανάλυση των συμπληρωματικών ιδιοτήτων των δύο μεθόδων και διερεύνηση της χρήσης τους ως συστημάτων δικλείδων ασφαλείας για αυτόνομη οδήγηση.

- Ενοποίηση των δύο μεθόδων σε ένα Σύστημα Παρατήρησης Ανωμαλιών δύο επιπέδων, υλοποίησή του ως επόπτη ασφαλείας κλειστού βρόχου με προοδευτική πέδηση και αξιολόγησή του έναντι του ανεξέλεγκτου πράκτορα και καθεμιάς συνιστώσας χωριστά.

1.3 Συνεισφορές

Οι κύριες συνεισφορές της παρούσας έρευνας είναι οι εξής:

1. Ένα πλήρως λειτουργικό περιβάλλον Gymnasium βασισμένο στον προσομοιωτή CARLA έκδοσης 0.9.15, ειδικά διαμορφωμένο για τον αλγόριθμο DreamerV3, με διακριτό χώρο ενεργειών (action space) δεκαπέντε σημείων, σημασιολογικά τμηματοποιημένη (semantically segmented) παρατήρηση, διάνυσμα κατάστασης (state vector) δώδεκα διαστάσεων εκφρασμένο στο σύστημα συντεταγμένων του οχήματος και σύνθετη συνάρτηση ανταμοιβής (reward function) που εξισορροπεί την ακολουθία σημείων διαδρομής, τη διατήρηση της επιθυμητής ταχύτητας, την αποφυγή συγκρούσεων και τη διατήρηση της πορείας εντός λωρίδων.

2. Μια υλοποίηση μεθόδου ανίχνευσης ανωμαλιών εντός του αλγορίθμου DreamerV3, σε αντιδιαστολή με προηγούμενες εφαρμογές στον DreamerV2, η οποία λειτουργεί σε πραγματικό χρόνο σε περιβάλλον προσομοίωσης με εμπόδια.

3. Ένα σύστημα δυαδικής ταξινόμησης ανώμαλων καταστάσεων βασισμένο σε συνελικτικό νευρωνικό δίκτυο και εκπαιδευμένο με ζεύγη σημασιολογικά τμηματοποιημένων εικόνων παρατήρησης και φαντασίας.

4. Μία συγκριτική αξιολόγηση των δύο προσεγγίσεων με εμπειρικά αποτελέσματα σχετικά με τα δυνατά σημεία και τους περιορισμούς τους ως συστήματα ενεργής παρακολούθησης ασφάλειας για πράκτορες αυτόνομης οδήγησης.

5. Ένα Σύστημα Παρατήρησης Ανωμαλιών δύο επιπέδων, υλοποιημένο ως επόπτης ασφαλείας κλειστού βρόχου με προοδευτική πέδηση και ρύθμιση εμπιστοσύνης από το όριο KL, μαζί με ένα πρωτόκολλο αξιολόγησης ασφάλειας βασισμένο σε αποστάσεις (ποσοστά συγκρούσεων με διαστήματα εμπιστοσύνης, περιθώρια στάσης, αποστάσεις έναρξης πέδησης, πρόωρες παρεμβάσεις), το οποίο μετρά τον επόπτη έναντι του ανεξέλεγκτου πράκτορα και καθεμιάς συνιστώσας του χωριστά.

1.4 Δομή εργασίας

Το Κεφάλαιο 2 αναλύει το θεωρητικό υπόβαθρο και τις βάσεις της παρούσας έρευνας, καλύπτοντας θέματα όπως η ενεργή αντίληψη, οι αρχιτεκτονικές αυτόνομης οδήγησης, η βαθιά μάθηση για κατανόηση σεναρίων, η ανάλυση του αλγορίθμου DreamerV3 και το πλαίσιο ανίχνευσης ανωμαλιών στην ενισχυτική μάθηση. Το Κεφάλαιο 3 περιγράφει τον σχεδιασμό και την πλήρη υλοποίηση του συστήματος που αναπτύχθηκε, δηλαδή το περιβάλλον CARLA - Gymnasium, την εκπαίδευση του DreamerV3, την υλοποίηση των δύο μεθόδων ανίχνευσης, τον βρόχο αξιολόγησης σε πραγματικό χρόνο και το Σύστημα Παρατήρησης Ανωμαλιών κλειστού βρόχου. Το Κεφάλαιο 4 παρουσιάζει και αναλύει τα πειραματικά αποτελέσματα της αξιολόγησης. Το Κεφάλαιο 5 συνοψίζει τα συμπεράσματα της εργασίας και προτείνει κατευθύνσεις μελλοντικής έρευνας.

2

Θεωρητικό Υπόβαθρο

2.1 Ενεργή Αντίληψη

Η έννοια της ενεργής αντίληψης (active perception), η οποία εισήχθη από την Ruzena Bajcsy (1988) [3] στη θεμελιώδη εργασία της, αποτέλεσε μία ριζική απομάκρυνση από το παθητικό παράδειγμα ανάλυσης που κυριαρχούσε στην έρευνα μηχανικής όρασης κατά τις δεκαετίες του 1970 και 1980. Η Bajcsy υποστήριξε ότι η ευφυής αντίληψη δεν αποτελεί μία διαδικασία παθητικής καταγραφής αισθητηριακών δεδομένων, αλλά έναν βρόχο ελέγχου κατευθυνόμενο από στόχους, στον οποίο ο πράκτορας επιλέγει ενεργά, διαδοχοποιεί και προσαρμόζει τις ενέργειες αισθητήρων με σκοπό την ελαχιστοποίηση της αβεβαιότητας σχετικά με την κατάσταση του κόσμου. Το καθοριστικό χαρακτηριστικό ενός συστήματος ενεργής αντίληψης είναι ότι διαθέτει έλεγχο τόσο ως προς το τι αντιλαμβάνεται όσο και ως προς τον τρόπο με τον οποίο αντιλαμβάνεται, προσαρμόζοντας παραμέτρους όπως η εστίαση κάμερας, η κατεύθυνση βλέμματος, η γωνία σύγκλισης και η χωρική θέση, ώστε να συλλέγει τις πλέον πλούσιες σε πληροφορία παρατηρήσεις.

Η Bajcsy διατύπωσε την ενεργή αντίληψη ως πρόβλημα βελτιστοποίησης: δεδομένης μίας τρέχουσας κατάστασης πεποίθησης σχετικά με το περιβάλλον, ο πράκτορας οφείλει να επιλέξει την ακολουθία ενεργειών αντίληψης που ελαχιστοποιεί μία συνάρτηση απώλειας, συνήθως ορισμένη ως συνάρτηση αβεβαιότητας ή πληροφοριακού κέρδους, υπό φυσικούς

και υπολογιστικούς περιορισμούς. Η διατύπωση αυτή τοποθέτησε την αντίληψη εντός του πλαισίου του θεωρητικού σχεδιασμού αποφάσεων, προαναγγέλλοντας αρκετές δεκαετίες νωρίτερα τις προσεγγίσεις ενισχυτικής μάθησης για ενεργή αντίληψη που αναπτύχθηκαν τη δεκαετία του 2010.

Οι Bajcsy, Αλοιμόνος και Τσότσος (2018) [4] επανεξέτασαν τις ιδέες αυτές τρεις δεκαετίες αργότερα, υποστηρίζοντας ότι οι θεμελιώδεις θεωρητικές συνεισφορές της ενεργής αντίληψης παραμένουν εξίσου επίκαιρες. Τα σύγχρονα ρομποτικά συστήματα διαθέτουν πλέον την απαραίτητη υπολογιστική ισχύ για την υλοποίηση του αρχικού πλαισίου σε μεγάλη κλίμακα· ωστόσο, το πεδίο είχε διαχωριστεί σε εξειδικευμένα υπο-προβλήματα, όπως η ανίχνευση αντικειμένων, το SLAM και η οπτική ροή, χωρίς μία ενοποιητική αρχή. Οι συγγραφείς υποστήριξαν την ανάγκη μίας νέας σύνθεσης, με την ενεργή αντίληψη να λειτουργεί ως το γενικό θεωρητικό πλαίσιο εντός του οποίου μπορούν να οργανωθούν τα σύγχρονα συστήματα βαθιάς μάθησης.

Η συνάφεια της ενεργής αντίληψης με την παρούσα πτυχιακή εργασία είναι διττή. Η σύγχρονη έρευνα έχει επεκτείνει τις αρχές της ενεργής αντίληψης σε πρακτικές εφαρμογές αυτόνομης οδήγησης: ενδεικτικό παράδειγμα αποτελεί η εργασία των Ancha κ.ά. (2020) [1], οι οποίοι προτείνουν τη χρήση ελεγχόμενων αισθητήρων «φωτεινής κουρτίνας» (light curtains) για 3D ανίχνευση αντικειμένων καθοδηγούμενη από την αβεβαιότητα πρόβλεψης ενός δικτύου βαθιάς μάθησης, αναπαράγοντας έτσι στο επίπεδο του αισθητήρα την ιδέα της Bajcsy για «συλλογή δεδομένων κατά παραγγελία». Αρχικά, το μοντέλο κόσμου του DreamerV3 μπορεί να θεωρηθεί ως μία μορφή ενεργής αντίληψης στον λανθάνοντα χώρο: το εσωτερικό μοντέλο του κόσμου του πράκτορα αποτελεί ένα πιθανοτικό παραγωγικό μοντέλο, το οποίο χρησιμοποιείται για την ενεργή πρόβλεψη μελλοντικών παρατηρήσεων, κλείνοντας έτσι τον βρόχο μεταξύ δράσης και αντίληψης. Επιπλέον, η ανίχνευση ανωμαλιών, που αποτελεί και τον κεντρικό άξονα της παρούσας εργασίας, αντιστοιχεί στο πλαίσιο της ενεργής αντίληψης, στο πρόβλημα εντοπισμού αποκλίσεων μεταξύ των προβλέψεων του μοντέλου κόσμου και των πραγματικών παρατηρήσεων, γεγονός που υποδηλώνει ότι η τρέχουσα κατάσταση πεποίθησης δεν αποτελεί πλέον αξιόπιστο οδηγό δράσης.

2.2 Αυτόνομη Οδήγηση: Αρχιτεκτονική και Προκλήσεις

Τα συστήματα αυτόνομης οδήγησης χαρακτηρίζονται συνήθως με βάση το επίπεδο αυτονομίας τους, το οποίο εκτείνεται από το Επίπεδο 0 (καμία αυτοματοποίηση) έως το Επίπεδο 5 (πλήρης αυτοματοποίηση χωρίς ανάγκη ανθρώπινης παρέμβασης υπό οποιεσδήποτε συνθήκες). Μέχρι το 2024, κανένα εμπορικά διαθέσιμο σύστημα δεν έχει επιτύχει αυτονομία Επιπέδου 5· τα πλέον προηγμένα συστήματα λειτουργούν στα Επίπεδα 2 ή 3, απαιτώντας συνεχή ανθρώπινη επίβλεψη ή δυνατότητα άμεσης ανάκτησης ελέγχου σε απαιτητικές συν-

θήκες [22].

Η κλασική αρθρωτή αρχιτεκτονική για αυτόνομη οδήγηση αποσυνθέτει το πρόβλημα οδήγησης σε επιμέρους υποσυστήματα αντίληψης, πρόβλεψης, σχεδιασμού και ελέγχου. Το υποσύστημα αντίληψης επεξεργάζεται ακατέργαστα δεδομένα αισθητήρων όπως κάμερες, LiDAR, radar και υπερηχητικούς αισθητήρες, και παράγει δομημένες αναπαραστάσεις του περιβάλλοντος, συμπεριλαμβανομένων ανιχνευμένων αντικειμένων, σημασιολογικών ετικετών και τοπικοποίησης του οχήματος. Οι Bachute και Subhedar (2021) [2] παρουσιάζουν μία εκτενή ταξινόμηση αλγορίθμων μηχανικής και βαθιάς μάθησης που χρησιμοποιούνται στα επιμέρους αυτά υποσυστήματα, συγκρίνοντας την απόδοσή τους μέσω μετρικών όπως τον μέσο λόγο τομής προς ένωση (mean intersection over union - mIoU) και την μέση ακρίβεια (average precision - AP). Οι Meng κ.ά. (2023) [25] μελέτησαν τριάντα πραγματικά συστήματα αυτόνομης οδήγησης και διαπίστωσαν ότι υψηλότερα επίπεδα αυτοματοποίησης συνδέονται με ολοένα και πιο ετερογενή σύνολα αισθητήρων και αυξημένη εξάρτηση από τεχνικές συγχώνευσης αυτών.

Οι περιορισμοί της αρθρωτής αρχιτεκτονικής, όπως η ευθραυστότητα στα όρια μεταξύ υποσυστημάτων, η συσσώρευση σφαλμάτων και η δυσκολία κοινής βελτιστοποίησης ολόκληρου του αγωγού επεξεργασίας, οδήγησαν στην ανάπτυξη προσεγγίσεων ολοκληρωτικής μάθησης (end-to-end learning), στις οποίες ένα ενιαίο νευρωνικό δίκτυο χαρτογραφεί απευθείας τις ακατέργαστες αισθητηριακές παρατηρήσεις σε ενέργειες ελέγχου. Οι Gupta κ.ά. (2021) [14] παρουσιάζουν μία επισκόπηση προσεγγίσεων βαθιάς μάθησης για ανίχνευση αντικειμένων και κατανόηση σκηνών στην αυτόνομη οδήγηση, καλύπτοντας συνελικτικές αρχιτεκτονικές, πολυτροπική συγχώνευση αισθητήρων και τις προκλήσεις εκτέλεσης σε πραγματικό χρόνο. Οι Kosuru και Venkitaraman (2023) [22] εξετάζουν ευρύτερες προκλήσεις που σχετίζονται με την επίτευξη αυτονομίας Επιπέδου 5, συμπεριλαμβανομένων πλαισίων κανονισμών, απαιτήσεων υποδομών και ζητημάτων κοινωνικής αποδοχής.

Μία κρίσιμη και ακόμη άλυτη πρόκληση για όλες τις αρχιτεκτονικές αυτόνομης οδήγησης είναι η ανθεκτικότητα σε συνθήκες εκτός κατανομής (out-of-distribution conditions). Ένα όχημα που έχει εκπαιδευτεί ή αξιολογηθεί σε ένα σύνολο καλά ορισμένων σεναρίων θα αντιμετωπίσει αναπόφευκτα καταστάσεις κατά τη λειτουργία του, όπως ασυνήθιστες διαμορφώσεις δρόμων, άτυπους χρήστες του οδικού δικτύου, ακραία καιρικά φαινόμενα ή αστοχίες αισθητήρων, οι οποίες δεν υπήρχαν στην αρχική κατανομή εκπαίδευσής του [7, 27]. Η ικανότητα ανίχνευσης τέτοιων καταστάσεων και κατάλληλης αντίδρασης, όπως η ανάληψη ελέγχου από άνθρωπο χειριστή ή η μείωση ταχύτητας, αποτελεί θεμελιώδη προϋπόθεση για την ασφαλή ανάπτυξη αυτόνομων οχημάτων.

2.3 Αισθητήρες και Στοίβα Αντίληψης σε Αυτόνομα Οχήματα

2.3.1 Τυπολογία Αισθητήρων

Το υποσύστημα αντίληψης ενός αυτόνομου οχήματος αποτελεί τον «αισθητήριο κόμβο» (sensing layer) της αρχιτεκτονικής, και το πλήθος, ο τύπος και η διάταξη των αισθητήρων αποτελούν κρίσιμες σχεδιαστικές αποφάσεις. Οι Meng κ.ά. (2023) [25], στη συστηματική ανάλυση 30 εμπορικών συστημάτων αυτόνομης οδήγησης, κατέδειξαν ότι τα συστήματα υψηλότερου επιπέδου αυτοματοποίησης χαρακτηρίζονται από αυξανόμενη αισθητηριακή ετερογένεια (sensor heterogeneity), δηλαδή από την παράλληλη χρήση πολλαπλών τύπων αισθητήρων, καθένας από τους οποίους συνεισφέρει στη γνώση του περιβάλλοντος με συμπληρωματικό τρόπο [10].

- **Κάμερες:** Οι οπτικές κάμερες αποτελούν τον βασικό αισθητήρα αντίληψης εικόνας, παρέχοντας πλούσια οπτική πληροφορία υψηλής ανάλυσης. Διακρίνονται σε RGB κάμερες (ακατέργαστη έγχρωμη εικόνα), κάμερες βάθους (depth cameras) και κάμερες σημασιολογικής τμηματοποίησης (semantic segmentation cameras), οι οποίες παράγουν pixel-wise ετικέτες κλάσεων αντί για τιμές χρώματος. Οι κάμερες εμφανίζουν χαμηλό κόστος και υψηλή ανάλυση, αλλά είναι ευαίσθητες σε δυσμενείς καιρικές και φωτεινές συνθήκες [36].

- **LiDAR (Light Detection and Ranging):** Ο αισθητήρας LiDAR εκπέμπει παλμούς λέιζερ και μετρά τον χρόνο επιστροφής για να δημιουργήσει νέφη σημείων (point clouds) τριών διαστάσεων με εξαιρετική χωρική ακρίβεια εκατοστών. Παρέχει αξιόπιστες μετρήσεις ακόμα και σε συνθήκες χαμηλού φωτισμού, αλλά είναι σημαντικά πιο ακριβός από τις κάμερες. Χρησιμοποιείται κυρίως για ανίχνευση εμποδίων, τοπικοποίηση (localization) και χαρτογράφηση (mapping).

- **RADAR (Radio Detection and Ranging):** Το RADAR εκπέμπει ραδιοκύματα και μετρά τον χρόνο επιστροφής και το φαινόμενο Doppler για ανίχνευση αντικειμένων και μέτρηση σχετικής ταχύτητας. Είναι ανθεκτικό σε δυσμενείς καιρικές συνθήκες (ομίχλη, βροχή, χιόνι) και παρέχει αξιόπιστη ανίχνευση σε μεγάλες αποστάσεις, με μειωμένη χωρική ανάλυση σε σύγκριση με τον LiDAR.

- **Υπερηχητικοί αισθητήρες:** Οι Υπερηχητικοί αισθητήρες χαρακτηρίζονται από το χαμηλό τους κόστος και χρησιμοποιούνται κυρίως για ανίχνευση σε μικρές αποστάσεις (0.2 - 5m), χαμηλής ταχύτητας ελιγμούς όπως παρκάρισμα και αποφυγή κοντινών εμποδίων.

2.3.2 Στοίβα Αντίληψης: Τέσσερις Κύριες Εργασίες

Ανεξαρτήτως του τύπου αισθητήρα που χρησιμοποιείται, ο αγωγός επεξεργασίας των σημάτων αντίληψης ενός αυτόνομου οχήματος περιλαμβάνει τέσσερις βασικές εργασίες [34, 14]:

1. **Ανίχνευση (Detection):** Εντοπισμός και οριοθέτηση αντικειμένων σε μία εικόνα ή νέφος σημείων. Κύριοι αλγόριθμοι βαθιάς μάθησης: YOLO [29], Faster R-CNN, SSD. Ο στόχος είναι η εύρεση τόσο στατικών αντικειμένων (κτήρια, δέντρα, εμπόδια) όσο και δυναμικών (πεζοί, ποδηλάτες, οχήματα).

2. **Ταξινόμηση (Classification):** Μόλις εντοπιστεί ένα αντικείμενο, η ταξινόμηση καθορίζει σε ποια κατηγορία ανήκει (π.χ. πεζός, αυτοκίνητο, φορτηγό, ποδήλατο). Η ακρίβεια ταξινόμησης εξαρτάται σε μεγάλο βαθμό από την ποιότητα και ποσότητα των δεδομένων εκπαίδευσης.

3. **Παρακολούθηση (Tracking):** Παρακολούθηση κινούμενων αντικειμένων διαχρονικά, με υπολογισμό ταχύτητας, επιτάχυνσης και προβλεπόμενης τροχιάς. Ο συνδυασμός ανίχνευσης-ταξινόμησης-παρακολούθησης (detect-classify-track) είναι απαραίτητος για τον ασφαλή σχεδιασμό κίνησης.

4. **Σημασιολογική Τμηματοποίηση (Semantic Segmentation):** Ανάθεση σημασιολογικής ετικέτας κλάσης σε κάθε εικονοστοιχείο (pixel) της εικόνας. Σε αντίθεση με την ανίχνευση bounding boxes, η τμηματοποίηση παρέχει pixel-level κατανόηση της σκηνής, διαχωρίζοντας οδόστρωμα, πεζοδρόμιο, σηματοδοτήσεις, κτήρια, βλάστηση, οχήματα και πεζούς.

2.3.3 Σημασιολογική Τμηματοποίηση και Παλέτα CityScapes

Η σημασιολογική τμηματοποίηση αποτελεί ιδιαίτερα σημαντική εργασία αντίληψης για συστήματα αυτόνομης οδήγησης που λειτουργούν σε αστικά περιβάλλοντα. Το σύνολο δεδομένων Cityscapes [9], το οποίο εισήγαγαν οι Cordts κ.ά. (2016), αποτελεί το καθιερωμένο πρότυπο αξιολόγησης αλγορίθμων σημασιολογικής τμηματοποίησης αστικών σκηνών. Περιλαμβάνει 5.000 λεπτομερώς σχολιασμένες εικόνες από 50 ευρωπαϊκές πόλεις, 30 συνολικές κλάσεις εκ των οποίων 19 χρησιμοποιούνται στην αξιολόγηση, οργανωμένες σε 8 υπερκατηγορίες (επίπεδη επιφάνεια, μηχανολογικές εργασίες, φύση, ουρανός, άνθρωπος, όχημα, αντικείμενο, κ.ά.), με δείκτη αξιολόγησης mIoU (mean Intersection over Union).

Στο πλαίσιο της παρούσας εργασίας, η σημασιολογικά τμηματοποιημένη κάμερα του CARLA χρησιμοποιείται αντί για ακατέργαστο RGB σήμα για δύο λόγους: *(i)* η σημασιολογική παλέτα παρέχει αμετάβλητες (invariant) αναπαραστάσεις ανεξαρτήτως φωτισμού και καιρικών συνθηκών, και *(ii)* οι αποκλίσεις μεταξύ πραγματικής και φανταζόμενης σημασιολογικής εικόνας είναι πιο ευδιάκριτες και ερμηνεύσιμες, καθιστώντας τη σύγκριση κατάλληλη

τόσο για τη μέθοδο KL-Divergence όσο και για τον CNN ταξινομητή. Το CARLA παρέχει σημασιολογική τμηματοποίηση με 28 κλάσεις βασισμένες στη CityScapes παλέτα, στην συγκεκριμένη υλοποίηση χρησιμοποιούνται οι 19 από αυτές όπως αναφέρονται στο κεφάλαιο 3.3.4 [11].

2.4 Περιβάλλοντα Προσομοίωσης για Έρευνα Αυτόνομης Οδήγησης

Η έρευνα στην αυτόνομη οδήγηση περιορίζεται σημαντικά από το κόστος και την οργανωτική πολυπλοκότητα πειραμάτων στον πραγματικό κόσμο. Η εξοπλισμένη λειτουργία ακόμη και ενός μόνο ερευνητικού οχήματος απαιτεί σημαντική επένδυση, ενώ η συλλογή συνόλου δεδομένων που να καλύπτει επαρκώς την μεγάλη σειρά σπάνιων αλλά κρίσιμων για την ασφάλεια γεγονότων είναι ουσιαστικά ανέφικτη σε φυσικές συνθήκες. Η προσομοίωση παρέχει μία επεκτάσιμη εναλλακτική λύση, επιτρέποντας γρήγορη επανάληψη πειραμάτων, ελεγχόμενες πειραματικές συνθήκες και ασφαλή αναπαραγωγή επικίνδυνων σεναρίων.

Το CARLA (Car Learning to Act), το οποίο παρουσιάστηκε από τους Dosovitskiy κ.ά. (2017) [11], αποτελεί έναν ανοικτού κώδικα προσομοιωτή αστικής οδήγησης βασισμένο στη μηχανή γραφικών Unreal Engine. Παρέχει ένα ποικίλο σύνολο αστικών περιβαλλόντων, ευέλικτο σύστημα αισθητήρων (κάμερες με παραμετροποιήσιμη μετεπεξεργασία, LiDAR, radar, GPS και IMU), ρυθμιζόμενες κυκλοφοριακές και καιρικές συνθήκες, διεπαφή Python για αλληλεπίδραση με το περιβάλλον και τυποποιημένο πρωτόκολλο αξιολόγησης. Το CARLA έχει καταστεί μια από τις κυρίαρχες πλατφόρμες προσομοίωσης για έρευνα αυτόνομης οδήγησης, αποτελώντας περιβάλλον αξιολόγησης τόσο για το παιγνιοθεωρητικό πλαίσιο ενεργής αντίληψης των Zhang και Fisac (2021) [37], όσο και για την πλατφόρμα CarDreamer [13], η οποία επηρεάζει άμεσα την παρούσα εργασία.

Οι Richter, Hayder και Koltun (2017) [30] απέδειξαν ότι συνθετικά δεδομένα υψηλής ποιότητας, τα οποία συλλέγονται από εμπορικές κάρτες γραφικών (GPUs), μπορούν να προσεγγίσουν τα πραγματικά σύνολα δεδομένων ως προς τις στατιστικές τους ιδιότητες. Το σύνολο αξιολόγησής τους, αποτελούμενο από 254.000 σχολιασμένα καρέ από ρεαλιστικό αστικό περιβάλλον παιχνιδιού, συλλέχθηκε χωρίς πρόσβαση στον πηγαίο κώδικα του παιχνιδιού, μέσω μίας νέας μεθόδου σχολιασμού. Η εργασία αυτή επιβεβαίωσε την αρχή ότι τα συνθετικά δεδομένα μπορούν να αντικαταστήσουν ή να συμπληρώσουν πραγματικά δεδομένα, αρχή η οποία αποτελεί και τη θεωρητική βάση χρήσης του CARLA στην παρούσα πτυχιακή εργασία.

2.5 Θεωρητικό Πλαίσιο Ενισχυτικής Μάθησης

Η Ενισχυτική Μάθηση (Reinforcement Learning - RL) [33] αποτελεί έναν κλάδο μηχανικής μάθησης στον οποίο ένας πράκτορας (agent) μαθαίνει να λαμβάνει αποφάσεις αλληλεπιδρώντας με ένα περιβάλλον (environment) μέσω κύκλων δράσης-παρατήρησης-ανταμοιβής. Σε αντίθεση με την επιβλεπόμενη μάθηση, ο πράκτορας δεν λαμβάνει ετικέτες ορθών ενεργειών αλλά μόνο ένα βαθμωτό (scalar) σήμα ανταμοιβής, το οποίο αντικατοπτρίζει την «ποιότητα» κάθε ενέργειας σε σχέση με τον εκάστοτε στόχο. Η παρούσα ενότητα παρουσιάζει τα θεμελιώδη μαθηματικά εργαλεία που απαιτούνται για την κατανόηση του DreamerV3 που χρησιμοποιείται στην παρούσα εργασία.

2.5.1 Μαρκοβιανή Διαδικασία Απόφασης

Τυπικός Ορισμός

Η Μαρκοβιανή Διαδικασία Απόφασης (Markov Decision Process - MDP) [28] αποτελεί το θεμελιώδες μαθηματικό πλαίσιο για την τυπική μοντελοποίηση προβλημάτων ακολουθιακής λήψης αποφάσεων. Ο τυπικός ορισμός ανάγεται στο έργο του Bellman (1957) [5] στον Δυναμικό Προγραμματισμό (Dynamic Programming), ενώ η σύγχρονη αντιμετώπιση της θεωρίας RL σε πλαίσιο MDP καθιερώθηκε κυρίως από τους Sutton και Barto [33].

Τυπικά, μία MDP ορίζεται ως $(\mathcal{S}, \mathcal{A}, \mathcal{P}, \mathcal{R}, \gamma)$, όπου:

- $\mathcal{S}$ είναι ο **χώρος καταστάσεων** (state space), ο οποίος μπορεί να είναι πεπερασμένος ή άπειρος, διακριτός ή συνεχής,
- $\mathcal{A}$ είναι ο **χώρος ενεργειών** (action space), που αντίστοιχα μπορεί να είναι διακριτός ή συνεχής,
- $\mathcal{P} : \mathcal{S} \times \mathcal{A} \times \mathcal{S} \to [0, 1]$ είναι η **συνάρτηση μετάβασης καταστάσεων** (transition function), ορισμένη ως υπό συνθήκη πιθανότητα $\mathcal{P}(s' \mid s, a)$ μετάβασης στην κατάσταση s' όταν εκτελεστεί η ενέργεια a στην κατάσταση s,
- $\mathcal{R} : \mathcal{S} \times \mathcal{A} \to \mathbb{R}$ είναι η **συνάρτηση ανταμοιβής** (reward function), που αντιστοιχεί στο αναμενόμενο βαθμωτό σήμα r_t που λαμβάνει ο πράκτορας μετά από κάθε μετάβαση,
- $\gamma \in [0, 1)$ είναι ο **παράγοντας προεξόφλησης** (discount factor), που καθορίζει τη σχετική σπουδαιότητα μελλοντικών έναντι άμεσων ανταμοιβών.

Μαρκοβιανή Ιδιότητα

Η ομώνυμη Μαρκοβιανή ιδιότητα (Markov property) υπαγορεύει ότι η κατανομή πιθανότητας της επόμενης κατάστασης εξαρτάται αποκλειστικά από την τρέχουσα κατάσταση και

την ενέργεια που επιλέχθηκε, ανεξαρτήτως όλου του προηγούμενου ιστορικού:

$$\mathcal{P}(s_{t+1} \mid s_t, a_t, s_{t-1}, a_{t-1}, \ldots, s_0, a_0) = \mathcal{P}(s_{t+1} \mid s_t, a_t)$$

Η ιδιότητα αυτή συνεπάγεται ότι η τρέχουσα κατάσταση s_t «συνοψίζει» πλήρως ό,τι είναι γνωστό για το παρελθόν και το μέλλον του συστήματος, καθιστώντας περιττή τη διατήρηση ολόκληρης της ιστορίας αλληλεπιδράσεων.

Πολιτική, Συνάρτηση Αξίας και Εξισώσεις Bellman

Ο στόχος της RL σε πλαίσιο MDP είναι η εύρεση μίας **πολιτικής** $\pi : \mathcal{S} \to \Delta(\mathcal{A})$, η οποία χαρτογραφεί καταστάσεις σε κατανομές πιθανότητας πάνω στον χώρο ενεργειών, ούτως ώστε να μεγιστοποιείται η αναμενόμενη αθροιστική προεξοφλημένη ανταμοιβή:

$$J(\pi) = \mathbb{E}_\pi \left[\sum_{t=0}^{\infty} \gamma^t r_t \right]$$

Η **συνάρτηση αξίας κατάστασης** (state-value function) $V^\pi : \mathcal{S} \to \mathbb{R}$ εκτιμά την αναμενόμενη αθροιστική ανταμοιβή ξεκινώντας από κατάσταση s και ακολουθώντας την πολιτική π:

$$V^\pi(s) = \mathbb{E}_\pi \left[\sum_{t=0}^{\infty} \gamma^t r_t \;\middle|\; s_0 = s \right]$$

Αντίστοιχα, η **συνάρτηση αξίας ενέργειας** (action-value function ή Q-function) $Q^\pi : \mathcal{S} \times \mathcal{A} \to \mathbb{R}$ εκτιμά την αναμενόμενη αθροιστική ανταμοιβή εάν εκτελεστεί η ενέργεια a στην κατάσταση s και στη συνέχεια ακολουθηθεί η πολιτική π:

$$Q^\pi(s, a) = \mathbb{E}_\pi \left[\sum_{t=0}^{\infty} \gamma^t r_t \;\middle|\; s_0 = s,\, a_0 = a \right]$$

Η αναδρομική σχέση που συνδέει τις δύο αυτές συναρτήσεις εκφράζεται μέσω των **εξισώσεων Bellman** (Bellman equations) [5]:

$$V^\pi(s) = \sum_{a \in \mathcal{A}} \pi(a \mid s) \left[\mathcal{R}(s, a) + \gamma \sum_{s' \in \mathcal{S}} \mathcal{P}(s' \mid s, a)\, V^\pi(s') \right] \tag{2.1}$$

$$Q^\pi(s, a) = \mathcal{R}(s, a) + \gamma \sum_{s' \in \mathcal{S}} \mathcal{P}(s' \mid s, a) \sum_{a' \in \mathcal{A}} \pi(a' \mid s')\, Q^\pi(s', a') \tag{2.2}$$

Βέλτιστη Πολιτική και Εξισώσεις Βέλτιστης Τιμής

Η βέλτιστη πολιτική π^* ορίζεται ως εκείνη που μεγιστοποιεί τη συνάρτηση αξίας για κάθε κατάσταση:

$$\pi^* = \arg\max_{\pi} V^{\pi}(s), \qquad \forall\, s \in \mathcal{S}$$

Η βέλτιστη συνάρτηση αξίας $V^*(s) = \max_\pi V^\pi(s)$ ικανοποιεί τις **εξισώσεις βέλτιστης τιμής Bellman** (Bellman optimality equations):

$$V^*(s) = \max_{a \in \mathcal{A}} \left[\mathcal{R}(s,a) + \gamma \sum_{s' \in \mathcal{S}} \mathcal{P}(s' \mid s,a)\, V^*(s') \right] \tag{2.3}$$

$$Q^*(s,a) = \mathcal{R}(s,a) + \gamma \sum_{s' \in \mathcal{S}} \mathcal{P}(s' \mid s,a) \max_{a' \in \mathcal{A}} Q^*(s',a') \tag{2.4}$$

Επέκταση σε Μερικώς Παρατηρήσιμα Περιβάλλοντα (POMDP)

Στην πράξη, τα περισσότερα σύγχρονα περιβάλλοντα RL δεν πληρούν αυστηρά τη Μαρκοβιανή ιδιότητα στον χώρο των παρατηρήσεων, καθώς ο πράκτορας δεν έχει πρόσβαση στην πλήρη κατάσταση s_t αλλά μόνο σε μερικές παρατηρήσεις o_t (π.χ. εικόνες κάμερας). Ένα τέτοιο σύστημα μοντελοποιείται ως **Μερικώς Παρατηρήσιμη MDP** (Partially Observable MDP - POMDP) [20], η οποία επεκτείνει την MDP με:

- τον χώρο παρατηρήσεων $\mathcal{O}$,
- και τη συνάρτηση εκπομπής $\mathcal{E}(o_t \mid s_t)$, που περιγράφει πώς οι παρατηρήσεις παράγονται από τις κρυφές καταστάσεις.

Η αντιμετώπιση της μερικής παρατηρησιμότητας αποτελεί έναν από τους κεντρικούς ρόλους του RSSM του DreamerV3 (βλ. Ενότητα 2.6.2): η αναδρομική ντετερμινιστική κατάσταση h_t λειτουργεί ως συμπαγής αναπαράσταση της κατάστασης πεποίθησης (belief state) του πράκτορα, συγκεντρώνοντας πληροφορία από ολόκληρο το ιστορικό παρατηρήσεων και ενεργειών.

2.5.2 Απόκλιση Kullback-Leibler

Εντροπία Shannon και Θεωρία Πληροφορίας

Η απόκλιση Kullback-Leibler (KL), γνωστή και ως *σχετική εντροπία* (relative entropy), αποτελεί θεμελιώδες μέγεθος της Θεωρίας Πληροφορίας (Information Theory) [32, 23] και χρησιμοποιείται εκτεταμένα σε μεταβλητική συμπερασματολογία (variational inference), γλωσσικά μοντέλα και αλγορίθμους RL. Το θεμέλιό της είναι η **εντροπία Shannon** [32], που μετρά τη μέση αβεβαιότητα (ή πληροφοριακό περιεχόμενο) μιας τυχαίας μεταβλητής X

με κατανομή P:

$$H(P) = -\sum_{x} P(x) \log P(x)$$

Για συνεχή κατανομή, ο παραπάνω ορισμός επεκτείνεται με αντικατάσταση του αθροίσματος από ολοκλήρωμα. Η εντροπία $H(P)$ λαμβάνει μέγιστη τιμή για ομοιόμορφη κατανομή, εκφράζοντας τη μέγιστη αβεβαιότητα.

Τυπικός Ορισμός Απόκλισης KL

Για δύο κατανομές πιθανότητας P και Q ορισμένες στον ίδιο χώρο δειγματοληψίας, η απόκλιση KL $\mathrm{KL}(P\|Q)$ ορίζεται ως [23]:

$$\mathrm{KL}(P\|Q) = \sum_{x} P(x) \log \frac{P(x)}{Q(x)}$$

για διακριτές κατανομές, ή ισοδύναμα:

$$\mathrm{KL}(P\|Q) = \int p(x) \log \frac{p(x)}{q(x)}\, dx$$

για συνεχείς κατανομές. Εδώ, P συνήθως αντιστοιχεί στην «πραγματική» ή target κατανομή, ενώ Q αντιστοιχεί στην προσεγγιστική ή reference κατανομή.

Ιδιότητες

Η απόκλιση KL εμφανίζει τις ακόλουθες σημαντικές ιδιότητες:

1. **Μη-αρνητικότητα:** $\mathrm{KL}(P\|Q) \geq 0$, με ισότητα αν και μόνον αν $P = Q$ σχεδόν παντού. Αυτό απορρέει άμεσα από την ανισότητα του Jensen εφαρμοζόμενη στην κυρτή συνάρτηση log.

2. **Ασυμμετρία:** $\mathrm{KL}(P\|Q) \neq \mathrm{KL}(Q\|P)$ γενικά, οπότε δεν αποτελεί μετρική απόσταση κατά τη μαθηματική έννοια. Εξ αυτού, ο *forward KL* $\mathrm{KL}(P\|Q)$ (zero-avoiding) και ο *reverse KL* $\mathrm{KL}(Q\|P)$ (zero-forcing) οδηγούν σε διαφορετικά εφαρμοσμένα αποτελέσματα κατά την προσέγγιση κατανομών.

3. **Αθροιστικότητα για ανεξάρτητες κατανομές:** για ανεξάρτητες τυχαίες μεταβλητές (X, Y), ισχύει $\mathrm{KL}(P_{XY}\|Q_{XY}) = \mathrm{KL}(P_X\|Q_X) + \mathrm{KL}(P_Y\|Q_Y)$.

Σύνδεση με Μεταβλητική Συμπερασματολογία και VAE

Στο πλαίσιο των μεταβλητικών Αυτο-κωδικοποιητών (Variational Autoencoders - VAE) [21], η απόκλιση KL εμφανίζεται ως κανονικοποιητικός όρος στο Κατώτατο Όριο Αποδεί-

ξεων (Evidence Lower Bound - ELBO):

$$\mathcal{L}_{\text{ELBO}} = \mathbb{E}_{q(z|x)}[\log p(x \mid z)] - \text{KL}(q(z \mid x) \| p(z))$$

Ο πρώτος όρος (ανακατασκευή) μετρά την ποιότητα παραγωγής εξόδου, ενώ ο δεύτερος (KL) λειτουργεί ως ρυθμιστής που τιμωρεί αποκλίσεις της posterior $q(z|x)$ από την prior $p(z)$. Ο τρόπος λειτουργίας του RSSM ακολουθεί το ίδιο αρχιτεκτονικό μοτίβο.

Ρόλος στο DreamerV3 και στην Ανίχνευση Ανωμαλιών

Στο RSSM του DreamerV3, η απόκλιση KL εμφανίζεται σε δύο ξεχωριστούς ρόλους. Πρώτον, ως **κανονικοποιητικός όρος εκπαίδευσης**: η απόκλιση $\text{KL}[q(z_t \mid h_t, x_t) \| p(z_t \mid h_t)]$ ενθαρρύνει το transition model (prior) να προβλέπει με ακρίβεια την posterior κατανομή που παρήχθη από την πραγματική παρατήρηση. Δεύτερον, ως **μέτρο ανίχνευσης ανωμαλιών**: η μέθοδος των Zollicoffer κ.ά. [38] (βλ. Ενότητα 2.8) χρησιμοποιεί σύνθεση τριών KL όρων ώστε να ορίσει ένα θεωρητικά θεμελιωμένο κατώφλι ανίχνευσης OOD καταστάσεων.

2.6 DreamerV3: Ενισχυτική Μάθηση με Μοντέλα Κόσμου

2.6.1 Επισκόπηση

Ο DreamerV3 [16] αποτελεί έναν αλγόριθμο ενισχυτικής μάθησης βασισμένο σε μοντέλα κόσμου, ο οποίος μαθαίνει ένα εσωτερικό μοντέλο του περιβάλλοντος από παρατηρήσεις εικόνας υψηλής διάστασης και βελτιστοποιεί μία πολιτική αποκλειστικά εντός του λανθάνοντος χώρου του μοντέλου αυτού. Αποτελεί την κορύφωση της σειράς αλγορίθμων Dreamer, οι οποίοι βασίζονται στην ιδέα των μοντέλων κόσμου (world models) των Ha και Schmidhuber [15], και επιτυγχάνει κορυφαία δειγματική αποδοτικότητα (sample efficiency) σε περισσότερες από 150 ετερογενείς εργασίες χρησιμοποιώντας μία ενιαία και σταθερή παραμετροποίηση υπερπαραμέτρων. Μεταξύ αυτών περιλαμβάνεται και η πρώτη πλήρως αυτόνομη συλλογή διαμαντιών στο Minecraft χωρίς ανθρώπινες επιδείξεις ή προκαθορισμένα προγράμματα εκπαίδευσης [17].

Τα τρία βασικά συστατικά του DreamerV3 είναι:

1. ένα μοντέλο κόσμου που μαθαίνει να προβλέπει τις συνέπειες των ενεργειών σε έναν συμπιεσμένο λανθάνοντα χώρο,

2. ένα δίκτυο actor που μαθαίνει να επιλέγει ενέργειες οι οποίες μεγιστοποιούν τη φανταζόμενη αθροιστική ανταμοιβή,

3. και ένα δίκτυο critic που μαθαίνει να εκτιμά την αξία των λανθανουσών καταστάσεων.

Το μοντέλο κόσμου εκπαιδεύεται αποκλειστικά μέσω πραγματικών αλληλεπιδράσεων με το περιβάλλον, ενώ τα δίκτυα actor και critic εκπαιδεύονται αποκλειστικά μέσω φανταζόμενων τροχιών που παράγονται από το ίδιο το μοντέλο κόσμου.

2.6.2 Επαναλαμβανόμενο Μοντέλο Χώρου Καταστάσεων (RSSM)

Κίνητρο και Αρχιτεκτονική Υψηλού Επιπέδου

Το μοντέλο κόσμου βασίζεται σε ένα Επαναλαμβανόμενο Μοντέλο Χώρου Καταστάσεων (Recurrent State-Space Model - RSSM) [16]. Η κεντρική πρόκληση που καλείται να αντιμετωπίσει το RSSM είναι η μερική παρατηρησιμότητα του πραγματικού κόσμου: μία μεμονωμένη εικόνα κάμερας δεν κωδικοποιεί πλήρως την κατάσταση του περιβάλλοντος (π.χ. ταχύτητα, επιτάχυνση, κρυμμένα αντικείμενα). Για να ξεπεραστεί αυτός ο περιορισμός, το RSSM **παραγοντοποιεί τη λανθάνουσα κατάσταση σε ένα ντετερμινιστικό και ένα στοχαστικό στοιχείο**:

- Το **ντετερμινιστικό στοιχείο** h_t παράγεται από ένα Επαναλαμβανόμενο Νευρωνικό Δίκτυο (Gated Recurrent Unit - GRU), το οποίο ενημερώνεται αυτοπαλίνδρομα σε κάθε χρονικό βήμα. Αυτή η αναδρομική κατάσταση λειτουργεί ως «μνήμη» του πράκτορα: αθροίζει κωδικοποιημένες πληροφορίες από όλα τα προηγούμενα ζεύγη παρατήρησης-ενέργειας, αντιμετωπίζοντας έτσι το πρόβλημα μερικής παρατηρησιμότητας. Η ντετερμινιστική διαδικασία αποτελεί ανάλογο της κατάστασης πεποίθησης (belief state) σε ένα POMDP [20].

- Το **στοχαστικό στοιχείο** z_t κωδικοποιεί την πληροφορία της τρέχουσας παρατήρησης που δεν μπορεί να προβλεφθεί από το ιστορικό, εκφράζοντας την πληροφοριακά μη αναγώγιμη αβεβαιότητα του περιβάλλοντος. Η διπλή αυτή αναπαράσταση επιτρέπει τη «φαντασία» μελλοντικών τροχιών χρησιμοποιώντας μόνο τα ντετερμινιστικά και στοχαστικά πρότυπα, χωρίς πρόσβαση στον πραγματικό αισθητήρα.

Τυπική Διατύπωση των Υπομοντέλων

Τυπικά, το RSSM αποτελείται από τα εξής επιμέρους υπομοντέλα:

- **Επαναλαμβανόμενο μοντέλο** (GRU):

$$h_t = f_\phi(h_{t-1}, z_{t-1}, a_{t-1})$$

Ένα δίκτυο GRU ενημερώνει τη ντετερμινιστική κατάσταση από την προηγούμενη λανθάνουσα κατάσταση, την προηγούμενη στοχαστική κατάσταση και την προηγού-

μενη ενέργεια. Η χρήση GRU αντί LSTM μειώνει το υπολογιστικό κόστος και το πλήθος παραμέτρων κατά την εκπαίδευση σε ακολουθίες.

- **Μοντέλο αναπαράστασης** (posterior q):

$$z_t \sim q_\phi(z_t \mid h_t, x_t)$$

Ένας συνελικτικός κωδικοποιητής (CNN) συμπιέζει την τρέχουσα παρατήρηση x_t (εικόνα) υπό συνθήκη της ντετερμινιστικής κατάστασης h_t, παράγοντας μία στοχαστική κατανομή posterior. Κατά την εκπαίδευση το μοντέλο αναπαράστασης έχει πρόσβαση στην πραγματική παρατήρηση, άρα υπολογίζει «πλούσια» posterior.

- **Μοντέλο μετάβασης** (prior p):

$$\hat{z}_t \sim p_\phi(\hat{z}_t \mid h_t)$$

Το μοντέλο μετάβασης προβλέπει την κατανομή της επόμενης στοχαστικής κατάστασης αποκλειστικά από τη ντετερμινιστική κατάσταση h_t, χωρίς πρόσβαση στην τρέχουσα παρατήρηση. Αυτή η διαδικασία αντιστοιχεί στη «φαντασία» (imagination) του μοντέλου: αναδίπλωση μελλοντικών τροχιών αμιγώς βάσει μαθημένων δυναμικών.

- **Αποκωδικοποιητής παρατήρησης**:

$$\hat{x}_t \sim p_\phi(\hat{x}_t \mid h_t, z_t)$$

Ανακατασκευάζει την παρατήρηση από τη λανθάνουσα κατάσταση (h_t, z_t). Η ποιότητα ανακατασκευής παρέχει ένα εκπαιδευτικό σήμα που ενθαρρύνει τον κωδικοποιητή να διατηρεί πληροφοριακά σχετικά χαρακτηριστικά.

- **Προβλεπτής ανταμοιβής**:

$$\hat{r}_t \sim p_\phi(\hat{r}_t \mid h_t, z_t)$$

Προβλέπει το βαθμωτό σήμα ανταμοιβής από τη λανθάνουσα κατάσταση.

- **Προβλεπτής συνέχισης επεισοδίου**:

$$\hat{\gamma}_t \sim p_\phi(\hat{\gamma}_t \mid h_t, z_t)$$

Προβλέπει την πιθανότητα συνέχισης του επεισοδίου (δηλ. εάν η κατάσταση είναι τερματική), επιτρέποντας στον actor-critic να αντιμετωπίσει ορθά τα φανταζόμενα τερματικά γεγονότα.

Κατηγορική Αναπαράσταση και Απόκλιση KL

Αντί για συνήθεις Γκαουσιανές κατανομές, ο DreamerV3 χρησιμοποιεί **κατηγορικές κατανομές** (categorical distributions) για τη στοχαστική κατάσταση: 32 ανεξάρτητες κατηγορίες διαστάσεως 32 η καθεμία, παράγοντας μια αναπαράσταση 1024 διαστάσεων (32×32). Η επιλογή αυτή βελτιώνει τη χαρακτηριστική ακρίβεια αναπαράστασης σε σχέση με Γκαουσιανές κατανομές, καθώς οι κατηγορικές μεταβλητές μπορούν να κωδικοποιήσουν αυθαίρετες πολυτροπικές και μη-ομαλές posterior κατανομές.

Η απόκλιση KL μεταξύ posterior και prior, $\mathrm{KL}[q(z_t \mid h_t, x_t) \| p(z_t \mid h_t)]$, αποτελεί κεντρικό όρο της συνάρτησης απώλειας (βλ. Ενότητα 2.6.3), ενθαρρύνοντας το transition model να μπορεί να προβλέψει με ακρίβεια την posterior κατανομή χωρίς πρόσβαση στην παρατήρηση.

2.6.3 Στόχοι Εκπαίδευσης και Τεχνικές Ανθεκτικότητας

Συνάρτηση Απώλειας Μοντέλου Κόσμου

Το μοντέλο κόσμου εκπαιδεύεται end-to-end μέσω ελαχιστοποίησης μίας σύνθετης συνάρτησης απώλειας [16]. Δεδομένης μίας δεσμίδας ακολουθιών εισόδων $x_{1:T}$, ενεργειών $a_{1:T}$, ανταμοιβών $r_{1:T}$ και σημαιών συνέχισης $c_{1:T}$, οι παράμετροι ϕ ελαχιστοποιούν:

$$\mathcal{L}(\phi) = \mathbb{E}_{q_\phi}\left[\sum_{t=1}^{T}\Big(\beta_{\text{pred}}\,\mathcal{L}_{\text{pred}}(\phi) + \beta_{\text{dyn}}\,\mathcal{L}_{\text{dyn}}(\phi) + \beta_{\text{rep}}\,\mathcal{L}_{\text{rep}}(\phi)\Big)\right]$$

με βάρη $\beta_{\text{pred}} = 1$, $\beta_{\text{dyn}} = 1$ και $\beta_{\text{rep}} = 0.1$. Οι τρεις επιμέρους απώλειες ορίζονται ως:

$$\mathcal{L}_{\text{pred}}(\phi) = -\ln p_\phi(x_t \mid z_t, h_t) - \ln p_\phi(r_t \mid z_t, h_t) - \ln p_\phi(c_t \mid z_t, h_t) \tag{2.5}$$

$$\mathcal{L}_{\text{dyn}}(\phi) = \max\big(1,\ \mathrm{KL}\big[\,\mathrm{sg}(q_\phi(z_t \mid h_t, x_t)) \,\big\|\, p_\phi(z_t \mid h_t)\big]\big) \tag{2.6}$$

$$\mathcal{L}_{\text{rep}}(\phi) = \max\big(1,\ \mathrm{KL}\big[q_\phi(z_t \mid h_t, x_t) \,\big\|\, \mathrm{sg}(p_\phi(z_t \mid h_t))\big]\big) \tag{2.7}$$

όπου $\mathrm{sg}(\cdot)$ συμβολίζει τον τελεστή αποκοπής βαθμίδας (stop-gradient). Η διαφορά μεταξύ $\mathcal{L}_{\text{dyn}}$ και $\mathcal{L}_{\text{rep}}$ έγκειται στο πού εφαρμόζεται η αποκοπή: η $\mathcal{L}_{\text{dyn}}$ εκπαιδεύει το transition model (prior) να προβλέπει τη posterior, ενώ η $\mathcal{L}_{\text{rep}}$ εκπαιδεύει τις αναπαραστάσεις να καθίστανται πιο προβλέψιμες. Το $\max(1, \cdot)$ υλοποιεί τη στρατηγική **free bits** [16]: αν η KL ήδη υπερβαίνει 1 nat ≈ 1.44 bits, η απώλεια ενεργοποιείται· διαφορετικά παραμένει ανενεργή, αποτρέποντας παθολογικές λύσεις όπου οι αναπαραστάσεις γίνονται εκφυλιστικά απλές.

Μετασχηματισμός Symlog

Για τη διαχείριση τιμών ανταμοιβής διαφορετικών τάξεων μεγέθους, το DreamerV3 εισάγει τον μετασχηματισμό **symlog**:

$$\text{symlog}(x) = \text{sign}(x) \cdot \ln(|x| + 1)$$

ο οποίος εφαρμόζεται τόσο στους στόχους ανταμοιβής όσο και στις εισόδους διανύσματος κατάστασης. Η αντίστροφη συνάρτηση (*symexp*) εφαρμόζεται στις εξόδους των προβλεπτών, επιτρέποντας σταθερή εκπαίδευση ακόμα και όταν οι ανταμοιβές διαφέρουν κατά πολλές τάξεις μεγέθους μεταξύ διαφορετικών εργασιών.

Two-Hot Κωδικοποίηση Ανταμοιβών

Αντί για παλινδρόμηση, ο προβλεπτής ανταμοιβής εξάγει μία κατηγορική κατανομή πάνω σε ένα πλέγμα από B τιμές. Ο στόχος ανταμοιβής r κωδικοποιείται ως **two-hot διάνυσμα**: μόνο τα δύο κοντινότερα σημεία του πλέγματος b_i, b_{i+1} έχουν μη-μηδενική πιθανότητα, αναλογική της γραμμικής παρεμβολής τους. Η two-hot κωδικοποίηση σε συνδυασμό με symlog εκτιμάται ότι συνεισφέρει στη σταθερότητα εκπαίδευσης σε περιβάλλοντα με αραιές ή εκτεταμένης κλίμακας ανταμοιβές.

Εκπαίδευση Actor-Critic

Τα δίκτυα actor και critic εκπαιδεύονται αποκλειστικά από φανταζόμενες τροχιές μήκους H βημάτων, οι οποίες παράγονται ξεκινώντας από την τρέχουσα posterior κατάσταση και αναπτύσσοντας το transition model *χωρίς* πρόσβαση στον πραγματικό αισθητήρα. Ο actor μεγιστοποιεί τη συνολική φανταζόμενη αξία:

$$V_\lambda(s_\tau) = \sum_{t=\tau}^{\tau+H} \gamma^{t-\tau}\, r_t + \gamma^H V(s_{\tau+H})$$

χρησιμοποιώντας συνδυασμό αλγορίθμου REINFORCE [35] και straight-through gradients για τις κατηγορικές στοχαστικές μεταβλητές. Ο critic εκπαιδεύεται μέσω two-hot + symlog regression ώστε να προβλέπει τιμές V_λ.

2.7 CarDreamer: Μοντέλα Κόσμου για Αυτόνομη Οδήγηση

Το CarDreamer [13] αποτελεί την πρώτη ανοικτού κώδικα πλατφόρμα ειδικά σχεδιασμένη για την ανάπτυξη και αξιολόγηση αλγορίθμων αυτόνομης οδήγησης βασισμένων σε

μοντέλα κόσμου. Η αρχιτεκτονική της αποτελείται από τρία κύρια συστατικά: *(i)* ένα εναλλάξιμο σκελετό μοντέλου κόσμου (world model backbone) που υποστηρίζει DreamerV2, DreamerV3 και Planning2Explore, *(ii)* ένα σύνολο παραμετροποιήσιμων ενσωματωμένων οδηγικών εργασιών (built-in tasks) εντός του CARLA, συμβατών με το Gymnasium [8], και *(iii)* μία σουίτα ανάπτυξης εργασιών (task development suite) με εργαλεία για route planning, διαχείριση κυκλοφορίας και πολυτροπικές παρατηρήσεις.

Ρυθμίσεις Παρατηρησιμότητας

Ένα ιδιαίτερο χαρακτηριστικό του CarDreamer είναι η υποστήριξη τριών επιπέδων παρατηρησιμότητας [13]:

- **Field-of-View (FOV):** Ο πράκτορας βλέπει μόνο τα οχήματα εντός του οπτικού του πεδίου.
- **Shared-FOV (SFOV):** Τα οχήματα μεταδίδουν αμοιβαία δεδομένα αισθητήρων μεταξύ τους.
- **Full Observability (FULL):** Πλήρης πρόσβαση σε πληροφορίες κυκλοφορίας και περιβάλλοντος.

Αυτές οι ρυθμίσεις αντιστοιχούν άμεσα στο POMDP πλαίσιο [20] που χρησιμοποιεί το RSSM για τη διαχείριση μερικής παρατηρησιμότητας.

Σχεδιασμός Συνάρτησης Ανταμοιβής

Μία σημαντική εμπειρική εύρεση του CarDreamer αφορά τη σχεδίαση της συνάρτησης ανταμοιβής: η ανταμοιβή βάσει ταχύτητας οδηγεί σε ανώτερη απόδοση σε σύγκριση με την ανταμοιβή βάσει απόλυτης θέσης. Όταν ο πράκτορας ανταμείβεται μόνο για θέση, συχνά συγκλίνει σε τοπικό βέλτιστο όπου παραμένει ακίνητος αποφεύγοντας συγκρούσεις, μια υπο-βέλτιστη πολιτική που εκμεταλλεύεται το σχήμα ανταμοιβής. Η ανταμοιβή βάσει ταχύτητας αποτρέπει αυτή τη συμπεριφορά. Επιπλέον, το CarDreamer καταδεικνύει ότι ο όρος εντροπίας στον actor-critic μπορεί να οδηγήσει σε ζιγκζαγκ τροχιές σε οδηγικά πλαίσια, καθώς η υψηλή εντροπία ανταμείβεται στον υπολογισμό αξίας ακόμα και αν παράγει μη-ομαλές τροχιές.

Βασικά Ευρήματα

Ένα από τα βασικά συμπεράσματα του CarDreamer είναι ότι η μορφή της παρατήρησης επηρεάζει σημαντικά την ασφάλεια των αυτόνομων οχημάτων. Οι σημασιολογικές αναπαραστάσεις τύπου birds-eye-view (BEV) υπερτερούν των ακατέργαστων RGB εικόνων στην ακολούθηση διαδρομής, ενώ η πρόσβαση σε ρητά σήματα πρόθεσης οχήματος, όπως τα προγραμματισμένα σημεία πορείας, βελτιώνει περαιτέρω την ασφάλεια και την αποδοτικότητα.

Τα ευρήματα αυτά επηρεάζουν άμεσα τις σχεδιαστικές επιλογές της παρούσας εργασίας, ιδιαίτερα όσον αφορά τη χρήση καμερών σημασιολογικής τμηματοποίησης [9] και την παροχή συντεταγμένων επόμενου waypoint ως μέρος του διανύσματος κατάστασης.

2.8 Ανίχνευση Ανωμαλιών στην Ενισχυτική Μάθηση με Μοντέλα Κόσμου

2.8.1 Ευρύτερο Πλαίσιο: Ανίχνευση Ανωμαλιών σε Αυτόνομη Οδήγηση

Η ανίχνευση ανωμαλιών (anomaly detection) και εκτός-κατανομής (Out-of-Distribution - OOD) καταστάσεων αποτελεί ένα ευρύ ερευνητικό πεδίο στην αυτόνομη οδήγηση. Οι Bogdoll κ.ά. (2022) [7] παρουσιάζουν μία ολοκληρωμένη επισκόπηση της έρευνας, διακρίνοντας δύο κύριες κατευθύνσεις: *(i)* μεθόδους βάσει ανακατασκευής (reconstruction-based), που χρησιμοποιούν αυτοκωδικοποιητές για να ανιχνεύσουν αποκλίσεις μεταξύ εισόδου και εξόδου, και *(ii)* μεθόδους βάσει κατανομής (distribution-based), που εκτιμούν την πιθανότητα μίας εισόδου υπό την μαθημένη κατανομή εκπαίδευσης. Οι Nitsch κ.ά. (2021) [27] εξετάζουν ειδικά το πρόβλημα OOD ανίχνευσης για αντιληπτικά συστήματα αυτόνομης οδήγησης, επισημαίνοντας ότι τα υπάρχοντα benchmarks OOD ανίχνευσης δεν αντιμετωπίζουν επαρκώς τις ιδιαίτερες προκλήσεις αντίληψης σε αστικό περιβάλλον. Οι Mosin κ.ά. (2022) [26] συγκρίνουν προσεγγίσεις αυτοκωδικοποιητή για ανίχνευση ανωμαλιών σε σενάρια οδήγησης αυτοκινητόδρομου, καταλήγοντας ότι η ποιότητα ανακατασκευής αποτελεί αξιόπιστο δείκτη ανωμαλίας όταν το μοντέλο έχει εκπαιδευτεί αποκλειστικά σε κανονικά δεδομένα.

Η παρούσα εργασία τοποθετείται σε τομή αυτών των δύο κατευθύνσεων: αξιοποιεί την εσωτερική πιθανοτική δομή του RSSM (distribution-based) ενώ παράλληλα χρησιμοποιεί την ανακατασκευή εικόνας (reconstruction-based) ως επικουρικό σήμα για τον CNN ταξινομητή.

2.8.2 Διατύπωση του Προβλήματος

Οι Zollicoffer κ.ά. (2025) [38] εξετάζουν το πρόβλημα της ανίχνευσης ανωμαλιών σε πράκτορες ενισχυτικής μάθησης που χρησιμοποιούν μοντέλα κόσμου. Ως ανωμαλία ορίζεται μία μόνιμη μεταβολή στον χώρο παρατηρήσεων ή στις δυναμικές μετάβασης καταστάσεων ενός περιβάλλοντος, η οποία εμφανίζεται κατά το στάδιο εξαγωγής συμπερασμάτων (inference), δεν είχε προβλεφθεί κατά την εκπαίδευση και, συνεπώς, καθιστά την πολιτική του πράκτορα αναξιόπιστη.

Οι ανωμαλίες διαφέρουν από τη συνήθη στοχαστική μεταβλητότητα, καθώς αντιπροσωπεύουν μία δομική μεταβολή του περιβάλλοντος που ακυρώνει το μαθημένο μοντέλο κόσμου του πράκτορα.

Οι συγγραφείς επισημαίνουν ότι το πρόβλημα αυτό είναι ιδιαίτερα κρίσιμο για πράκτορες RL, διότι, σε αντίθεση με την επιβλεπόμενη μάθηση, τα δεδομένα εκπαίδευσης στην RL δεν είναι ανεξάρτητα και ομοιόμορφα κατανεμημένα (non-i.i.d.), ενώ η μαθημένη πολιτική είναι ιδιαίτερα ευαίσθητη σε μεταβολές κατανομής του περιβάλλοντος [7, 27]. Ακόμη και μία μικρή αλλαγή στις δυναμικές μετάβασης μπορεί να οδηγήσει μία συγκλίνουσα πολιτική σε καταστροφική αποτυχία.

2.8.3 Προσέγγιση Οριοθέτησης μέσω Απόκλισης KL

Η βασική συνεισφορά των Zollicoffer κ.ά. [38] είναι μία προσέγγιση οριοθέτησης που χρησιμοποιεί την ασυμφωνία μεταξύ της προβλεπόμενης («φανταζόμενης») επόμενης κατάστασης του μοντέλου κόσμου και της πραγματικής παρατηρούμενης κατάστασης ως δείκτη ανωμαλίας. Η βασική διαίσθηση είναι ότι, κατά την κανονική λειτουργία, το transition model (prior) και το representation model (posterior) του μοντέλου κόσμου θα πρέπει να συμφωνούν στενά. Όταν εμφανίζεται μία ανωμαλία, οι δυναμικές μετάβασης του περιβάλλοντος μεταβάλλονται και οι prior και posterior κατανομές αρχίζουν να αποκλίνουν.

Η μέθοδος υπολογίζει τρεις όρους απόκλισης KL. Έστω ότι η κατανομή

$$q(z_t \mid h_t,\, x_t)$$

αντιστοιχεί στην posterior κατανομή της στοχαστικής κατάστασης δεδομένου του τρέχοντος ιστορικού h_t και της παρατήρησης x_t, η κατανομή

$$p_\phi(z_t \mid h_t)$$

αντιστοιχεί στην prior κατανομή του transition model δεδομένου μόνο του ιστορικού, και h_0 συμβολίζει μία κενή αρχική κρυφή κατάσταση που προσομοιώνει την πλήρη απουσία ιστορικού. Ορίζονται οι ακόλουθες ποσότητες:

- **Σκορ ανωμαλίας** (novelty score):

$$KL_A \;=\; \mathrm{KL}\Big[q(z_t \mid h_t, x_t) \;\Big\|\; p_\phi(z_t \mid h_t)\Big]$$

  Η απόκλιση KL μεταξύ posterior και prior υπό το τρέχον ιστορικό. Πρόκειται για τον τυπικό όρο KL του μοντέλου κόσμου, ο οποίος μετρά το πληροφοριακό περιεχόμενο της τρέχουσας παρατήρησης σε σχέση με την πρόβλεψη του μοντέλου.

- **Prior χωρίς ιστορικό**:

$$KL_B \;=\; \mathrm{KL}\Big[q(z_t \mid h_t, x_t) \;\Big\|\; p_\phi(z_t \mid h_0)\Big]$$

Η απόκλιση KL μεταξύ της πλήρους posterior (με πραγματικό ιστορικό και παρατήρηση) και του prior του transition model με κενό ιστορικό h_0. Η ποσότητα αυτή εκφράζει πόσο η πλήρης posterior αποκλίνει από ό,τι το μοντέλο θα προέβλεπε χωρίς καμία πληροφορία ιστορικού.

- **Representation model χωρίς ιστορικό**:

$$KL_C \;=\; \mathrm{KL}\Big[q(z_t \mid h_t, x_t) \;\Big\|\; p_\phi(z_t \mid h_0, x_t)\Big]$$

Η απόκλιση KL μεταξύ της πλήρους posterior και της εξόδου του **representation model** (posterior network) όταν τροφοδοτείται με κενό ιστορικό h_0 αλλά με την πραγματική παρατήρηση x_t. Η ποσότητα αυτή μετρά αποκλειστικά τη συνεισφορά του ιστορικού h_t στην posterior κατανομή, απομονώνοντάς την από τη συνεισφορά της παρατήρησης.

Σημειώνεται ότι και στους τρεις όρους η **βασική κατανομή (αριστερά)** είναι πάντοτε η πλήρης posterior $q(z_t \mid h_t, x_t)$· μόνο η κατανομή αναφοράς (δεξιά) διαφέρει ανά όρο. Επίσης, ενώ στο KL_B χρησιμοποιείται το transition model $p_\phi(\cdot \mid h_0)$, στο KL_C χρησιμοποιείται το representation model $p_\phi(\cdot \mid h_0, x_t)$, δηλαδή το ίδιο δίκτυο posterior που παράγει και το $q(z_t \mid h_t, x_t)$, αλλά με κενό ιστορικό αντί του πραγματικού.

Το κατώφλι ανωμαλίας ορίζεται ως:

$$\text{threshold} \;=\; KL_B - KL_C$$

Μία κατάσταση ταξινομείται ως ανωμαλία όταν ικανοποιείται τουλάχιστον μία από τις ακόλουθες συνθήκες (Propositions 3.1 και 3.2 στο [38]):

$$\text{threshold} < 0 \qquad \text{ή} \qquad KL_A > \text{threshold}$$

Η πρώτη συνθήκη (threshold < 0) ενεργοποιείται όταν η σύγκριση διασταυρούμενης ή εγκάρσιας εντροπίας (cross entropy) γίνεται αρνητική: καθώς το KL_A είναι εξ ορισμού μη-αρνητικό, η ανισότητα $KL_A >$ threshold ικανοποιείται αυτομάτως, οπότε η παρατήρηση σηματοδοτείται ως ανωμαλία. Η δεύτερη συνθήκη ($KL_A >$ threshold) ορίζει ένα όριο απόφασης στον λανθάνοντα χώρο: το μοντέλο είναι πιο «έκπληκτο» από την τρέχουσα παρατήρηση σε σχέση με ό,τι θα δικαιολογούσε το μαθημένο ιστορικό του.

Η βασική διαίσθηση πίσω από τη μέθοδο είναι ότι, εάν η τρέχουσα παρατήρηση εμφανίζεται περισσότερο απρόβλεπτη σε σχέση με το τρέχον ιστορικό απ' ό,τι θα εμφανιζόταν χωρίς ιστορικό, τότε το ιστορικό παρέχει παραπλανητικό πλαίσιο πληροφορίας. Αυτό αποτελεί χαρακτηριστικό γνώρισμα μίας ανωμαλίας που έχει καταστήσει το μοντέλο κόσμου μη έγκυρο για την τρέχουσα κατάσταση του περιβάλλοντος.

2.9 Συνελικτικό Νευρωνικό Δίκτυο Δυαδικής Ταξινόμησης

2.9.1 Επισκόπηση Συνελικτικών Νευρωνικών Δικτύων

Τα Συνελικτικά Νευρωνικά Δίκτυα (Convolutional Neural Networks - CNN) [24] αποτελούν μία κατηγορία νευρωνικών δικτύων βαθιάς μάθησης ειδικά σχεδιασμένη για επεξεργασία δεδομένων πλεγματικής τοπολογίας, όπως εικόνες. Η αρχιτεκτονική τους εκμεταλλεύεται δύο βασικές ιδιότητες των δεδομένων εικόνας: την **τοπική συνεκτικότητα** (local connectivity), δηλαδή ότι χαρακτηριστικά σε μία εικόνα εξαρτώνται κυρίως από τις γειτονικές τους περιοχές, και τη **μεταφορική αναλλοιότητα** (translational invariance), δηλαδή ότι ένα μοτίβο αναγνωρίζεται ανεξάρτητα από τη θέση του στην εικόνα.

Τα CNNs εισήχθησαν στην τρέχουσα μορφή τους από τους LeCun κ.ά. [24] και απέκτησαν κυρίαρχη θέση στη μηχανική όραση μετά τη δουλειά των He κ.ά. (2016) [18] για τα υπολειμματικά δίκτυα (residual networks). Στην παρούσα εργασία, ένα CNN εκπαιδεύεται ως δυαδικός ταξινομητής ανίχνευσης ανωμαλιών, λαμβάνοντας ως είσοδο ζεύγη σημασιολογικά τμηματοποιημένων εικόνων (πραγματική παρατήρηση και φανταζόμενη πρόβλεψη του DreamerV3) και εξάγοντας μία πιθανότητα ανωμαλίας.

2.9.2 Δομικά Στοιχεία Αρχιτεκτονικής

Συνελικτικά Στρώματα

Το βασικό δομικό στοιχείο ενός CNN είναι το **συνελικτικό στρώμα** (convolutional layer), στο οποίο εφαρμόζεται μία σειρά από εκπαιδεύσιμους πυρήνες (learned kernels) $\mathbf{W} \in \mathbb{R}^{k \times k \times C_{\text{in}}}$ πάνω στον χάρτη χαρακτηριστικών εισόδου μέσω διακριτής συνέλιξης:

$$y_{i,j,c} = \sum_{m=0}^{k-1} \sum_{n=0}^{k-1} \sum_{c'=0}^{C_{\text{in}}-1} W_{m,n,c',c} \cdot x_{i+m,\, j+n,\, c'} + b_c$$

όπου $y_{i,j,c}$ είναι η τιμή εξόδου στην τοποθεσία (i, j) του c-οστού χάρτη χαρακτηριστικών, k είναι το μέγεθος πυρήνα (kernel size), C_{in} ο αριθμός καναλιών εισόδου και b_c μία μεροληπτική παράμετρος. Οι εκπαιδεύσιμοι πυρήνες ανιχνεύουν ιεραρχικά χαρακτηριστικά: τα πρώτα στρώματα ανιχνεύουν ακμές και υφές, ενώ τα βαθύτερα ανιχνεύουν σύνθετες σημασιολογικές δομές.

Ομαλοποίηση Δεσμίδας και Ενεργοποίηση

Μετά από κάθε συνελικτικό στρώμα, εφαρμόζεται **ομαλοποίηση δεσμίδας** (Batch Normalization - BN) [19], η οποία κανονικοποιεί τις εξόδους ανά δεσμίδα εκπαίδευσης ώστε

να έχουν μηδενική μέση τιμή και μοναδιαία διακύμανση:

$$\hat{x}^{(i)} = \frac{x^{(i)} - \mu_B}{\sqrt{\sigma_B^2 + \epsilon}}, \qquad y^{(i)} = \gamma \hat{x}^{(i)} + \beta$$

Η BN επιταχύνει την εκπαίδευση, μειώνει την εξάρτηση από τη ρύθμιση του ρυθμού μάθησης και δρα ως κανονικοποιητής που αντιστοιχεί σε μείωση του overfitting. Ακολουθεί η συνάρτηση ενεργοποίησης **ReLU** (Rectified Linear Unit): $\sigma(x) = \max(0, x)$, η οποία εισάγει μη-γραμμικότητα στο δίκτυο.

Στρώματα Συγκέντρωσης

Τα **στρώματα συγκέντρωσης** (pooling layers) μειώνουν τη χωρική ανάλυση των χαρτών χαρακτηριστικών, παρέχοντας τοπική μεταφορική αναλλοιότητα και μειώνοντας τον αριθμό παραμέτρων. Η πιο συνηθισμένη μορφή είναι η max-pooling, η οποία επιλέγει τη μέγιστη τιμή σε κάθε παράθυρο:

$$y_{i,j} = \max_{0 \le m,n < k} x_{i \cdot s+m,\, j \cdot s+n}$$

όπου s είναι το βήμα (stride) της συγκέντρωσης.

2.9.3 Δυαδική Ταξινόμηση και Συνάρτηση Απώλειας

Για τη δυαδική ταξινόμηση (normal vs. anomaly), το τελικό στρώμα του δικτύου αποτελείται από ένα πλήρως συνδεδεμένο (fully connected) στρώμα που εξάγει ένα μοναδικό logit, ακολουθούμενο από **σιγμοειδή ενεργοποίηση** (sigmoid):

$$\hat{y} = \sigma(z) = \frac{1}{1 + e^{-z}} \in (0, 1)$$

Η έξοδος $\hat{y}$ ερμηνεύεται ως η εκτιμώμενη πιθανότητα $P(\text{anomaly} \mid \mathbf{x})$.

Η εκπαίδευση πραγματοποιείται μέσω ελαχιστοποίησης της **Δυαδικής Διασταυρούμενης Εντροπίας** (Binary Cross-Entropy - BCE):

$$\mathcal{L}_{\text{BCE}} = -\frac{1}{N} \sum_{i=1}^{N} [y_i \log \hat{y}_i + (1 - y_i) \log(1 - \hat{y}_i)]$$

όπου $y_i \in \{0, 1\}$ είναι η πραγματική ετικέτα (0 για κανονικό δείγμα, 1 για ανώμαλο δείγμα) και $\hat{y}_i$ είναι η προβλεπόμενη πιθανότητα του δικτύου. Η BCE επιβάλλει μεγάλη ποινή σε προβλέψεις που αποδίδουν υψηλή πιθανότητα στη λανθασμένη κλάση, ενθαρρύνοντας έτσι πιθανοτικές εξόδους που αντανακλούν καλύτερα τη βεβαιότητα του μοντέλου.

3

Αρχιτεκτονική Συστήματος και Υλοποίηση

Το παρόν κεφάλαιο περιγράφει την πλήρη τεχνική υλοποίηση του συστήματος της παρούσας εργασίας, από τον σχεδιασμό του περιβάλλοντος CARLA έως τον βρόχο αξιολόγησης σε πραγματικό χρόνο. Το σύστημα υλοποιείται σε Python 3.8, χρησιμοποιώντας το framework SheepRL για το DreamerV3, το TensorFlow/Keras για τον δυαδικό ταξινομητή CNN και το Python API του προσομοιωτή CARLA 0.9.15 για την αλληλεπίδραση με το περιβάλλον.

3.1 Περιβάλλον CARLA συμβατό με Gymnasium

3.1.1 Φιλοσοφία Σχεδιασμού Περιβάλλοντος

Το περιβάλλον υλοποιείται ως κλάση συμβατή με το πρότυπο Gymnasium [12], η οποία κληρονομεί τόσο από το gym.Env όσο και από μία αφηρημένη βασική κλάση CarEnv. Ο σχεδιασμός αυτός ακολουθεί την αρχή του CarDreamer, σύμφωνα με την οποία η χρήση της τυποποιημένης διεπαφής Gymnasium αποσυνδέει το μοντέλο κόσμου από την εκάστοτε οδηγική εργασία, επιτρέποντας άμεση ενσωμάτωση με την υλοποίηση DreamerV3 του SheepRL.

Το περιβάλλον CARLA εκτελείται σε συγχρονισμένη λειτουργία με σταθερό χρονικό βήμα 0.1 δευτερολέπτων (10 Hz), εξασφαλίζοντας ντετερμινιστική εξέλιξη των επεισοδίων. Η προσομοίωση πραγματοποιείται σε αστικό περιβάλλον με σαφείς σημάνσεις λωρίδων, δια-

σταυρώσεις και περιοχές πεζών (ενδεικτικά Town01 στις πρώτες δύο προσομοιώσεις). Το όχημα-πράκτορας είναι ένα όχημα τύπου Tesla Model 3 που ελέγχεται από τον αλγόριθμο DreamerV3 μέσω της συνάρτησης apply_control, η οποία δέχεται ένα αντικείμενο τύπου carla.VehicleControl με παραμέτρους (throttle, steer, brake) που ελέγχουν την επιτάχυνση, την κατεύθυνση του τιμονιού και την πέδηση αντίστοιχα· τα παραπάνω είναι παρεχόμενα από τον ίδιο τον προσομοιωτή.

3.1.2 Χώρος Παρατηρήσεων

Ο χώρος παρατηρήσεων ορίζεται ως ένα λεξικό τύπου Gymnasium Dict με δύο συνιστώσες, σύμφωνα με την αρχιτεκτονική πολυτροπικής κωδικοποίησης του DreamerV3:

- **semantic_camera**: ένας πίνακας διαστάσεων $128 \times 128 \times 3$ τύπου uint8, ο οποίος περιέχει την έξοδο σημασιολογικής τμηματοποίησης με κωδικοποίηση παλέτας CityScapes. Η κάμερα είναι τοποθετημένη σε ύψος οροφής ($z = 1.6\,m$) με κλίση 30 μοιρών προς τα εμπρός και οριζόντιο οπτικό πεδίο 120 μοιρών. Η χρήση σημασιολογικής τμηματοποίησης αντί ακατέργαστων RGB εικόνων επιλέγεται διότι παρέχει μία συμπαγή, επισημασμένη κατά κλάση αναπαράσταση του περιβάλλοντος, η οποία είναι κατάλληλη για τον εντοπισμό αποκλίσεων μεταξύ πραγματικών παρατηρήσεων και φανταζόμενων προβλέψεων του μοντέλου κόσμου και είναι φυσικά ανθεκτική σε καιρικές συνθήκες και αντανακλάσεις.

- **state**: ένα διάνυσμα δώδεκα διαστάσεων τύπου float32, εκφρασμένο στο σύστημα συντεταγμένων του οχήματος (vehicle frame). Οι δέκα πρώτες διαστάσεις κωδικοποιούν τα πέντε επόμενα σημεία πορείας (waypoints), καθένα ως ζεύγος (διαμήκης απόσταση, εγκάρσια απόσταση) ως προς τον τρέχοντα προσανατολισμό του οχήματος· η ενδέκατη διάσταση είναι η βαθμωτή ταχύτητα και η δωδέκατη η γωνιακή απόκλιση (σε μοίρες) από το αμέσως επόμενο waypoint. Η χρήση σχετικών (vehicle-frame) αντί απόλυτων συντεταγμένων ενισχύει τη γενίκευση της πολιτικής, καθώς η αναπαράσταση παραμένει αμετάβλητη ως προς την απόλυτη θέση και τον προσανατολισμό του οχήματος στον χάρτη.

3.1.3 Χώρος Ενεργειών

Ο χώρος ενεργειών είναι διακριτός και αποτελείται από 15 ενέργειες, οι οποίες προκύπτουν από το καρτεσιανό γινόμενο 3 τιμών επιτάχυνσης ([-2.0, 0.0, 2.0] $\mathrm{m/s^2}$) και 5 τιμών διεύθυνσης τιμονιού ([-0.6, -0.2, 0.0, 0.2, 0.6]). Η διακριτοποίηση αυτή ακολουθεί την προσέγγιση του CarDreamer και επιτρέπει τη χρήση κατηγορικής πολιτικής στο DreamerV3.

Η αποκωδικοποίηση της διακριτής ενέργειας σε εντολή ελέγχου είναι άμεση: οι θετικές τιμές επιτάχυνσης αντιστοιχίζονται σε επιτάχυνση (throttle) και οι αρνητικές σε πέδηση

(brake), αμφότερες κανονικοποιημένες στο διάστημα $[0, 1]$, ενώ η αντίστοιχη τιμή διεύθυνσης εφαρμόζεται στο τιμόνι.

3.1.4 Διαχείριση Διαδρομής και Waypoints

Το όχημα ακολουθεί μία διαδρομή βασισμένη σε σημεία πορείας (waypoints) σε δύο σενάρια, το πρώτο σενάριο θέτει μία προκαθορισμένη διαδρομή από σημείο εκκίνησης με συντεταγμένες (87.69, 145.67) έως προορισμό στις (162.25, 330.60) και το δεύτερο σενάριο επιλέγει τυχαία σημεία εκκίνησης και προορισμού μέσω μίας συνάρτησης τυχαίας επιλογής από το σύνολο των διαθέσιμων σημείων θέσης (spawn points) και της συνάρτησης waypoint.next με τιμή 250 για το σημείο προορισμού, όπου δυναμικά υπολογίζονται οι συντεταγμένες προορισμού σε απόσταση 250 μέτρων. Ο υπολογισμός της διαδρομής γίνεται μέσω του CARLA GlobalRoutePlanner, με τροποποιημένη έκδοση της κλάσης BasicAgent του προσομοιωτή, η οποία έχει προσαρμοστεί ώστε να επιστρέφει ακολουθία σημείων πορείας (waypoints) αντί για υψηλού επιπέδου εντολές πλοήγησης.

Η τροποποίηση αυτή παρέχει την απαραίτητη πυκνή ακολουθία σημείων για τον υπολογισμό της συνάρτησης ανταμοιβής και της παρατήρησης κατάστασης. Τα σημεία διατηρούνται ως λίστα, η οποία καταναλώνεται καθώς το όχημα προχωρά στη διαδρομή. Το σύστημα παρακολουθεί τόσο το προηγούμενο όσο και το επόμενο σημείο, ώστε να υπολογίζει την πρόοδο και την αντίστοιχη ανταμοιβή.

Κατά την αξιολόγηση, ένα στατικό εμπόδιο τοποθετείται σε τυχαίο σημείο της διαδρομής, δημιουργώντας συνθήκες ανωμαλίας που χρησιμοποιούνται για την αξιολόγηση των συστημάτων ανίχνευσης. Η τοποθέτηση υπόκειται σε δύο περιορισμούς πρωτοκόλλου. Πρώτον, το σημείο επιλέγεται σε *ευθεία προσέγγιση*: η μεταβολή της κατεύθυνσης της διαδρομής στα 15 προηγούμενα waypoints δεν επιτρέπεται να υπερβαίνει τις 15° (με πεπερασμένο αριθμό προσπαθειών πριν ο περιορισμός εγκαταλειφθεί για το επεισόδιο), ώστε το εμπόδιο να εισέρχεται στο οπτικό πεδίο του οχήματος πριν αυτό το προσεγγίσει· εμπόδια αμέσως μετά από στροφή θα ήταν εκ κατασκευής μη αποφεύξιμα από οποιονδήποτε ανιχνευτή. Δεύτερον, στη ρύθμιση τυχαίων εμποδίων το σύνολο επιλογής περιορίζεται σε blueprints οχημάτων και στατικών αντικειμένων (`vehicle.*`, `static.*.*`)· οι πεζοί εξαιρούνται, διότι ο προσομοιωτής δεν καταγράφει γεγονός σύγκρουσης όταν το όχημα-πράκτορας ωθεί έναν πεζό, οπότε τα αντίστοιχα επεισόδια δεν θα μπορούσαν ποτέ να καταλήξουν σε σύγκρουση.

3.1.5 Συνάρτηση Ανταμοιβής

Η συνάρτηση ανταμοιβής αποτελείται από τους παρακάτω επιμέρους όρους, οι οποίοι στοχεύουν στην ενθάρρυνση ασφαλούς, αποδοτικής και προσανατολισμένης στη διαδρομή οδήγησης:

- **Ανταμοιβή waypoint**: αποδίδεται κάθε φορά που το όχημα φτάνει σε ένα σημείο

διαδρομής (waypoint) με επιτυχία. Επίσης εφαρμόζεται ποινή εάν η απόκλιση από το επόμενο σημείο υπερβεί ένα προκαθορισμένο όριο, αυτή η τεχνική προσομοιώνει την περίπτωση που το όχημα προσπεράσει το επόμενο σημείο διαδρομής και βγει εκτός πορείας, στην περίπτωση αυτή τερματίζεται το επεισόδιο.

- **Ανταμοιβή ταχύτητας**: αναλογική της συνιστώσας ταχύτητας προς τη διεύθυνση του επόμενου σημείου, με ποινή για πλευρική ολίσθηση και απόκλιση από επιθυμητή ταχύτητα.
- **Ποινή σύγκρουσης**: υψηλού επιπέδου αρνητική τιμή σε περίπτωση σύγκρουσης, όπου τερματίζεται και το επεισόδιο.
- **Ποινή εισβολής λωρίδας**: ποινή για παραβίαση συνεχούς γραμμής ή έξοδο από το οδόστρωμα, κλιμακούμενη με την πλευρική απόκλιση. Οι διακεκομμένες γραμμές δεν τιμωρούνται.
- **Ανταμοιβή προορισμού**: τερματική ανταμοιβή για επιτυχή ολοκλήρωση της διαδρομής.
- **Ποινή χρόνου**: η οποία αποθαρρύνει την αργή ή αναποτελεσματική οδήγηση.

3.1.6 Τερματισμός Επεισοδίων

Τα επεισόδια τερματίζονται υπό τις εξής συνθήκες:

- σύγκρουση,
- παραβίαση συνεχούς λωρίδας ή έξοδο από το οδόστρωμα,
- απόκλιση από σημείο διαδρομής,
- χρονικό τέλος επεισοδίου,
- ολοκλήρωση διαδρομής / επίτευξη στόχου.

3.2 Εκπαίδευση DreamerV3 με SheepRL

3.2.1 Πλαίσιο SheepRL

Η υλοποίηση του DreamerV3 βασίζεται στο **SheepRL** framework [6], ένα modular PyTorch-Lightning framework για κατανεμημένη εκπαίδευση αλγορίθμων RL βασισμένων σε μοντέλα κόσμου. Το SheepRL παρέχει ολοκληρωμένες υλοποιήσεις DreamerV2, DreamerV3 [16] και διαφόρων άλλων αλγορίθμων, με υποστήριξη πολλαπλών GPU μέσω PyTorch Lightning Fabric και Hydra-based παραμετροποίηση υπερπαραμέτρων.

3.2.2 Παραμετροποίηση Υπερπαραμέτρων

Ο Πίνακας 3.1 συνοψίζει τις βασικές υπερπαραμέτρους που χρησιμοποιήθηκαν στην παρούσα εργασία.

Πίνακας 3.1: *Υπερπαράμετροι εκπαίδευσης DreamerV3*

Υπερπαράμετρος	**Τιμή**
Ολικά χρονικά βήματα	5×10^6
Replay ratio	1
Μέγεθος δεσμίδας (per rank)	16
Μήκος ακολουθίας (per rank)	64
Μέγεθος buffer αναπαραγωγής	100,000
CNN κλειδιά (encoder/decoder)	`semantic_camera`
MLP κλειδιά (encoder/decoder)	`state`

Η παραμετροποίηση συνδυάζει τον CNN κωδικοποιητή για τη σημασιολογική εικόνα διαστάσεων $128 \times 128 \times 3$ με έναν MLP κωδικοποιητή για το 12-διάστατο διάνυσμα κατάστασης. Ο CNN κωδικοποιητής του DreamerV3 αποτελείται από 4 στρώματα Conv2d με πυρήνα 4×4, stride 2 και padding 1, ακολουθούμενα από LayerNorm και SiLU ενεργοποίηση.

3.2.3 Σενάρια Εκπαίδευσης

Ο DreamerV3 εκπαιδεύεται σε τρία διαφορετικά σενάρια, προχωρώντας από απλό σε πολύπλοκο, για την επαλήθευση της ικανότητας γενίκευσης:

1. **Στατική διαδρομή, στατικό περιβάλλον**: Σταθερό σημείο εκκίνησης και προκαθορισμένη διαδρομή. Ιδανικό για την εξακρίβωση σύγκλισης της βασικής πολιτικής.

2. **Τυχαία διαδρομή, στατικό περιβάλλον**: Τυχαία επιλογή σημείου εκκίνησης και προορισμού σε κάθε επεισόδιο. Ενθαρρύνει την εκμάθηση μίας πιο γενικευμένης πολιτικής ακολουθίας σημείων.

3. **Τυχαία διαδρομή, τυχαίο περιβάλλον**: Εκπαίδευση του αλγορίθμου σε σειρά τυχαίων πόλεων ανά επεισόδιο. Δοκιμάζει τη γενίκευση σε πολυπλοκότερα σενάρια και διαφορετικές συνθήκες κόσμου.

Η εκπαίδευση κάθε σεναρίου ξεκινά εκ νέου (χωρίς μεταφορά βαρών), ώστε να διατηρείται πειραματική καθαρότητα.

3.3 Δημιουργία Συνόλου Δεδομένων Ανωμαλιών

3.3.1 Στρατηγική Συλλογής

Το σύνολο δεδομένων για τον CNN ταξινομητή συλλέγεται κατά τη φάση αξιολόγησης (evaluation) του παγωμένου πράκτορα DreamerV3, εκτελώντας 100 επεισόδια στη ρύθμιση *τυχαίων* εμποδίων, η οποία περιλαμβάνει ως ειδική περίπτωση και το μοναδικό όχημα-εμπόδιο· εκπαιδεύεται έτσι *ένας* ταξινομητής, ο οποίος χρησιμοποιείται αμετάβλητος και στις δύο ρυθμίσεις αξιολόγησης. Κάθε χρονικό βήμα κάθε επεισοδίου παράγει ένα ζεύγος εικόνων:

- **Παρατήρηση** o_t: η σημασιολογικά τμηματοποιημένη εικόνα $128 \times 128 \times 3$ που παρέχεται από τον αισθητήρα CARLA.
- **Φαντασία** $\hat{o}_t$: η ανακατασκευή του αποκωδικοποιητή του DreamerV3, παραγόμενη από την πλήρη λανθάνουσα κατάσταση (h_t, z_t) του RSSM. Επειδή ο πράκτορας DreamerV3 έχει εκπαιδευτεί αποκλειστικά σε διαδρομές χωρίς εμπόδια και η ανίχνευση εκτελείται με το μοντέλο «παγωμένο» σε λειτουργία αξιολόγησης (όπου τα εμπόδια εισάγονται για πρώτη φορά), ο αποκωδικοποιητής αναπαράγει τον κόσμο όπως τον έμαθε, δηλαδή χωρίς το εμπόδιο. Η αναμενόμενη («φανταζόμενη») σκηνή είναι έτσι, εκ κατασκευής, απαλλαγμένη εμποδίων, ανεξάρτητα από το ότι η posterior κατάσταση z_t έχει κωδικοποιήσει την τρέχουσα παρατήρηση.

3.3.2 Διαχωρισμός Κανονικών και Ανώμαλων Βημάτων

Κατα την διάρκεια της αξιολόγησης, ένα στατικό εμπόδιο τοποθετείται σε τυχαίο σημείο της διαδρομής (μεταξύ ενός ορίου 10 σημείων μετά την εκκίνηση και πριν τον προορισμό), δημιουργώντας ένα εμπόδιο που εμφανίζεται τυχαία στο οπτικό πεδίο του πράκτορα κατά την προσέγγιση.

Είναι σημαντικό να τονιστεί ότι ένα επεισόδιο *δεν* είναι ανώμαλο σε όλη του τη διάρκεια. Το επεισόδιο ξεκινά υπό κανονικές συνθήκες και το εμπόδιο εισέρχεται στο οπτικό πεδίο του οχήματος μόνο κατά την προσέγγισή του, δηλαδή αφού το όχημα έχει ήδη διανύσει μέρος της διαδρομής. Για τον λόγο αυτό, η απόδοση της αληθούς ετικέτας γίνεται *ανά χρονικό βήμα* (per-timestep): ορίζεται $y_t = 1$ μόνο για τα βήματα στα οποία το εμπόδιο είναι πράγματι παρόν στη σκηνή (μετά την εμφάνισή του) και $y_t = 0$ για όλα τα προηγούμενα βήματα του ίδιου επεισοδίου, στα οποία η σκηνή είναι ουσιαστικά κανονική.

Συνέπεια αυτού είναι ότι μόνο ένα κλάσμα των καρέ κάθε επεισοδίου φέρει την ετικέτα 1, και επομένως το τελικό σύνολο δεδομένων είναι εγγενώς *μη ισορροπημένο*, με τα κανονικά καρέ να υπερτερούν αριθμητικά. Στη συλλογή των 100 επεισοδίων, τα ανώμαλα καρέ αντιστοιχούν συνολικά σε περίπου 16% των 17,756 ζευγών (αναλυτικά ανά υποσύνολο στην Ενότητα 3.5.3), ενώ στις έξι συνθήκες της συγκριτικής αξιολόγησης το ποσοστό ανωμαλιών κυμαίνεται από 2.7% έως 25.2% (πλήρη στοιχεία στον Πίνακα 4.3 του Κεφαλαίου 4).

Η ανισορροπία αυτή είναι ο λόγος για τον οποίο η αξιολόγηση δεν στηρίζεται μόνο στην ολική ακρίβεια (accuracy) αλλά και σε μετρικές ανθεκτικές σε ανισορροπία κλάσεων, όπως η ισορροπημένη ακρίβεια και ο συντελεστής MCC.

Η αληθής ετικέτα παράγεται από τον μορφολογικό τελεστή της εκάστοτε ρύθμισης εμποδίων (Παράρτημα Α′.5): στη ρύθμιση μοναδικού εμποδίου ο τελεστής είναι δεσμευμένος στην κλάση (*car*), ενώ στη ρύθμιση τυχαίων εμποδίων είναι ανεξάρτητος κλάσης και εντοπίζει οποιοδήποτε μη ανακατασκευασμένο αντικείμενο εντός του διαδρόμου κίνησης. Η ρύθμιση επιλέγεται από έναν ενιαίο διακόπτη παραμετροποίησης, κοινό για το περιβάλλον και τον βρόχο αξιολόγησης, ώστε τα εμπόδια που εισάγονται και οι ετικέτες που παράγονται να αναφέρονται πάντοτε στην ίδια ρύθμιση.

3.3.3 Προεπεξεργασία Εικόνων

Πριν από την αποθήκευση και εκπαίδευση, κάθε εικόνα υφίσταται προεπεξεργασία δύο σταδίων:

1. **Χρωματική αντιστοίχιση σε δείκτη κλάσης**: Η σημασιολογική εικόνα μετατρέπεται σε πίνακα δεικτών κλάσεων χρησιμοποιώντας το λεξικό `CITYSCAPES_PALETTE` που χαρτογραφεί χρώματα RGB σε ακέραιες ετικέτες κλάσεων (1-19 αντιστοιχούν σε: οδόστρωμα, πεζοδρόμιο, κτήριο, τοίχος, φράχτης, κολώνα, φανάρια, σήμανση, βλάστηση, έδαφος, ουρανός, πεζός, αναβάτης, αυτοκίνητο, φορτηγό, λεωφορείο, τρένο, μοτοσυκλέτα, ποδήλατο). Σημειώνεται ότι, ενώ ο αισθητήρας του CARLA παράγει εικόνα ανάλυσης 128×128, το DreamerV3 την υποδειγματοληπτεί εσωτερικά σε 64×64 για τον κωδικοποιητή και τον αποκωδικοποιητή του· τόσο η πραγματική παρατήρηση όσο και η ανακατασκευή που συγκρίνονται εδώ έχουν επομένως ανάλυση 64×64.

2. **Αποκοπή περιοχής ενδιαφέροντος (ROI)**: Από τον πίνακα δεικτών 64×64 αποκόπτεται ένα σταθερό παράθυρο 24×24 εστιασμένο στο οδόστρωμα και στην πορεία του οχήματος, ώστε να διατηρηθεί το πληροφοριακά πλούσιο τμήμα της σκηνής και να ελαχιστοποιηθεί ο υπολογιστικός φόρτος του ταξινομητή.

Στην είσοδο του ταξινομητή, τα δύο κανάλια (παρατήρηση και φαντασία) συνενώνονται κατά τον άξονα του βάθους: $\mathbf{x}_t = [o_t \,\|\, \hat{o}_t] \in \mathbb{R}^{24\times24\times2}$.

3.4 Υλοποίηση Ανίχνευσης Ανωμαλιών βάσει KL

3.4.1 Ενσωμάτωση στον Κώδικα DreamerV3

Η μέθοδος ανίχνευσης ανωμαλιών υλοποιείται εντός της μεθόδου `get_states()` της κλάσης `PlayerDV3` στον κώδικα του πράκτορα DreamerV3, η οποία καλείται σε κάθε χρονικό

βήμα της αξιολόγησης. Η κλάση αυτή διαχειρίζεται τον πράκτορα DreamerV3 σε λειτουργία inference, με πρόσβαση σε όλα τα υπομοντέλα του RSSM.

Η μέθοδος δέχεται ως εισόδους: την ενέργεια του τρέχοντος βήματος (`action`), τον αριθμό βήματος πολιτικής (`policy_step`) και την τρέχουσα παρατήρηση (`obs`).

3.4.2 Δίοδος Πλήρους Ιστορικού

Η ανίχνευση ανωμαλίας εκτελείται *μετά* την κλήση της μεθόδου `get_actions()`, η οποία ευθύνεται για την πλήρη ενημέρωση της αναδρομικής κατάστασης. Συγκεκριμένα, η `get_actions()` εκτελεί τα εξής βήματα σε κάθε χρονικό βήμα t:

1. Κωδικοποίηση της τρέχουσας παρατήρησης: $e_t = \text{encoder}(o_t)$.
2. Ενημέρωση της ντετερμινιστικής αναδρομικής κατάστασης μέσω του GRU:

$$h_t \;=\; \text{GRU}(\text{cat}(z_{t-1},\, a_{t-1}),\; h_{t-1})$$

   αποθηκεύοντάς την στο `self.recurrent_state`.
3. Υπολογισμός της posterior κατανομής μέσω του representation model:

$$(\texttt{stochastic_state_logits},\; z_t) \;=\; \text{representation}(h_t,\, e_t)$$

   αποθηκεύοντάς τα στα `self.stochastic_state_logits` και `self.stochastic_state` αντίστοιχα.
4. Σχηματισμός της πλήρους λανθάνουσας κατάστασης: $s_t = \text{cat}(z_t,\, h_t)$, η οποία χρησιμοποιείται για την επιλογή ενέργειας μέσω του actor.

Κατά συνέπεια, όταν καλείται η `get_states()`, οι τιμές `self.recurrent_state` και `self.stochastic_state_logits` αντικατοπτρίζουν ήδη την πλήρως ενημερωμένη κατάσταση h_t και τα posterior logits $q_\phi(z_t \mid h_t, x_t)$ του τρέχοντος βήματος. Η `get_states()` δεν εκτελεί ξανά δίοδο μέσω του GRU ή του `dynamic()`, αλλά **διαβάζει απευθείας** τα αποθηκευμένα `self.recurrent_state` και `self.stochastic_state_logits` και υπολογίζει τα απαραίτητα KL μεγέθη.

Η μοναδική επιπλέον κλήση της κανονικής διόδου μέσα στην `get_states()` είναι:

- Transition model με τρέχον ιστορικό:

$$(\texttt{prior_logits},\; \cdot) \;=\; _\text{transition}(h_t) \quad \Rightarrow \quad p_\phi(z_t \mid h_t)$$

παράγοντας τα prior logits που απαιτούνται για τον υπολογισμό του KL_A.

3.4.3 Δίοδος Κενού Ιστορικού

Η δίοδος κενού ιστορικού εκτελείται *εξ ολοκλήρου* μέσα στην `get_states()`. Κατασκευάζεται ένα μηδενικό διάνυσμα ίδιων διαστάσεων με το h_t:

$$h_0 \;=\; \mathbf{0} \;\in\; \mathbb{R}^{d_h}$$

το οποίο αντιπροσωπεύει την πλήρη απουσία ιστορικής μνήμης. Στη συνέχεια εκτελούνται *δύο ανεξάρτητες* κλήσεις, χωρίς κλήση του GRU ή του `dynamic()`:

1. **Transition model με** h_0 (prior χωρίς ιστορικό):

$$(\texttt{prior_logits_h0},\ \cdot) \;=\; _\text{transition}(h_0) \quad \Rightarrow \quad p_\phi(z_t \mid h_0)$$

2. **Representation model με** h_0 **και** x_t (posterior χωρίς ιστορικό, με παρατήρηση):

$$(\texttt{posterior_logits_h0},\ \cdot) \;=\; _\text{representation}(h_0,\, e_t) \quad \Rightarrow \quad p_\phi(z_t \mid h_0, x_t)$$

Κρίσιμη παρατήρηση: η κωδικοποίηση $e_t = \text{encoder}(o_t)$ επαναϋπολογίζεται εντός της `get_states()` ανεξάρτητα από την `get_actions()`, καθώς χρησιμοποιείται ως είσοδος στο representation model με h_0. Η κλήση του `_representation` με h_0 χρησιμοποιεί το *ίδιο δίκτυο* που παράγει και το πλήρες posterior, απλώς με μηδενικό ιστορικό, απομονώνοντας έτσι τη συνεισφορά του h_t στη posterior κατανομή.

3.4.4 Υπολογισμός των Τριών KL Όρων

Βάσει των logits που συγκεντρώθηκαν από τις δύο διόδους, υπολογίζονται οι τρεις KL αποκλίσεις [38]. Η υλοποίηση χρησιμοποιεί την `kl_divergence` του PyTorch με κατανομές `OneHotCategoricalStraightThrough` (κατηγορική κατανομή 32×32 του DreamerV3), τυλιγμένες σε `Independent` για ανεξάρτητη μεταχείριση κάθε ομάδας κατηγοριών.

Οι τρεις όροι ορίζονται ως:

$$KL_A = \text{KL}\Big[q_\phi(z_t \mid h_t, x_t) \;\Big\|\; p_\phi(z_t \mid h_t)\Big] \tag{3.1}$$

$$KL_B = \text{KL}\Big[q_\phi(z_t \mid h_t, x_t) \;\Big\|\; p_\phi(z_t \mid h_0)\Big] \tag{3.2}$$

$$KL_C = \text{KL}\Big[q_\phi(z_t \mid h_t, x_t) \;\Big\|\; p_\phi(z_t \mid h_0, x_t)\Big] \tag{3.3}$$

όπου:

- $q_\phi(z_t \mid h_t, x_t) \leftarrow$ `self.stochastic_state_logits` (παράχθηκε από `get_actions()`)

- $p_\phi(z_t \mid h_t) \leftarrow$ `prior_logits` (από `_transition(self.recurrent_state)`)
- $p_\phi(z_t \mid h_0) \leftarrow$ `prior_logits_h0` (από `_transition(h_0)`)
- $p_\phi(z_t \mid h_0, x_t) \leftarrow$ `posterior_logits_h0` (από `_representation(h_0, e_t)`)

Σε όλους τους όρους η **βασική κατανομή (αριστερά)** είναι πάντοτε η πλήρης posterior $q_\phi(z_t \mid h_t, x_t)$· μόνο η κατανομή αναφοράς (δεξιά) αλλάζει. Το κατώφλι και ο κανόνας ταξινόμησης παραμένουν αμετάβλητοι:

$$\text{threshold} = KL_B - KL_C, \qquad \text{novel} = (\text{threshold} < 0) \ \vee \ (KL_A > \text{threshold})$$

3.4.5 Κανόνας Ταξινόμησης Ανωμαλίας

Από τους τρεις KL όρους ορίζεται το δυναμικό κατώφλι:

$$\text{threshold} = B - C$$

και η ταξινόμηση ανωμαλίας:

$$\text{novel} = (\text{threshold} < 0) \ \vee \ (A > \text{threshold})$$

Η πρώτη συνθήκη (threshold < 0) υποδηλώνει ότι το ιστορικό αντί να βοηθά, παραπλανά την πρόβλεψη, γεγονός που αποτελεί ισχυρή ένδειξη δομικής μεταβολής. Η δεύτερη ($A >$ threshold) υποδηλώνει ότι η τρέχουσα παρατήρηση είναι περισσότερο απρόβλεπτη από ό,τι εκτιμά το μοντέλο βάσει του ιστορικού.

3.5 Αρχιτεκτονική και Εκπαίδευση CNN Ταξινομητή

3.5.1 Είσοδος και Προεπεξεργασία

Ο ταξινομητής υλοποιείται σε TensorFlow/Keras. Δέχεται ως είσοδο έναν πίνακα $24 \times 24 \times 2$, στον οποίο το πρώτο κανάλι είναι ο χάρτης δεικτών κλάσεων της πραγματικής παρατήρησης και το δεύτερο ο αντίστοιχος χάρτης της φανταζόμενης εικόνας. Το μοντέλο ανιχνεύει διαφορές στις κλάσεις μεταξύ παρατήρησης και φαντασίας, καθώς η παρουσία ενός εμποδίου θα εμφανίζεται στην παρατήρηση αλλά όχι στη φαντασία του μοντέλου κόσμου που δεν το περίμενε.

3.5.2 Αρχιτεκτονική Δικτύου

Η αρχιτεκτονική ακολουθεί ένα τυπικό συνελικτικό μοτίβο με προοδευτική μείωση χωρικής ανάλυσης και αύξηση αριθμού φίλτρων [24]:

1. **Πρώτο Στρώμα**: `Conv2D(64, 5×5, relu)` → `BatchNormalization` [19] → `MaxPooling2D(2`
   Ο μεγαλύτερος πυρήνας 5×5 δίνει πλατύτερο receptive field, κατάλληλο για σχετικά μικρές εικόνες 24×24.

2. **Δεύτερο Στρώμα**: `Conv2D(64, 3×3, relu)` → `BatchNormalization` → `MaxPooling2D(2×2`
   Μικρότερος πυρήνας για εξαγωγή λεπτότερων χαρακτηριστικών στη μειωμένη ανάλυση.

3. **Κανονικοποίηση**: `Dropout(0.5)` → `Flatten`. Το Dropout ελαχιστοποιεί την υπερπροσαρμογή (overfitting) σε ένα σχετικά μικρό σύνολο δεδομένων.

4. **Πλήρως Συνδεδεμένα**: `Dense(128, relu)` → `Dropout(0.5)` → `Dense(1, sigmoid)`.

Η αρχιτεκτονική μεταγλωττίζεται με βελτιστοποιητή `Adam` (learning rate 10^{-3}) και συνάρτηση απώλειας `binary_crossentropy`.

3.5.3 Σύνθεση Συνόλου Δεδομένων και Εκπαίδευση

Τα κανονικά και ανώμαλα δεδομένα φορτώνονται από τους αντίστοιχους φακέλους και διαχωρίζονται σε σύνολο εκπαίδευσης ($\approx 70\%$), επικύρωσης ($\approx 15\%$) και ελέγχου ($\approx 15\%$) *κατά ολόκληρα επεισόδια*: τα αναγνωριστικά επεισοδίων διαβάζονται από τα ονόματα των αρχείων, ταξινομούνται και τεμαχίζονται σε τρεις συνεχόμενες περιοχές επεισοδίων, ώστε τα ποσοστά να αναφέρονται στο πλήθος των καρέ. Ο διαχωρισμός κατά επεισόδια, αντί κατά μεμονωμένα καρέ, είναι ουσιώδης: διαδοχικά καρέ του ίδιου επεισοδίου στα 10 Hz είναι έντονα συσχετισμένα, και ένας διαχωρισμός σε επίπεδο καρέ θα τοποθετούσε σχεδόν πανομοιότυπα δείγματα εκατέρωθεν του ορίου εκπαίδευσης–ελέγχου, διογκώνοντας τεχνητά τις μετρικές ελέγχου. Με τον διαχωρισμό κατά επεισόδια, κανένα καρέ των συνόλων επικύρωσης ή ελέγχου δεν προέρχεται από επεισόδιο που συμμετείχε στην εκπαίδευση.

Εκπαιδεύεται *ένας* ταξινομητής, στο ενιαίο σύνολο της ρύθμισης τυχαίων εμποδίων (Ενότητα 3.3), και χρησιμοποιείται αμετάβλητος και στις δύο ρυθμίσεις αξιολόγησης. Η συλλογή αποδίδει 17,756 ζεύγη από 100 επεισόδια. Ο διαχωρισμός αναθέτει 62 επεισόδια (12,516 καρέ, 70.5%, εκ των οποίων 19.0% ανώμαλα) στην εκπαίδευση, 18 επεισόδια (2,601 καρέ, 14.6%, με 7.3% ανώμαλα) στην επικύρωση και 20 επεισόδια (2,639 καρέ, 14.9%, με 10.0% ανώμαλα) στον έλεγχο. Κάθε δείγμα είναι ένας πίνακας $24 \times 24 \times 2$ (συνένωση παρατήρησης και φαντασίας).

Το σύνολο επικύρωσης χρησιμοποιείται ως validation data κατά την εκπαίδευση, ώστε να παρακολουθείται η σύγκλιση της απώλειας και της ακρίβειας σε ανεξάρτητα δεδομένα σε κάθε

εποχή, ενώ το σύνολο ελέγχου χρησιμοποιείται αποκλειστικά για την τελική αναφορά των μετρικών, χωρίς να έχει επηρεάσει καθόλου την εκπαίδευση ή την επιλογή του κατωφλίου. Μετά την εκπαίδευση, το δίκτυο επιτυγχάνει διασταυρούμενη εντροπία (BCE) $1.0 \cdot 10^{-3}$ και ακρίβεια 0.9997 στο σύνολο εκπαίδευσης, 0.323 και 0.947 στο σύνολο επικύρωσης, και 0.246 και 0.966 στα κρατημένα επεισόδια ελέγχου (συγκεντρωτικά στον Πίνακα 4.2 του Κεφαλαίου 4· οι ακρίβειες αναφέρονται στο προεπιλεγμένο κατώφλι 0.5 του Keras). Σε αντίθεση με τον παλαιότερο διαχωρισμό σε επίπεδο καρέ, ο έντιμος διαχωρισμός κατά επεισόδια αποκαλύπτει μη μηδενική γενίκευση προς νέα επεισόδια: το σήμα ασυμφωνίας παρατήρησης–φαντασίας παραμένει ισχυρά διαχωρίσιμο, όχι όμως τετριμμένα.

3.5.4 Πρόβλεψη κατά την Αξιολόγηση

Ο ταξινομητής λειτουργεί ως δυαδικός ανιχνευτής με έξοδο στο $\{0, 1\}$. Κατά την πρόβλεψη, η βαθμωτή έξοδος της σιγμοειδούς ενεργοποίησης συγκρίνεται με ένα κατώφλι απόφασης τ:

$$\hat{y} = \begin{cases} 0 & \text{αν } \sigma(z) < \tau \\ 1 & \text{διαφορετικά.} \end{cases}$$

Υπό τον διαχωρισμό κατά επεισόδια της Ενότητας 3.5.3, η κατανομή των εξόδων της σιγμοειδούς είναι συγκεντρωμένη κοντά στα $\{0, 1\}$ αλλά *όχι* διπολική: ένα μη αμελητέο κλάσμα των εξόδων βρίσκεται στην ενδιάμεση ζώνη και μια μειοψηφία ανώμαλων καρέ λαμβάνει τιμές κοντά στο μηδέν, οπότε η επιλογή του τ αποτελεί πραγματική επιλογή σημείου λειτουργίας και όχι απλή αριθμητική ανοχή. Η επιλογή γίνεται στο σύνολο *επικύρωσης*, από τη χαρακτηριστική καμπύλη λειτουργίας (ROC) της σιγμοειδούς εξόδου, ως το *μεγαλύτερο* τ που διατηρεί την ανάκληση επικύρωσης τουλάχιστον στο επίπεδο όπου η καμπύλη ισοπεδώνεται (0.81)· έτσι η συντηρητική ως προς την ασφάλεια κατεύθυνση (προτίμηση του ψευδούς συναγερμού έναντι της αστοχίας ανίχνευσης) εκφράζεται ως κατώτατο όριο ανάκλησης, ενώ αφαιρούνται όσοι ψευδείς συναγερμοί το επιτρέπουν. Η διαδικασία και οι καμπύλες παρατίθενται στην Ενότητα 4.3.1 του Κεφαλαίου 4· η επιλεγμένη τιμή είναι $\tau = 0.1485$. Το σύνολο ελέγχου βαθμολογείται μία και μόνη φορά στην επιλεγμένη τιμή και δεν συμμετέχει στην επιλογή. Η καταστολή των παροδικών, μεμονωμένων ψευδών συναγερμών δεν ανατίθεται στο κατώφλι αλλά στη χρονική λογική του επόπτη ασφαλείας (Ενότητα 3.7).

Η δυαδική έξοδος `anomaly_detection` $\in \{0, 1\}$ καταγράφεται σε κάθε χρονικό βήμα και χρησιμοποιείται στη συγκριτική αξιολόγηση των δύο ανιχνευτών (Ενότητα 3.6) και ως είσοδος του επόπτη ασφαλείας (Ενότητα 3.7).

3.6 Βρόχος Αξιολόγησης Πραγματικού Χρόνου

3.6.1 Δομή Βρόχου

Ο βρόχος αξιολόγησης εκτελεί 100 επεισόδια με τον παγωμένο πράκτορα DreamerV3. Στην αρχή *κάθε* επεισοδίου, η αναδρομική κατάσταση του πράκτορα μηδενίζεται (`init_states`) και ως πρώτη παρατήρηση χρησιμοποιείται αυτή που επιστρέφει το `env.reset()`, ώστε το ιστορικό στο οποίο βασίζεται το όριο KL να ανήκει αποκλειστικά στο τρέχον επεισόδιο και να μην μεταφέρεται κατάσταση μεταξύ επεισοδίων. Στο σενάριο των τυχαίων πόλεων, μετά από κάθε αλλαγή χάρτη (`load_world`) επανεφαρμόζονται οι ρυθμίσεις συγχρονισμένης λειτουργίας των 10 Hz, ώστε η προσομοίωση να παραμένει ντετερμινιστική σε όλη τη διάρκεια της εκτέλεσης. Σε κάθε βήμα:

1. Ο πράκτορας παράγει μία ενέργεια μέσω της `get_actions`, η οποία ενημερώνει την αναδρομική κατάσταση h_t και υπολογίζει την posterior $q_\phi(z_t \mid h_t, x_t)$ του τρέχοντος βήματος.

2. Το περιβάλλον εκτελεί ένα βήμα και επιστρέφει νέα παρατήρηση.

3. Καλείται η μέθοδος `get_states`, η οποία:

   - διαβάζει την ήδη ενημερωμένη posterior και εκτελεί τη δίοδο κενού ιστορικού,
   - υπολογίζει KL_A, KL_B, KL_C και το δυναμικό κατώφλι, παράγοντας τη δυαδική σημαία ανωμαλίας,
   - επιστρέφει τα prior/posterior logits και την ανακατασκευασμένη («φανταζόμενη») παρατήρηση $\hat{o}_t$.

4. Η σημασιολογική παρατήρηση και η φαντασία μετατρέπονται σε χάρτες δεικτών κλάσεων.

5. Ο CNN ταξινομητής λαμβάνει το συνενωμένο ζεύγος $24 \times 24 \times 2$ και παράγει την πρόβλεψη ανωμαλίας.

6. Σε κάθε βήμα καταγράφονται η αληθής ετικέτα (από τον μορφολογικό τελεστή της τρέχουσας ρύθμισης εμποδίων, Παράρτημα Α′.5) μαζί με τις αποφάσεις και των δύο ανιχνευτών, ώστε να αξιολογηθούν στα ίδια ακριβώς δεδομένα.

7. Τα δύο δυαδικά σήματα τροφοδοτούν τον επόπτη ασφαλείας της Ενότητας 3.7, ο οποίος υπολογίζει την εντολή πέδησης· η εντολή εφαρμόζεται από το περιβάλλον στο *επόμενο* βήμα (μία περίοδος ελέγχου των 0.1 s). Στη διαμόρφωση αναφοράς (*βασική γραμμή*) ο επόπτης δεν επεμβαίνει ποτέ στο όχημα.

3.6.2 Μετρικές Αξιολόγησης

Για τη σύγκριση των δύο μεθόδων συλλέγονται τα αποτελέσματα ταξινόμησης ανά βήμα για όλα τα επεισόδια. Οι κύριες μετρικές αξιολόγησης περιλαμβάνουν:

- **Ακρίβεια (Accuracy)**: Ποσοστό ορθά ταξινομημένων βημάτων.
- **Precision / Recall**: Από `sklearn.metrics.precision_recall_fscore_support` και `confusion_matrix`.
- **F1-Score**: Αρμονικός μέσος precision και recall.
- **Ισορροπημένη ακρίβεια (Balanced accuracy)**: Μέσος όρος ευαισθησίας (recall) και ειδικότητας, κατάλληλος για μη ισορροπημένες κλάσεις.
- **MCC (Matthews Correlation Coefficient)**: Συντελεστής συσχέτισης Matthews· ισορροπημένο μέτρο ποιότητας ταξινόμησης ακόμη και υπό ανισορροπία κλάσεων.
- **Ψευδώς Θετικά (False Positives)**: Κρίσιμη μετρική για συστήματα ασφαλείας· υψηλό ποσοστό ψευδών συναγερμών υποβαθμίζει τη χρηστικότητα.

Τα αποτελέσματα και η συγκριτική ανάλυση των δύο μεθόδων παρουσιάζονται στο Κεφάλαιο 4.

3.7 Σύστημα Παρατήρησης Ανωμαλιών σε Κλειστό Βρόχο

Πέρα από τη συγκριτική αξιολόγηση των δύο ανιχνευτών ως παθητικών σημάτων, τα δύο δυαδικά σήματα ενοποιούνται σε ένα *Σύστημα Παρατήρησης Ανωμαλιών* (Anomaly Observation System) που λειτουργεί ως επόπτης ασφαλείας κλειστού βρόχου: σε κάθε χρονικό βήμα υπολογίζει μια εντολή πέδησης στο $[0, 1]$, την οποία το περιβάλλον εφαρμόζει στο επόμενο βήμα, υπερισχύοντας της πέδησης που επιλέγει η πολιτική. Ο σχεδιασμός απορρέει ευθέως από τη συμπληρωματικότητα των δύο σημάτων (Κεφάλαια 4 και 5): ο ταξινομητής CNN είναι ο πρωτεύων ανιχνευτής εμποδίων, ενώ το όριο KL λειτουργεί ως επόπτης εγκυρότητας του μοντέλου και ρυθμίζει μόνο την εμπιστοσύνη που αποδίδεται στον ταξινομητή.

3.7.1 Προοδευτική πέδηση με ανοχή κενών

Η πέδηση είναι *προοδευτική*: μια ακολουθία διαδοχικών σημάνσεων του ταξινομητή αυξάνει την εντολή πέδησης κατά $\delta = 0.25$ ανά καρέ, έως την πλήρη πέδηση στο τέταρτο διαδοχικό καρέ (0.4 s στα 10 Hz), οπότε μια σήμανση που *επιμένει* ακινητοποιεί το όχημα ενώ μια μεμονωμένη σήμανση παράγει το πολύ ένα ελαφρύ φρενάρισμα. Η ακολουθία επιβιώνει από κενό

έως $g = 1$ καρέ χωρίς σήμανση (η πέδηση διατηρείται στο τρέχον επίπεδο) και μηδενίζεται από μεγαλύτερο κενό, οπότε η πέδηση απελευθερώνεται. Αυτή η χρονική λογική είναι που διαχωρίζει ένα πραγματικό εμπόδιο από τα σφάλματα ανακατασκευής ενός ατελούς μοντέλου κόσμου: το εμπόδιο παραμένει στον διάδρομο κίνησης και κρατά τη σήμανση ενεργή καρέ με το καρέ, ενώ τα σφάλματα ανακατασκευής είναι ασυνεπή μεταξύ διαδοχικών καρέ και δεν συσσωρεύονται.

3.7.2 Ρύθμιση εμπιστοσύνης από το όριο KL

Ο συναγερμός του ορίου KL ορίζεται ως ο εκθετικά εξομαλυμένος μέσος όρος του δυαδικού σήματος καινοτομίας, $r_t = \beta\, r_{t-1} + (1 - \beta)\,\mathrm{novel}_t$ με $\beta = 0.9$, συγκρινόμενος με κατώφλι $\rho = 0.5$· η εξομάλυνση μετατρέπει τον ανά καρέ κανόνα σε δήλωση περί *παρατεταμένης* έκπληξης και σιωπά σε μεμονωμένες ενεργοποιήσεις. Όσο ο συναγερμός είναι κάτω, η προοδευτική πέδηση ξεκινά από την πρώτη σήμανση του ταξινομητή. Όσο ο συναγερμός είναι πάνω, ο ταξινομητής υποβαθμίζεται: η πέδηση ξεκινά μόνο μετά από $k = 3$ διαδοχικές σημάνσεις, σύμφωνα με τη μέτρηση του Κεφαλαίου 4 ότι η ακρίβεια σημάνσεων του ταξινομητή μειώνεται ακριβώς στις συνθήκες που εγείρουν τον συναγερμό. Στη διαμόρφωση δύο επιπέδων ο συναγερμός KL δεν έχει καμία άλλη επίδραση στο όχημα.

3.7.3 Διαμορφώσεις και τερματισμός ασφαλούς στάσης

Ο επόπτης εκτελείται σε μία από τέσσερις διαμορφώσεις, μία ανά εκτέλεση, οι οποίες συγκρίνονται μεταξύ εκτελέσεων (Ενότητα 4.8): *βασική γραμμή* (τα σήματα υπολογίζονται και καταγράφονται αλλά το όχημα δεν αγγίζεται ποτέ, δηλαδή ο ανοιχτός βρόχος της συγκριτικής αξιολόγησης), *μόνο ταξινομητής CNN*, *μόνο όριο KL* (μια ακολουθία διαδοχικών καρέ συναγερμού οδηγεί την ίδια προοδευτική πέδηση, μετρώντας τι επιτυγχάνει ο επόπτης εγκυρότητας ως αυτόνομος μηχανισμός ασφαλείας) και *πλήρες σύστημα CNN + KL* (η αρχιτεκτονική δύο επιπέδων που περιγράφηκε παραπάνω). Κατά την αξιολόγηση προστίθεται ένας πρόσθετος τερματισμός επεισοδίου, η *ασφαλής στάση*: όταν ο επόπτης έχει την πέδηση ενεργή και το όχημα παραμένει ακινητοποιημένο για δέκα διαδοχικά βήματα, το επεισόδιο περικόπτεται. Όλες οι παράμετροι του επόπτη (δ, g, β, ρ, k, το κατώφλι τ του ταξινομητή) καταγράφονται στο αρχείο αποτελεσμάτων κάθε εκτέλεσης.

4

Πειραματικά Αποτελέσματα και Ανάλυση

Εκτελεστική σύνοψη. Το παρόν κεφάλαιο παρουσιάζει και αναλύει το σύνολο των πειραματικών αποτελεσμάτων που συγκεντρώθηκαν στην παρούσα εργασία. Η παρουσίαση οργανώνεται σε τέσσερα μέρη: (i) την εκπαίδευση και τη σύγκλιση του πράκτορα DreamerV3 [16] στα τρία σενάρια οδήγησης, (ii) την εκπαίδευση του επιβλεπόμενου ταξινομητή CNN και την επιλογή του κατωφλίου απόφασής του, (iii) τη συγκριτική αξιολόγηση των δύο μεθόδων ανίχνευσης ανωμαλιών, του ταξινομητή CNN και του κατωφλίου ανωμαλίας KL των Zollicoffer κ.ά. [38] σε πραγματικό χρόνο, με χρήση του "παγωμένου" πράκτορα, και (iv) την αξιολόγηση ασφάλειας σε κλειστό βρόχο του Συστήματος Παρατήρησης Ανωμαλιών της Ενότητας 3.7, στο οποίο τα σήματα των ανιχνευτών τροφοδοτούν την πέδηση του οχήματος. Για κάθε μέρος παρατίθενται οι καμπύλες εκπαίδευσης, οι πίνακες σύγχυσης, το πλήρες σύνολο στατιστικών μετρικών και οι αντίστοιχες συγκριτικές γραφικές παραστάσεις.

4.1 Επισκόπηση πειραμάτων και ορολογία

Για την αποφυγή σύγχυσης μεταξύ των δύο ανεξάρτητων αξόνων μεταβλητότητας, υιοθετείται η ακόλουθη ορολογία, η οποία διατηρείται σε όλο το κεφάλαιο.

Σενάρια οδήγησης (εκπαίδευση & αξιολόγηση του DreamerV3). Ο πράκτορας εκπαιδεύεται και αξιολογείται σε τρία σενάρια αυξανόμενης δυσκολίας, σύμφωνα με την Ενότητα 3.2.3:

- **Σ1 - Στατική διαδρομή:** σταθερός χάρτης (`Town01`) και προκαθορισμένη διαδρομή σε κάθε επεισόδιο.
- **Σ2 - Τυχαία διαδρομή:** σταθερός χάρτης, αλλά τυχαία σημεία εκκίνησης/προορισμού ανά επεισόδιο.
- **Σ3 - Τυχαίες πόλεις:** τυχαία διαδρομή ανά επεισόδιο και αλλαγή του χάρτη πόλης σε άλλη τυχαία πόλη κάθε 20 επεισόδια.

Ρυθμίσεις εμποδίων (σύνολο δεδομένων & αξιολόγηση ανίχνευσης). Ο ταξινομητής CNN εκπαιδεύεται σε δύο ρυθμίσεις ως προς τη φύση του εμποδίου που εισάγεται κατά την αξιολόγηση:

- **P1 - Μοναδικό εμπόδιο:** ένα στατικό όχημα (κλάση *car*) τοποθετείται σε τυχαίο σημείο της διαδρομής.
- **P2 - Τυχαία εμπόδια:** σε κάθε επεισόδιο επιλέγεται τυχαία ένα εμπόδιο από τα blueprints οχημάτων και στατικών αντικειμένων του προσομοιωτή και τοποθετείται σε τυχαίο σημείο της διαδρομής (οι πεζοί εξαιρούνται, Ενότητα 3.1.4).

Και στις δύο ρυθμίσεις το εμπόδιο τοποθετείται σε ευθεία προσέγγιση (Ενότητα 3.1.4), ώστε να εισέρχεται στο οπτικό πεδίο πριν το όχημα το προσεγγίσει. Χρησιμοποιείται *ένας* ταξινομητής CNN, εκπαιδευμένος στο σύνολο της ρύθμισης P2, και στις δύο ρυθμίσεις αξιολόγησης· η αληθής ετικέτα παράγεται από τον μορφολογικό τελεστή της εκάστοτε ρύθμισης (δεσμευμένο στην κλάση στο P1, ανεξάρτητο κλάσης στο P2).

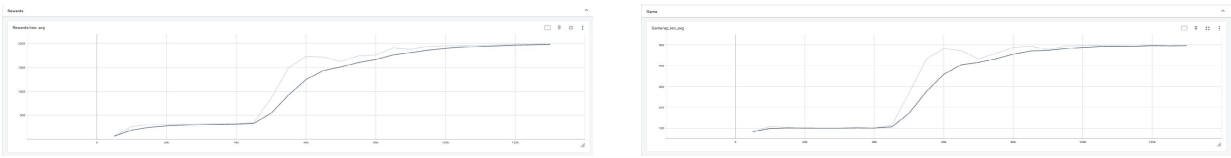
Ο συνολικός πίνακας σύγχυσης ανίχνευσης ανωμαλιών είναι, επομένως, 2 (ρυθμίσεις εμποδίων) $\times$ 3 (σενάρια οδήγησης) $= 6$ συνθήκες. Σε κάθε συνθήκη εκτελούνται 100 επεισόδια αξιολόγησης με τον παγωμένο πράκτορα και η ταξινόμηση γίνεται *ανά χρονικό βήμα* (per-timestep): η αληθής ετικέτα είναι $y_t = 1$ για τα βήματα στα οποία το εμπόδιο είναι παρόν στη σκηνή (μετά την εμφάνισή του) και $y_t = 0$ αλλιώς. Και οι δύο ανιχνευτές αξιολογούνται στα ίδια ακριβώς δεδομένα και την ίδια ακριβώς στιγμή, ώστε η σύγκριση να είναι δίκαιη. Οι μετρικές ανίχνευσης προέρχονται από τις εκτελέσεις *ανοιχτού* βρόχου (βασική γραμμή), στις οποίες ο επόπτης δεν επεμβαίνει στο όχημα· η αξιολόγηση κλειστού βρόχου παρουσιάζεται χωριστά στην Ενότητα 4.8. Τα επεισόδια κάθε εκτέλεσης αντλούνται ανεξάρτητα (διαδρομές, τύποι και θέσεις εμποδίων δειγματοληπτούνται εκ νέου), οπότε οι διαμορφώσεις συγκρίνονται μέσω διαστημάτων εμπιστοσύνης και όχι επεισόδιο προς επεισόδιο.

4.2 Εκπαίδευση και σύγκλιση του DreamerV3

Σε αυτή την ενότητα παρουσιάζονται οι καμπύλες εκπαίδευσης του πράκτορα DreamerV3 για τα τρία σενάρια. Όλες οι μετρικές καταγράφηκαν συναρτήσει του αριθμού βημάτων περιβάλλοντος (environment steps). Στα σενάρια Σ2 και Σ3, όπου οι ακατέργαστες καμπύλες είναι έντονα "πριονωτές", υπερτίθεται σε κάθε διάγραμμα, τόσο της μέσης ανταμοιβής όσο και του μήκους επεισοδίου, μια έντονη κόκκινη καμπύλη που αποτελεί την *εξομαλυμένη τάση* (smoothed trend) και αναδεικνύει τη συνολική πορεία πέρα από τον βραχυπρόθεσμο θόρυβο. Το σενάριο Σ1 δεν χρειάζεται τέτοια επισήμανση, καθώς οι καμπύλες του είναι ήδη ομαλές.

4.2.1 Σενάριο Σ1 - Στατική διαδρομή

Το Σχήμα 4.1 παρουσιάζει την εξέλιξη της μέσης ανταμοιβής και του μήκους επεισοδίου· οι τιμές που ακολουθούν διαβάζονται από τις καμπύλες εκπαίδευσης. Το σενάριο Σ1 εκπαιδεύτηκε για ≈ 130k περιβαλλοντικά βήματα και εμφανίζει υποδειγματική, μονοτονική σύγκλιση. Μετά από μια αρχική φάση εξερεύνησης/προθέρμανσης, κατά την οποία η μέση ανταμοιβή παραμένει σε χαμηλό πλατό ≈ 300 έως τα ≈ 45k βήματα, καθώς το μοντέλο κόσμου μαθαίνει να ανακατασκευάζει την παρατήρηση προτού ο πράκτορας αποκτήσει αξιοποιήσιμη φαντασία, η απόδοση *αρχίζει να συγκλίνει* απότομα γύρω στα ≈ 45k βήματα. Ακολουθεί μια σύντομη μεταβατική φάση (με στιγμιαία υπερακόντιση της μη εξομαλυμένης καμπύλης έως ≈ 1700 σε ανταμοιβή), και ο πράκτορας έχει *συγκλίνει πλήρως* έως τα ≈ 100k βήματα, σταθεροποιούμενος σε πλατό μέσης ανταμοιβής ≈ 2000 που διατηρείται αμετάβλητο έως το τέλος της εκπαίδευσης. Παράλληλα, το μήκος επεισοδίου ανεβαίνει από ≈ 100 και κορεσμοποιείται στον μέγιστο χρονικό ορίζοντα του επεισοδίου (≈ 500 βήματα), γεγονός που υποδηλώνει συνεπή ολοκλήρωση της διαδρομής χωρίς πρόωρο τερματισμό. Πρόκειται, συνεπώς, για ένα *πλήρως επιλυμένο* σενάριο, το οποίο αποτελεί την ιδανική βάση για την αξιολόγηση των ανιχνευτών ανωμαλιών.

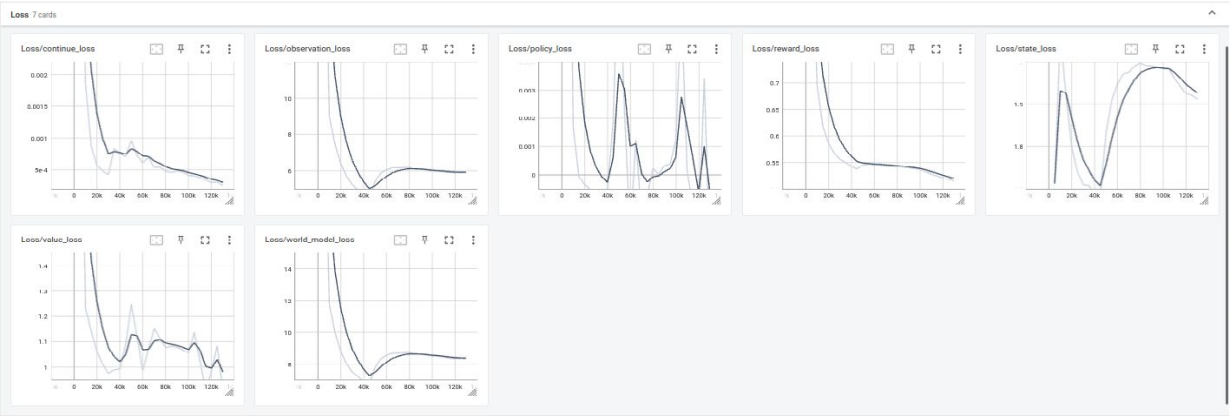


(α′) Μέση ανταμοιβή (β′) Μήκος επεισοδίου

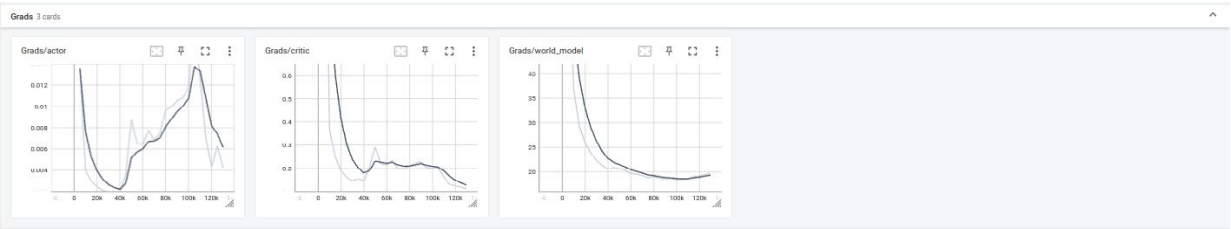
Σχήμα 4.1: *Σ1 (Στατική διαδρομή): καμπύλες μέσης ανταμοιβής και μέσου μήκους επεισοδίου. Η μονοτονική άνοδος και ο κορεσμός κοντά στον μέγιστο χρονικό ορίζοντα δείχνουν πλήρη σύγκλιση και συνεπή ολοκλήρωση διαδρομής.*

Το Σχήμα 4.2 παρουσιάζει τις επιμέρους απώλειες του μοντέλου κόσμου και των δικτύων actor/critic. Όλες οι συνιστώσες απώλειας (`observation`, `reward`, `continue`, `world_model`, `value`, `policy`) κατέρχονται και σταθεροποιούνται ομαλά, ενώ οι νόρμες των βαθμίδων

(Σχήμα 4.3) παραμένουν φραγμένες καθ' όλη τη διάρκεια της εκπαίδευσης, χωρίς ενδείξεις αστάθειας.



Σχήμα 4.2: *Σ1 (Στατική διαδρομή): συνιστώσες της συνάρτησης απώλειας. Όλες οι απώλειες συγκλίνουν ομαλά.*

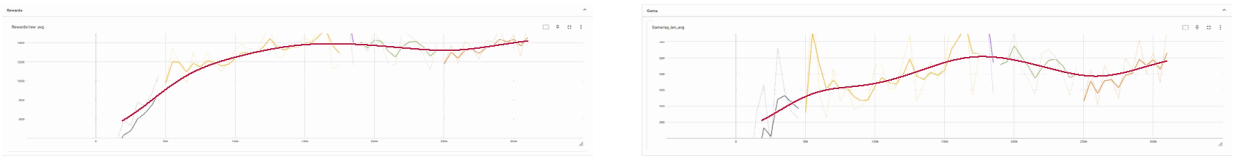


Σχήμα 4.3: *Σ1 (Στατική διαδρομή): νόρμες βαθμίδων για actor, critic και μοντέλο κόσμου. Οι βαθμίδες παραμένουν φραγμένες (ευσταθής εκπαίδευση).*

4.2.2 Σενάριο Σ2 - Τυχαία διαδρομή

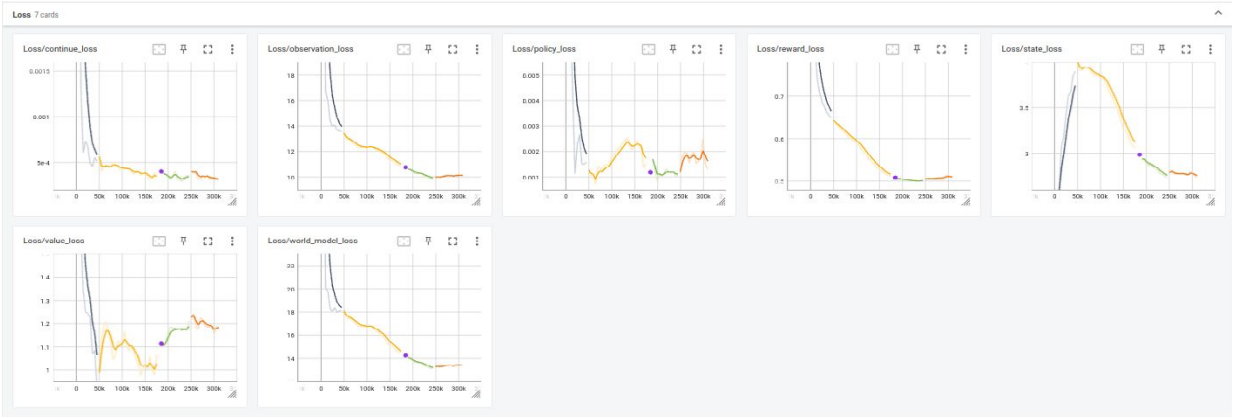
Το σενάριο Σ2 εκπαιδεύτηκε για ~ 300k περιβαλλοντικά βήματα. Όπως φαίνεται στο Σχήμα 4.4, το σενάριο της τυχαίας διαδρομής συγκλίνει επίσης, αλλά με σαφώς μεγαλύτερη διακύμανση και χωρίς το καθαρό, επίπεδο πλατό του Σ1. Μετά από μια αρχική φάση ανόδου (μέση ανταμοιβή έως ~ 860 γύρω στα ~ 45k βήματα), η απόδοση *αρχίζει να συγκλίνει* γύρω στα ~ 50k, εισερχόμενη σε μια ζώνη μέσης ανταμοιβής ~ 1200-1500 (με αιχμές έως ~ 1500), την οποία και *διατηρεί σταθερά, με έντονη διακύμανση αλλά χωρίς κατάρρευση από τα* $\sim 100k$ *βήματα και έπειτα*. Η αναμενόμενη "πριονωτή" συμπεριφορά οφείλεται στη διαφορετική δυσκολία κάθε τυχαίας διαδρομής, ενώ το μήκος επεισοδίου κυμαίνεται γύρω στα ~ 320-380 βήματα, καθώς οι διαδρομές παράγονται από τυχαία σημεία εκκίνησης και προορισμού· πρόκειται για αναμενόμενο αποτέλεσμα, που προκύπτει από το γεγονός ότι οι διαδρομές έχουν διαφορετικό μήκος, άρα και διαφορετική μέγιστη χρονική διάρκεια ολοκλήρωσης. Τα διακριτά χρωματικά τμήματα των καμπυλών αντιστοιχούν σε διαδοχικές επανεκκινήσεις/συνέχιση της εκπαίδευσης από checkpoint, ενωμένες σε μία ενιαία τροχιά που εκτείνεται πέραν των ~ 300k

βημάτων. Οι απώλειες (Σχήμα 4.5) εξακολουθούν να κατέρχονται (απώλεια μοντέλου κόσμου $\rightarrow\!\!\!\!\sim 14$, απώλεια παρατήρησης $\rightarrow\!\!\!\!\sim 10$), επιβεβαιώνοντας ότι ο πράκτορας έμαθε μια *γενικεύσιμη* πολιτική ακολουθίας σημείων διαδρομής αντί να απομνημονεύσει μία μόνο πορεία.



(α′) Μέση ανταμοιβή (β′) Μήκος επεισοδίου

Σχήμα 4.4: *Σ2 (Τυχαία διαδρομή): μέση ανταμοιβή και μήκος επεισοδίου. Σύγκλιση με διακύμανση λόγω της διαφορετικής δυσκολίας κάθε διαδρομής. Η έντονη κόκκινη καμπύλη και στα δύο διαγράμματα είναι η εξομαλυμένη τάση (smoothed trend) και αναδεικνύει την άνοδο προς το πλατό σύγκλισης.*



Σχήμα 4.5: *Σ2 (Τυχαία διαδρομή): συνιστώσες απώλειας. Συνεχιζόμενη πτωτική τάση.*



Σχήμα 4.6: *Σ2 (Τυχαία διαδρομή): νόρμες βαθμίδων actor/critic/μοντέλου κόσμου.*

4.2.3 Σενάριο Σ3 - Τυχαίες πόλεις

Το σενάριο των τυχαίων πόλεων είναι το απαιτητικότερο και, σε αντίθεση με τα Σ1 - Σ2, *δεν* επιτυγχάνει ποτέ σύγκλιση, παρότι η εκπαίδευση επεκτάθηκε έως τα ~ 550k περιβαλλοντικά βήματα. Δύο παρατηρήσεις είναι κρίσιμες. Πρώτον, οι καμπύλες ανταμοιβής και μήκους επεισοδίου (Σχήμα 4.7) εμφανίζονται ως ακολουθία διακριτών τμημάτων, καθένα από

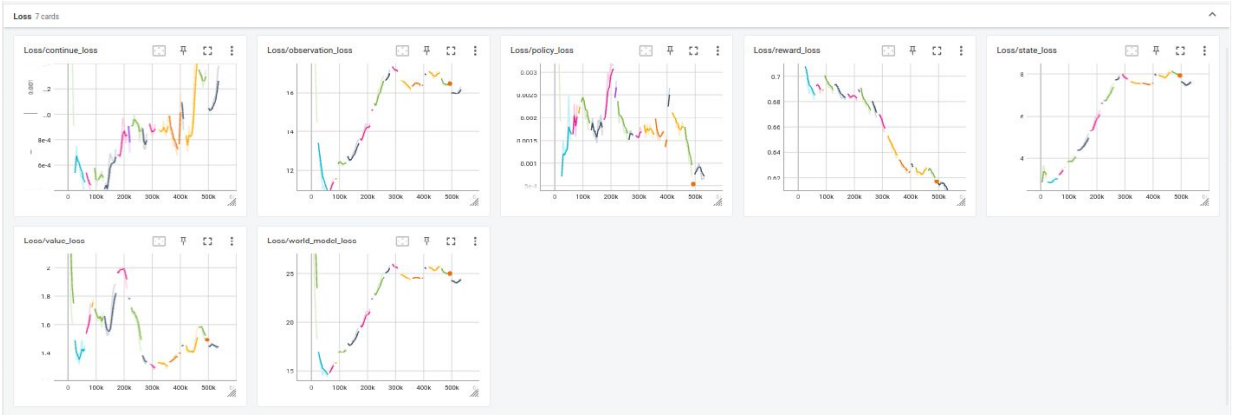
τα οποία ανεβαίνει απότομα και κατόπιν *καταρρέει*, συμπεριφορά απολύτως συνεπής με την εναλλαγή πόλης κάθε 20 επεισόδια: ο πράκτορας προσαρμόζεται στην τρέχουσα πόλη, και μόλις ο χάρτης αλλάξει η απόδοση καταρρέει προτού ανακάμψει μερικώς στη νέα πόλη. Οι τιμές που ακολουθούν διαβάζονται προσεγγιστικά από τις καμπύλες. Οι κορυφές ανά πόλη *αυξάνονται* καθ' όλη τη διάρκεια της εκπαίδευσης, η μέγιστη ανταμοιβή ανά πόλη ανεβαίνει από $\sim$350 στις πρώτες πόλεις έως $\sim$1300 στις τελευταίες, ενώ το μήκος επεισοδίου κορυφώνεται έως $\sim$400 βήματα, όμως σε κάθε αλλαγή χάρτη η απόδοση υποχωρεί εκ νέου σε ανταμοιβή $\sim$100-200 και μήκος $\sim$50-100 βήματα. Δεν σχηματίζεται ποτέ σταθερό πλατό: η γενίκευση σε εντελώς νέες, άγνωστες πόλεις δεν επιτεύχθηκε εντός του διαθέσιμου προϋπολογισμού εκπαίδευσης.



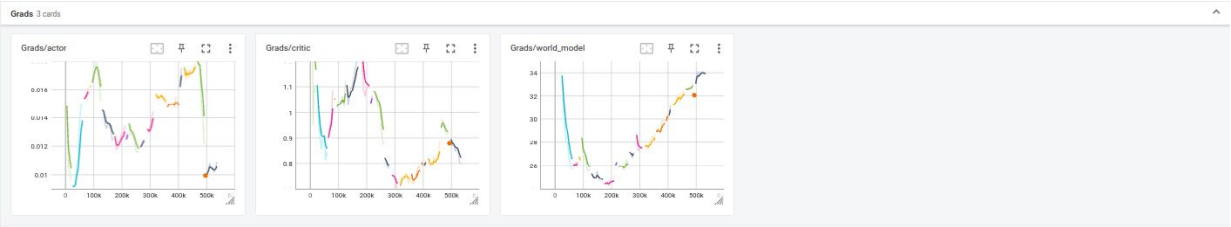
(α′) Μέση ανταμοιβή (β′) Μήκος επεισοδίου

Σχήμα 4.7: *Σ3 (Τυχαίες πόλεις): η "πριονωτή" μορφή με τα διαδοχικά καταρρέοντα τμήματα αντικατοπτρίζει την εναλλαγή πόλης κάθε 20 επεισόδια. Η έντονη κόκκινη καμπύλη και στα δύο διαγράμματα είναι η εξομαλυμένη συνολική τάση· παραμένει σε χαμηλή ζώνη και* δεν *συγκλίνει στο πλατό των Σ1 - Σ2, σε συμφωνία με την ανοδική τάση των απωλειών ανακατασκευής.*

Δεύτερον, και σημαντικότερο, οι απώλειες *αυξάνονται* κατά τη διάρκεια της εκπαίδευσης (Σχήμα 4.8): η απώλεια παρατήρησης ανεβαίνει από $\sim$11 σε $\sim$17, η απώλεια κατάστασης από $\sim$3 σε $\sim$8 και η συνολική απώλεια μοντέλου κόσμου από $\sim$15 σε $\sim$25. Πρόκειται για την ακριβώς αντίθετη συμπεριφορά σε σχέση με τα Σ1 - Σ2. Η αιτία είναι η *μη-στασιμότητα* του buffer επανάληψης: με μια νέα τυχαία πόλη κάθε 20 επεισόδια, το μοντέλο κόσμου καλείται να προσαρμοστεί σε έναν συνεχώς μετατοπιζόμενο στόχο τον οποίο δεν προλαβαίνει να μοντελοποιήσει.



Σχήμα 4.8: *Σ3 (Τυχαίες πόλεις): οι απώλειες ανακατασκευής (`observation`, `state`, `world_model`) αυξάνονται, ενώ η απώλεια ανταμοιβής μειώνεται· ένδειξη ότι ο πράκτορας εξακολουθεί να οδηγεί επαρκώς αν και η "φαντασία" του παύει να είναι πιστή.*



Σχήμα 4.9: *Σ3 (Τυχαίες πόλεις): νόρμες βαθμίδων. Η αυξανόμενη νόρμα του μοντέλου κόσμου συμβαδίζει με την αδυναμία ανακατασκευής των διαφορετικών πόλεων.*

Αποσύζευξη ελέγχου και ανακατασκευής. Μια ιδιαίτερα διαφωτιστική παρατήρηση είναι ότι, ενώ οι απώλειες ανακατασκευής αυξάνονται, η *απώλεια ανταμοιβής μειώνεται* (Σχήμα 4.8). Αυτό σημαίνει ότι το μοντέλο μπορεί ακόμη να προβλέπει ανταμοιβή/αξία αρκετά καλά ώστε να οδηγεί, παρόλο που η ανακατασκευή σε επίπεδο εικονοστοιχείων και κατάστασης υποβαθμίζεται. Με άλλα λόγια, το μοντέλο κόσμου αποτυγχάνει στην *ανακατασκευή* πολύ περισσότερο απ' ό,τι στον *έλεγχο*. Όπως θα φανεί στην Ενότητα 4.7, αυτή η αποσύζευξη είναι το κλειδί για την ερμηνεία της κατάρρευσης και των δύο ανιχνευτών στο σενάριο Σ3.

Συγκριτική σύνοψη σύγκλισης. Ο Πίνακας 4.1 συνοψίζει ποιοτικά τα ευρήματα εκπαίδευσης για τα τρία σενάρια, όπως προκύπτουν από την οπτική επιθεώρηση των καμπυλών εκπαίδευσης.

Πίνακας 4.1: *Ποιοτική σύνοψη εκπαίδευσης DreamerV3 ανά σενάριο.*

Δείκτης	**Σ1 Στατ.**	**Σ2 Τυχ. δρ.**	**Σ3 Τυχ. πόλεις**
Πλατό ανταμοιβής	Υψηλό και σταθερό	Μέτριο, με διακύμανση	Ασταθές (πριονωτό)
Μήκος επεισοδίου	Μεγάλο και σταθερό	Μέτριο	Ασταθές (πριονωτό)
Ταχύτητα σύγκλισης	Ταχεία, μονοτονική	Μέτρια, με διακύμανση	Δεν συγκλίνει
Τάση απωλειών ανακατασκευής	Πτωτική	Πτωτική	**Ανοδική**
Τάση απώλειας ανταμοιβής	Πτωτική	Πτωτική	Πτωτική
Κατάσταση	Σύγκλιση	Σύγκλιση με διακύμανση	Μη πλήρης (ανακατασκευή)

4.3 Εκπαίδευση του ταξινομητή CNN

Ο επιβλεπόμενος ταξινομητής CNN (αρχιτεκτονική Ενότητας 3.5) εκπαιδεύτηκε *μία* φορά, στο σύνολο δεδομένων της ρύθμισης τυχαίων εμποδίων, σε δείγματα εισόδου σχήματος

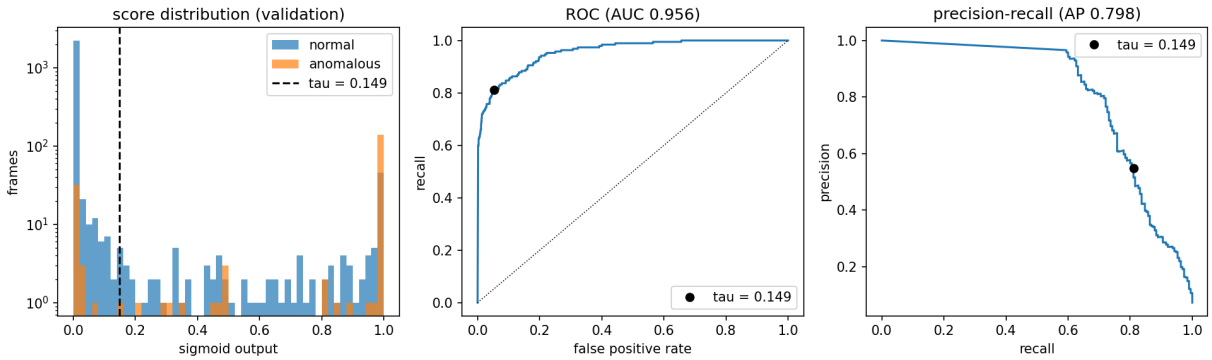
$24 \times 24 \times 2$ (συνένωση των χαρτών δεικτών κλάσεων της πραγματικής παρατήρησης και της φανταζόμενης ανακατασκευής, με εστίαση στο οδόστρωμα), και χρησιμοποιείται αμετάβλητος και στις δύο ρυθμίσεις αξιολόγησης. Ο διαχωρισμός εκπαίδευσης/επικύρωσης/ελέγχου γίνεται κατά ολόκληρα επεισόδια (Ενότητα 3.5.3), ώστε κανένα κρατημένο καρέ να μην προέρχεται από επεισόδιο της εκπαίδευσης. Ο Πίνακας 4.2 συνοψίζει τα μεγέθη των συνόλων και τις μετρικές ανά υποσύνολο. Υπό τον έντιμο αυτό διαχωρισμό, η διαχωριστικότητα παραμένει ισχυρή αλλά όχι τετριμμένη: η διασταυρούμενη εντροπία ελέγχου είναι 0.246 με ακρίβεια 0.966 (στο προεπιλεγμένο κατώφλι 0.5), έναντι $1.0 \cdot 10^{-3}$ / 0.9997 στο σύνολο εκπαίδευσης.

Πίνακας 4.2: *Εκπαίδευση του ταξινομητή CNN με διαχωρισμό κατά επεισόδια (ενιαίο σύνολο δεδομένων της ρύθμισης τυχαίων εμποδίων, 100 επεισόδια,* 17,756 *ζεύγη).*

Μέγεθος	**Εκπαίδευση**	**Επικύρωση**	**Έλεγχος**
Επεισόδια	62	18	20
Καρέ (ποσοστό συνόλου)	12,516 (70.5%)	2,601 (14.6%)	2,639 (14.9%)
Ποσοστό ανώμαλων καρέ	19.0%	7.3%	10.0%
Απώλεια (BCE)	$1.0 \cdot 10^{-3}$	0.323	0.246
Ακρίβεια (κατώφλι 0.5)	0.9997	0.947	0.966

4.3.1 Επιλογή κατωφλίου απόφασης

Το κατώφλι τ της σιγμοειδούς εξόδου επιλέγεται στο σύνολο επικύρωσης (Σχήμα 4.10). Η έξοδος διαχωρίζει τις δύο κλάσεις με εμβαδόν ROC 0.956 και μέση ακρίβεια σημάνσεων (average precision) 0.798· το 7.5% των τιμών επικύρωσης βρίσκεται στην ενδιάμεση ζώνη $(0.01, 0.99)$, δηλαδή η έξοδος δεν είναι διπολική. Το συντηρητικό όριο $\tau \to 0^+$ ($\tau = 10^{-6}$) επιτυγχάνει ανάκληση 0.974 με ποσοστό ψευδώς θετικών 0.348, δηλαδή σημαίνει ένα στα τρία κανονικά καρέ· η ανάκληση στη συνέχεια μειώνεται αργά κατά μήκος της καμπύλης ενώ το ποσοστό ψευδώς θετικών πέφτει απότομα, και η καμπύλη ισοπεδώνεται περίπου στην ανάκληση 0.81. Το κατώφλι ορίζεται ως το μεγαλύτερο τ που διατηρεί ανάκληση επικύρωσης τουλάχιστον 0.81, δίνοντας $\tau = 0.1485$ (επικύρωση: ανάκληση 0.811, ποσοστό ψευδώς θετικών 0.053, ακρίβεια σημάνσεων 0.548). Στα κρατημένα επεισόδια ελέγχου το κατώφλι αυτό αποδίδει ακρίβεια 0.956, ακρίβεια σημάνσεων 0.714, ανάκληση 0.940 και ποσοστό ψευδώς θετικών 0.042 (249 αληθώς θετικά, 100 ψευδώς θετικά, 16 αστοχίες σε 2,639 καρέ). Το βέλτιστο κατά Youden της ίδιας καμπύλης, $\tau = 0.026$, ανακτά τρία επιπλέον ανώμαλα καρέ ελέγχου με κόστος 41 επιπλέον ψευδώς θετικά.



Σχήμα 4.10: *Επιλογή του κατωφλίου απόφασης του ταξινομητή στο σύνολο επικύρωσης (*2,601 *καρέ,* 190 *ανώμαλα). Αριστερά: κατανομή της σιγμοειδούς εξόδου για κανονικά και ανώμαλα καρέ (λογαριθμική κλίμακα), με το επιλεγμένο* $\tau = 0.1485$*. Μέση: χαρακτηριστική καμπύλη λειτουργίας (ROC, εμβαδόν* 0.956*)· ο δείκτης είναι το σημείο λειτουργίας του επιλεγμένου κατωφλίου, ανάκληση* 0.811 *με ποσοστό ψευδώς θετικών* 0.053*. Δεξιά: καμπύλη ακρίβειας-ανάκλησης (μέση ακρίβεια σημάνσεων* 0.798*) με το ίδιο σημείο λειτουργίας.*

4.4 Πρωτόκολλο αξιολόγησης ανίχνευσης

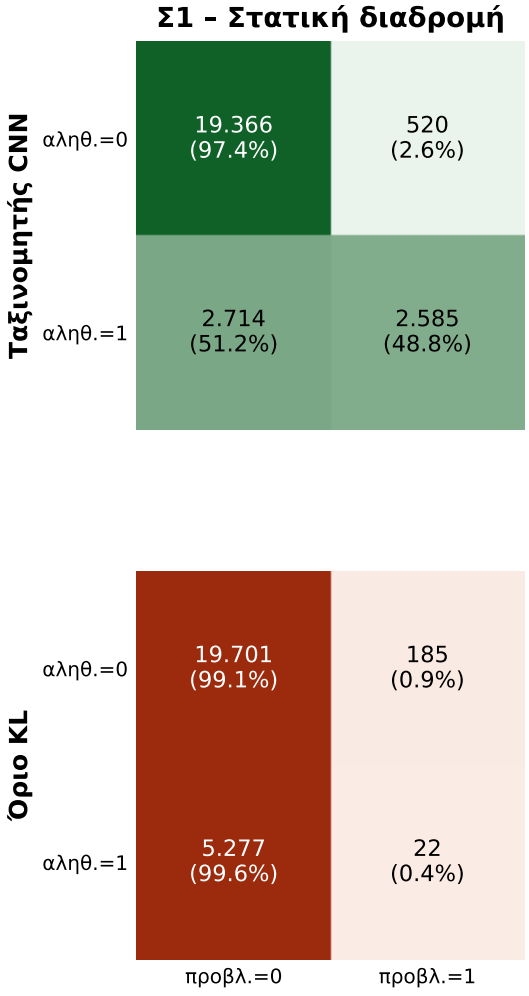
Μετά την εκπαίδευση, ο πράκτορας "παγώνει" και εκτελούνται 100 επεισόδια αξιολόγησης ανά συνθήκη, με ένα εμπόδιο να εισάγεται σε τυχαίο σημείο της διαδρομής (Ενότητες 3.3, 3.6). Σε κάθε χρονικό βήμα συλλέγονται ταυτόχρονα οι αποφάσεις και των δύο ανιχνευτών: του ταξινομητή CNN και του κατωφλίου KL [38]. Ο Πίνακας 4.3 παραθέτει το πλήθος δειγμάτων ανά συνθήκη και την ανισορροπία κλάσεων, η οποία είναι σημαντική για τη σωστή ερμηνεία της ακρίβειας (accuracy) έναντι της ισορροπημένης ακρίβειας (balanced accuracy). Σημειώνεται ότι τα ποσοστά ανωμαλιών των δύο ρυθμίσεων διαφέρουν έντονα, επειδή διαφέρουν οι τελεστές ετικέτας: ο δεσμευμένος στην κλάση τελεστής του P1 σημαίνει το όχημα-εμπόδιο από απόσταση έως και ~ 50 m, ενώ ο ανεξάρτητος κλάσης τελεστής του P2 ενεργοποιείται κυρίως εντός ~ 20 m, όταν το αντικείμενο εισέλθει στον διάδρομο κίνησης του παραθύρου 24×24.

Πίνακας 4.3: *Πλήθος δειγμάτων (per-timestep) και ποσοστό ανωμαλιών ανά συνθήκη αξιολόγησης (100 επεισόδια/συνθήκη).*

Ρύθμιση	Σενάριο	Δείγματα	Ανωμαλίες
P1 Μοναδικό	Σ1 Στατική διαδρομή	25,185	21.0%
P1 Μοναδικό	Σ2 Τυχαία διαδρομή	21,921	23.3%
P1 Μοναδικό	Σ3 Τυχαίες πόλεις	19,046	25.2%
P2 Τυχαία	Σ1 Στατική διαδρομή	26,135	2.7%
P2 Τυχαία	Σ2 Τυχαία διαδρομή	22,318	4.6%
P2 Τυχαία	Σ3 Τυχαίες πόλεις	15,230	11.0%

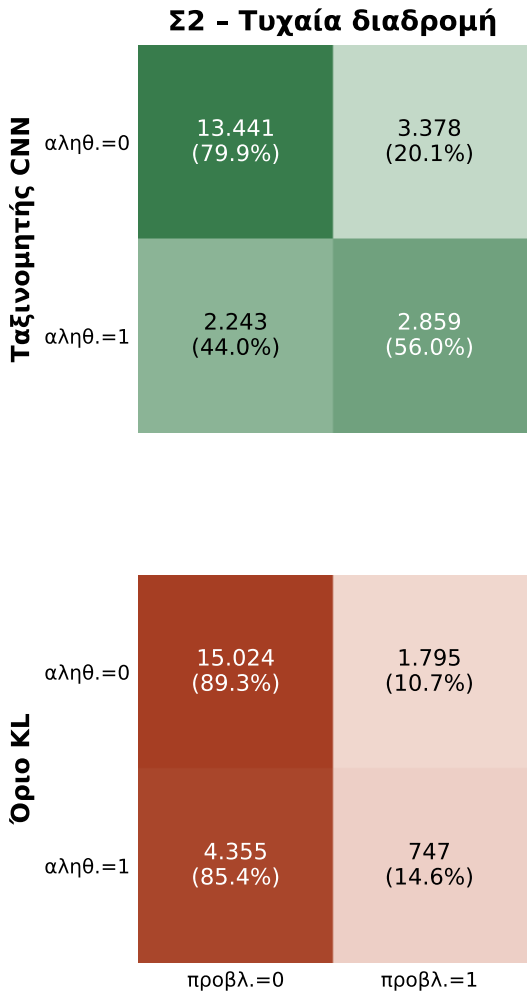
4.5 Αποτελέσματα P1 - Μοναδικό εμπόδιο

Τα Σχήματα 4.11-4.13 παρουσιάζουν τους πίνακες σύγχυσης (με απόλυτα πλήθη και ποσοστά ανά αληθή κλάση), ένα ανά σενάριο. Σε κάθε σχήμα παρατίθενται και οι δύο ανιχνευτές, με τον ταξινομητή CNN επάνω και το όριο KL κάτω, ώστε να συγκρίνονται άμεσα στην ίδια συνθήκη· ο Πίνακας 4.4 συνοψίζει το πλήρες σύνολο των στατιστικών μετρικών.



Σχήμα 4.11: *P1 (Μοναδικό εμπόδιο), σενάριο Σ1: πίνακες σύγχυσης ανά γραμμή-κανονικοποιημένοι, με τον ταξινομητή CNN (επάνω) και το όριο KL (κάτω). Ο CNN συγκεντρώνει ελάχιστα ψευδώς θετικά και ανιχνεύει το εμπόδιο στο κοντινό πεδίο (η ετικέτα του P1 σημαίνει το όχημα από ∼50 m, βλ. κείμενο), ενώ το όριο KL αστοχεί σχεδόν όλες τις ανωμαλίες.*

Στο καλά προσαρμοσμένο σενάριο Σ1 ο ταξινομητής επιτυγχάνει τον υψηλότερο MCC του στη ρύθμιση (0.572), με ακρίβεια σημάνσεων 0.833 και ποσοστό ψευδώς θετικών μόλις 0.026. Η ανάκλησή του έναντι της ετικέτας του P1, ωστόσο, είναι 0.488, και η τιμή αυτή χρειάζεται προσεκτική ανάγνωση: οφείλεται στη διαφορά εμβέλειας των δύο τελεστών ετικέτας και όχι σε αστοχία ανίχνευσης κατά την προσέγγιση. Ο δεσμευμένος στην κλάση τελεστής του P1 σημαίνει το όχημα-εμπόδιο από μακριά, στο Σ1 σημαίνει το 58.6% των καρέ σε απόσταση 30–50 m και το 99.9% εκείνων σε 20–30 m, ενώ ο ταξινομητής, εκπαιδευμένος



Σχήμα 4.12: *P1 (Μοναδικό εμπόδιο), σενάριο Σ2: πίνακες σύγχυσης του ταξινομητή CNN (επάνω) και του ορίου KL (κάτω). Η ακρίβεια σημάνσεων του CNN υποχωρεί σε σχέση με το Σ1, ενώ το όριο KL εξακολουθεί να αστοχεί την πλειονότητα των ανωμαλιών.*

Πίνακας 4.4: *P1 (Μοναδικό εμπόδιο): πλήρεις μετρικές ανά σενάριο, με τους δύο ανιχνευτές παρατιθέμενους δίπλα-δίπλα (CNN = ταξινομητής, KL = όριο ανωμαλίας). Με* ***έντονη*** *γραφή σημειώνεται ο καλύτερος ανιχνευτής ανά μετρική (για FPR/FNR, καλύτερη είναι η χαμηλότερη τιμή).*

Σ1 - Στατική διαδρομή

Μετρική	CNN	KL
Accuracy	**0.8716**	0.7831
Bal. acc.	**0.7308**	0.4974
Precision	**0.8325**	0.1063
Recall	**0.4878**	0.0042
Specificity	0.9739	**0.9907**
FPR	0.0261	**0.0093**
FNR	**0.5122**	0.9958
F1	**0.6152**	0.0080
MCC	**0.5724**	−0.0233

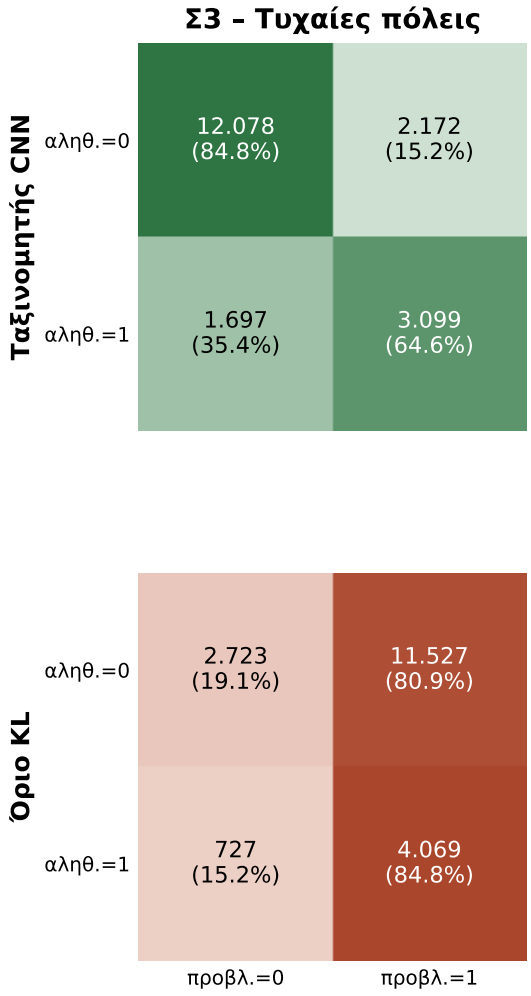
Σ2 - Τυχαία διαδρομή

Μετρική	CNN	KL
Accuracy	**0.7436**	0.7194
Bal. acc.	**0.6798**	0.5198
Precision	**0.4584**	0.2939
Recall	**0.5604**	0.1464
Specificity	0.7992	**0.8933**
FPR	0.2008	**0.1067**
FNR	**0.4396**	0.8536
F1	**0.5043**	0.1954
MCC	**0.3367**	0.0524

Σ3 - Τυχαίες πόλεις

Μετρική	CNN	KL
Accuracy	**0.7969**	0.3566
Bal. acc.	**0.7469**	0.5198
Precision	**0.5879**	0.2609
Recall	0.6462	**0.8484**
Specificity	**0.8476**	0.1911
FPR	**0.1524**	0.8089
FNR	0.3538	**0.1516**
F1	**0.6157**	0.3991
MCC	**0.4790**	0.0445

στην ανεξάρτητη κλάσης ετικέτα του διαδρόμου κίνησης, ενεργοποιείται στο κοντινό πεδίο: η ανά ζώνη απόστασης ανάκλησή του είναι 0.99 στα 10–20 m, 0.31 στα 20–30 m και 0.06 στα 30–50 m. Ο ταξινομητής δηλαδή ανιχνεύει το εμπόδιο όταν αυτό εισέλθει στο κοντινό



Σχήμα 4.13: *P1 (Μοναδικό εμπόδιο), σενάριο Σ3: πίνακες σύγχυσης του ταξινομητή CNN (επάνω) και του ορίου KL (κάτω). Ο CNN διατηρεί τη διαχωριστικότητά του, ενώ το όριο KL σημαίνει τα περισσότερα καρέ ως ανωμαλία (πολύ υψηλά ψευδώς θετικά).*

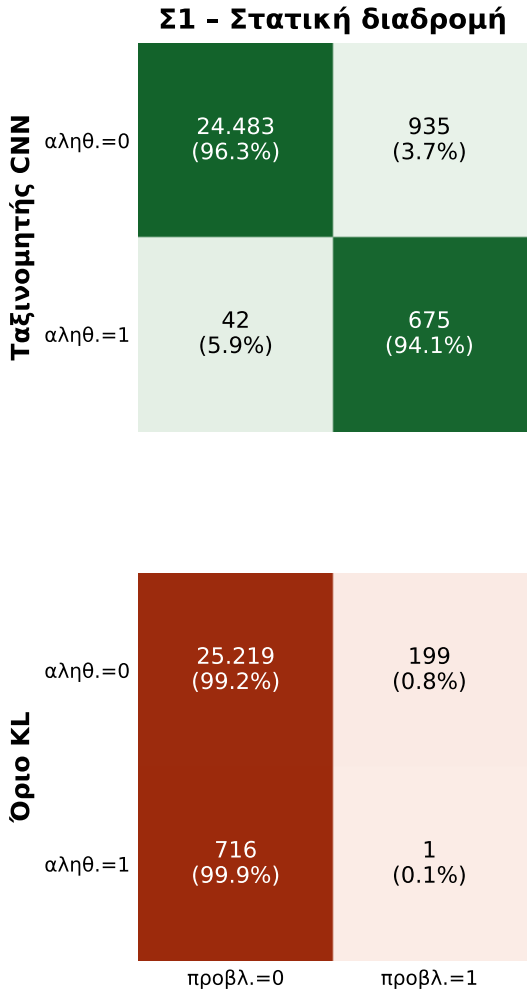
πεδίο του παραθύρου, και οι μετρικές του P1 προσμετρούν επιπλέον ως "αστοχίες" τα καρέ στα οποία ένα απομακρυσμένο όχημα είναι ήδη ορατό στον τελεστή της κλάσης.

Το όριο KL αποκρίνεται στο σενάριο και όχι στο εμπόδιο. Στο Σ1 μένει σχεδόν σιωπηλό (ποσοστό ψευδώς θετικών 0.009) και αστοχεί σχεδόν όλα τα ανώμαλα καρέ (ανάκληση 0.004)· στο Σ2 σημαίνει το 10.7% των κανονικών καρέ· στο Σ3 ενεργοποιείται στα περισσότερα καρέ (ποσοστό ψευδώς θετικών 0.809, ειδικότητα 0.191) και η ολική ακρίβεια πέφτει στο 0.357. Σε όλα τα σενάρια ο MCC του παραμένει το πολύ 0.052, δηλαδή στη γραμμή της τύχης ως προς την ανίχνευση εμποδίου.

4.6 Αποτελέσματα P2 - Τυχαία εμπόδια

Τα Σχήματα 4.14-4.16, καθώς και ο Πίνακας 4.5, παρουσιάζουν τα αντίστοιχα αποτελέσματα για τη ρύθμιση τυχαίων εμποδίων· όπως και στο P1, κάθε σχήμα δείχνει και τους δύο

ανιχνευτές (CNN επάνω, KL κάτω) για ένα σενάριο.



Σχήμα 4.14: *P2 (Τυχαία εμπόδια), σενάριο Σ1: πίνακες σύγχυσης του ταξινομητή CNN (επάνω) και του ορίου KL (κάτω), ανά γραμμή-κανονικοποιημένοι.*

Πίνακας 4.5: *P2 (Τυχαία εμπόδια): πλήρεις μετρικές ανά σενάριο, με τους δύο ανιχνευτές παρατιθέμενους δίπλα-δίπλα (CNN = ταξινομητής, KL = όριο ανωμαλίας). Με* ***έντονη*** *γραφή σημειώνεται ο καλύτερος ανιχνευτής ανά μετρική (για FPR/FNR, καλύτερη είναι η χαμηλότερη τιμή).*

Σ1 - Στατική διαδρομή

Μετρική	CNN	KL
Accuracy	0.9626	**0.9650**
Bal. acc.	**0.9523**	0.4968
Precision	**0.4193**	0.0050
Recall	**0.9414**	0.0014
Specificity	0.9632	**0.9922**
FPR	0.0368	**0.0078**
FNR	**0.0586**	0.9986
F1	**0.5801**	0.0022
MCC	**0.6146**	−0.0121

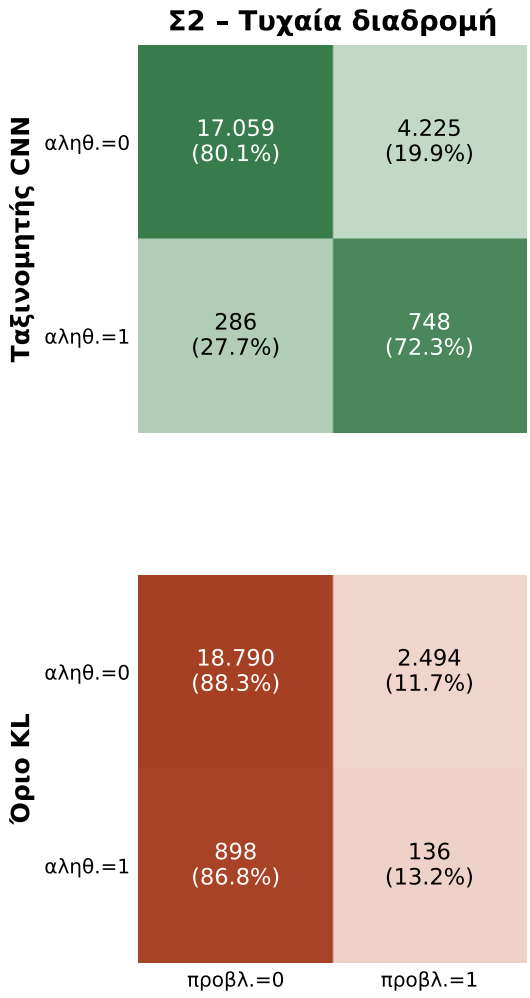
Σ2 - Τυχαία διαδρομή

Μετρική	CNN	KL
Accuracy	0.7979	**0.8480**
Bal. acc.	**0.7624**	0.5072
Precision	**0.1504**	0.0517
Recall	**0.7234**	0.1315
Specificity	0.8015	**0.8828**
FPR	0.1985	**0.1172**
FNR	**0.2766**	0.8685
F1	**0.2490**	0.0742
MCC	**0.2651**	0.0094

Σ3 - Τυχαίες πόλεις

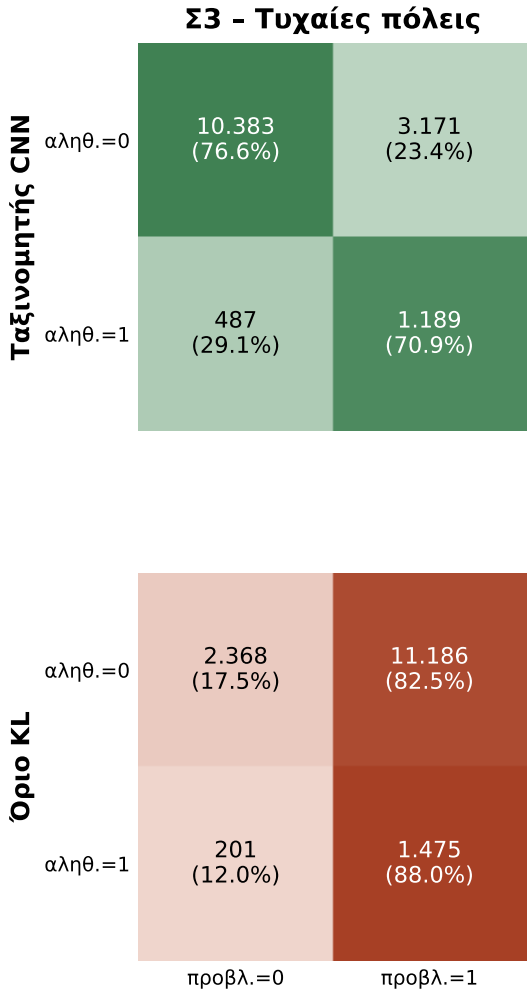
Μετρική	CNN	KL
Accuracy	**0.7598**	0.2523
Bal. acc.	**0.7377**	0.5274
Precision	**0.2727**	0.1165
Recall	0.7094	**0.8801**
Specificity	**0.7660**	0.1747
FPR	**0.2340**	0.8253
FNR	0.2906	**0.1199**
F1	**0.3940**	0.2058
MCC	**0.3292**	0.0458

Στη ρύθμιση P2 η ετικέτα συμπίπτει με τον τελεστή στον οποίο ο ταξινομητής εκπαιδεύτηκε, και η ανάκλησή του είναι αντίστοιχα υψηλότερη από ό,τι στο P1 (0.941, 0.723 και 0.709



Σχήμα 4.15: *P2 (Τυχαία εμπόδια), σενάριο Σ2: πίνακες σύγχυσης του ταξινομητή CNN (επάνω) και του ορίου KL (κάτω). Η ανάκληση του CNN είναι υψηλότερη από ό,τι στο P1, καθώς η ετικέτα είναι ο ανεξάρτητος κλάσης τελεστής στον οποίο ο ταξινομητής εκπαιδεύτηκε, ενώ η ακρίβεια σημάνσεών του είναι χαμηλότερη, στο χαμηλότερο ποσοστό ανωμαλιών της μελέτης.*

στα Σ1–Σ3)· στο Σ1 επιτυγχάνει και τον υψηλότερο MCC της μελέτης (0.615). Η ακρίβεια σημάνσεων είναι, ωστόσο, χαμηλότερη (0.419, 0.150, 0.273): τα ποσοστά ανωμαλιών του P2 είναι τα χαμηλότερα της μελέτης (2.7%–11.0%, Πίνακας 4.3), οπότε ακόμη και ένα μέτριο ποσοστό ψευδώς θετικών κατανέμεται σε πολύ περισσότερα κανονικά καρέ και συμπιέζει την ακρίβεια σημάνσεων. Το όριο KL αναπαράγει το μοτίβο του P1: σχεδόν σιωπηλό στο Σ1, ενεργό στα περισσότερα καρέ στο Σ3. Στο Σ2 παρατηρείται το γνώριμο παράδοξο της μη ισορροπημένης ταξινόμησης: η *ολική* ακρίβεια του ορίου KL (0.848) ξεπερνά εκείνη του ταξινομητή (0.798)· όμως η ισορροπημένη ακρίβεια (0.762 έναντι 0.507) και ο MCC (0.265 έναντι 0.009) δείχνουν ξεκάθαρα ότι ο ταξινομητής είναι ο ουσιαστικά ανώτερος ανιχνευτής, η ολική ακρίβεια απλώς παραπλανά στο ποσοστό ανωμαλιών του 4.6%.

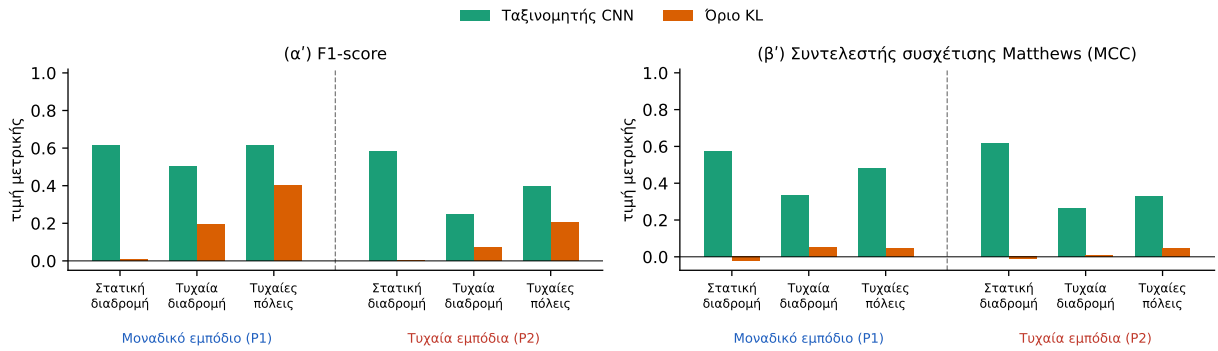


Σχήμα 4.16: *P2 (Τυχαία εμπόδια), σενάριο Σ3: πίνακες σύγχυσης του ταξινομητή CNN (επάνω) και του ορίου KL (κάτω). Το όριο KL σημαίνει σχεδόν τα πάντα ως ανωμαλία, με αποτέλεσμα πολύ υψηλά ψευδώς θετικά.*

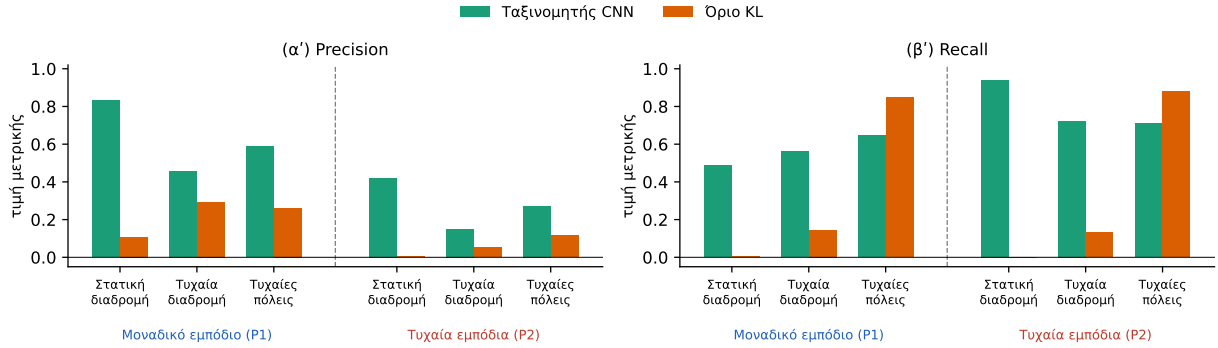
4.7 Συγκριτική ανάλυση των δύο μεθόδων

4.7.1 Συγκεντρωτική σύγκριση

Τα Σχήματα 4.17 και 4.18 συγκεντρώνουν τις βασικές μετρικές και για τις έξι συνθήκες. Το Σχήμα 4.17 επιβεβαιώνει το κεντρικό εύρημα: ο ταξινομητής CNN υπερτερεί του ορίου KL σε κάθε συνθήκη ως προς F_1 και MCC, με το όριο KL να παραμένει σταθερά κοντά στη γραμμή της τύχης (MCC ≈ 0· καλύτερη τιμή οπουδήποτε: 0.052). Το Σχήμα 4.18 αναδεικνύει τον μηχανισμό: ο ταξινομητής διατηρεί υψηλή ανάκληση με ελεγχόμενη ακρίβεια σημάνσεων, ενώ το όριο KL εναλλάσσεται μεταξύ πολύ χαμηλής ανάκλησης (Σ1, Σ2) και σχεδόν μοναδιαίας ανάκλησης με κατάρρευση ειδικότητας (Σ3).



Σχήμα 4.17: *Σύγκριση ταξινομητή CNN έναντι ορίου KL ως προς (α′) F_1 και (β′) MCC, για τις έξι συνθήκες. Ο ταξινομητής υπερτερεί παντού· το όριο KL μένει κοντά στο μηδέν (τύχη) ως προς τον MCC.*



Σχήμα 4.18: *Σύγκριση ως προς (α′) precision και (β′) recall. Η υψηλή ανάκληση του ταξινομητή σε συνδυασμό με ελεγχόμενη ακρίβεια σημάνσεων αντιπαραβάλλεται με τη δι-τροπική (αστοχία/υπερενεργοποίηση) συμπεριφορά του ορίου KL.*

4.7.2 Γιατί λειτουργεί ο ταξινομητής CNN

Ο ταξινομητής τροφοδοτείται ακριβώς με το κατάλληλο σήμα: τη συνένωση του χάρτη δεικτών κλάσεων της πραγματικής σημασιολογικής παρατήρησης με τον αντίστοιχο χάρτη της φανταζόμενης ανακατασκευής εστιασμένα στο οδόστρωμα. Ένα εμπόδιο εμφανίζεται ως τοπική ασυμφωνία κλάσης (μια περιοχή κλάσης πχ. *car*) που υπάρχει στην πραγματική εικόνα αλλά απουσιάζει από την ανακατασκευή, την οποία το prior δεν προέβλεψε. Επειδή το δίκτυο εκπαιδεύεται διακριτικά (discriminatively) πάνω σε αυτή την ασυμφωνία, μαθαίνει να αγνοεί τη γενική μεταβλητότητα σκηνής και να εστιάζει στη διαφορά σχήματος εμποδίου, εξ ου και η υψηλή ανάκλησή του στο κοντινό πεδίο έναντι της ετικέτας του διαδρόμου κίνησης.

4.7.3 Γιατί αποτυγχάνει το όριο KL

Το κατώφλι KL είναι ένα *ολικό* μέτρο "έκπληξης" πάνω σε ολόκληρο τον λανθάνοντα χώρο 32×32. Το εμπόδιο καταλαμβάνει ένα μικρό μόνο τμήμα της σκηνής, οπότε η συνεισφορά του στην ολική KL υπερκαλύπτεται από καθετί άλλο. Ως συνέπεια, ο όρος KL παρακολουθεί την *οικειότητα της σκηνής* και όχι την *παρουσία εμποδίου*:

- Στα καλά προσαρμοσμένα σενάρια (Σ1, Σ2), το μοντέλο σπανίως "εκπλήσσεται", άρα το όριο σχεδόν δεν ενεργοποιείται και αστοχεί την πλειονότητα των εμποδίων (FNR $\approx$ 0.85-1.00).

- Στις τυχαίες πόλεις (Σ3), το μοντέλο εκπλήσσεται *παντού*, άρα το όριο ενεργοποιείται στα περισσότερα καρέ (FPR $\approx$ 0.81-0.83).

Και στις δύο περιπτώσεις ο MCC παραμένει στην τύχη. Η εύλογη ερμηνεία είναι ότι το όριο KL λειτουργεί ως ανιχνευτής *μετατόπισης κατανομής/ανωμαλίας* [38, 7], και ένα μεμονωμένο στατικό εμπόδιο *δεν* συνιστά μετατόπιση κατανομής στο επίπεδο που μπορεί να "δει" το ολικό λανθάνον όριο KL. Το ότι ανιχνεύει επιτυχώς τις αλλαγές πόλης (κάτι που πράττει, και μάλιστα επιθετικά) μπορεί να θεωρηθεί ότι λειτουργεί όπως σχεδιάστηκε.

4.7.4 Η ομαλή υποβάθμιση του ταξινομητή

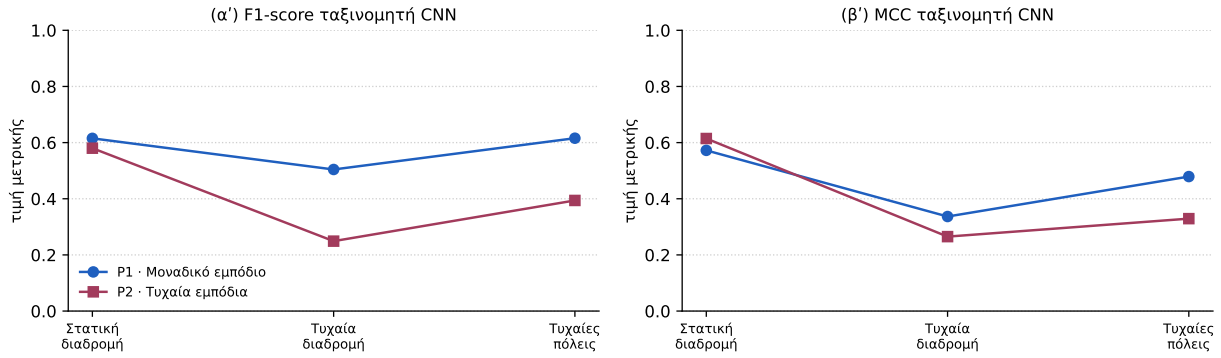
Καθώς η ανακατασκευή αναφοράς υποβαθμίζεται, η ακρίβεια σημάνσεων του ταξινομητή υποχωρεί ενώ η ανάκλησή του έναντι της ετικέτας του διαδρόμου κίνησης παραμένει υψηλή (Σχήμα 4.19): στο P1 η ακρίβεια σημάνσεων πέφτει από 0.833 στο Σ1 σε 0.458 στο Σ2 και 0.588 στο Σ3, και στο P2 από 0.419 σε 0.150 και 0.273, με τα ποσοστά ψευδώς θετικών να ανεβαίνουν από 0.026–0.037 στο Σ1 έως 0.20 στο Σ2 και 0.15–0.23 στο Σ3. Τα επιπλέον ψευδώς θετικά προκύπτουν από εσφαλμένη πρόβλεψη *μη-εμποδιακών* περιοχών, η οποία δημιουργεί διαφορές παρατήρησης-φαντασίας που μοιάζουν με εμπόδιο. Για έναν ελεγκτή ασφαλείας, αυτή είναι η ορθή κατεύθυνση αποτυχίας: προτιμά τον ψευδή συναγερμό (περιττό φρενάρισμα) από την αστοχία ανίχνευσης (πρόσκρουση). Οι απόλυτες τιμές των μετρικών των δύο ρυθμίσεων δεν είναι άμεσα συγκρίσιμες μεταξύ τους, καθώς προέρχονται από διαφορετικούς τελεστές ετικέτας (εμβέλεια $\sim$50 m έναντι $\sim$20 m) και πολύ διαφορετικά ποσοστά ανωμαλιών· η κοινή, συνεπής εικόνα είναι η πτώση της ακρίβειας σημάνσεων με τη δυσκολία του σεναρίου και στις δύο ρυθμίσεις.

4.7.5 Σύνδεση με την εκπαίδευση του μοντέλου κόσμου

Η κατάταξη των ανιχνευτών εξηγείται άμεσα από τις καμπύλες εκπαίδευσης της Ενότητας 4.2. Και οι δύο ανιχνευτές στηρίζονται στην αξιοπιστία της φαντασίας, και η ποιότητα ανακατασκευής του μοντέλου κόσμου είναι ακριβώς αυτό που καταρρέει στο Σ3 (απώλεια παρατήρησης 11$\rightarrow$17, απώλεια μοντέλου κόσμου 15$\rightarrow$25). Επομένως:

- **Σ1:** άριστο μοντέλο κόσμου $\Rightarrow$ ο ταξινομητής στον υψηλότερο MCC και των δύο ρυθμίσεων, το όριο KL σχεδόν σιωπηλό.

- **Σ2:** μοντέλο του οποίου οι απώλειες εξακολουθούσαν να μειώνονται στο τέλος της εκπαίδευσης $\Rightarrow$ η *χαμηλότερη* ακρίβεια σημάνσεων του ταξινομητή και στις δύο ρυθμί-



Σχήμα 4.19: *Ομαλή υποβάθμιση του ταξινομητή CNN ως προς (α′) F_1 και (β′) MCC, καθώς αυξάνεται η δυσκολία του σεναρίου, για τις δύο ρυθμίσεις εμποδίων. Οι δύο καμπύλες βαθμολογούνται έναντι διαφορετικών τελεστών ετικέτας και σε πολύ διαφορετικά ποσοστά ανωμαλιών, οπότε συγκρίνεται η τάση τους και όχι οι απόλυτες τιμές τους.*

σεις, ενώ το όριο KL παραμένει ως επί το πλείστον σιωπηλό· η υποβάθμιση σε επίπεδο διαδρομής πλήττει τον ταξινομητή χωρίς να εγείρει το όριο KL.

- **Σ3:** μη συγκλίνουσα ανακατασκευή ⇒ ακρίβεια σημάνσεων κάτω από το επίπεδο του Σ1 και εκφυλισμός του ορίου KL σε σχεδόν διαρκή συναγερμό.

Η αποσύζευξη ελέγχου-ανακατασκευής (απώλεια ανταμοιβής πτωτική ενώ η ανακατασκευή υποβαθμίζεται) είναι το ενοποιητικό σημείο: ο πράκτορας μπορεί ακόμη να *οδηγεί* στις τυχαίες πόλεις, αλλά η φαντασία του δεν είναι πλέον αρκετά πιστή ώστε να *επιτηρείται*. Με άλλα λόγια, το στρώμα ασφαλείας υποβαθμίζεται ταχύτερα από την πολιτική, διότι η ανίχνευση απαιτεί πιστότητα ανακατασκευής που ο έλεγχος δεν απαιτεί.

4.8 Αξιολόγηση ασφάλειας κλειστού βρόχου

Στο τελευταίο μέρος της αξιολόγησης, τα δύο σήματα ανίχνευσης παύουν να είναι παθητικά: το Σύστημα Παρατήρησης Ανωμαλιών της Ενότητας 3.7 τροφοδοτεί την πέδηση του οχήματος και μετράται ως μηχανισμός ασφαλείας. Για καθεμία από τις έξι συνθήκες εκτελούνται τέσσερις διαμορφώσεις των 100 επεισοδίων: η *βασική γραμμή* (κανένας έλεγχος), το *όριο KL* μόνο του, ο *ταξινομητής CNN* μόνος του, και το *πλήρες σύστημα CNN + KL*. Τα επεισόδια κάθε διαμόρφωσης αντλούνται ανεξάρτητα, με τις διαδρομές, τους τύπους και τις θέσεις των εμποδίων να δειγματοληπτούνται εκ νέου, οπότε οι διαμορφώσεις συγκρίνονται μέσω των 95% διαστημάτων εμπιστοσύνης (Wilson) των ποσοστών σύγκρουσής τους. Οι μετρικές ορίζονται επί της απόστασης οχήματος–εμποδίου, την οποία παρέχει ο προσομοιωτής σε κάθε βήμα, ώστε να είναι ανεξάρτητες από τον τελεστή ετικέτας: ασφαλής στάση που καταλήγει εντός 25 m από το εμπόδιο καταμετράται ως *στάση εμποδίου*, ενώ στάση μακρύτερα από αυτό ως *πρόωρη στάση*. Οι Πίνακες 4.6 και 4.7 συγκεντρώνουν τα αποτελέσματα.

Πίνακας 4.6: *Αξιολόγηση ασφάλειας κλειστού βρόχου, ρύθμιση P1 (μοναδικό όχημα-εμπόδιο), 100 ανεξάρτητα επεισόδια ανά διαμόρφωση. Τα ποσοστά εκφράζονται ως κλάσματα επεισοδίων· στάση εμποδίου είναι η ασφαλής στάση εντός 25 m από το εμπόδιο, πρόωρη στάση η ασφαλής στάση σε μεγαλύτερη απόσταση, ενώ η στήλη "άλλο" συγκεντρώνει εξόδους λωρίδας, απώλειες waypoint, ολοκληρώσεις διαδρομής και λήξεις χρόνου. Περιθώριο στάσης και απόσταση έναρξης πέδησης είναι διάμεσοι επί των στάσεων εμποδίου, η ταχύτητα πρόσκρουσης μέσος όρος επί των συγκρούσεων, ενώ πέδηση > 25 m και συναγερμός KL είναι ποσοστά καρέ.*

Σεν.	Διαμόρφωση	Συγκρούσεις [95% ΔΕ]	Στάση εμπ.	Πρόωρη στάση	Άλλο	Περιθ. (m)	Έναρξη πέδ. (m)	Πρόσκρ. (m/s)	Πέδηση >25 m (%)	Συναγ. KL (%)
Σ1	Βασική	0.98 [0.93, 0.99]	0.00	0.00	0.02	–	–	7.45	0.0	0.0
	Όριο KL	0.98 [0.93, 0.99]	0.00	0.00	0.02	–	–	7.48	0.0	0.0
	CNN	0.00 [0.00, 0.04]	0.91	0.08	0.01	18.1	22.2	–	4.8	0.0
	CNN + KL	0.00 [0.00, 0.04]	0.94	0.06	0.00	18.0	22.1	–	4.4	1.4
Σ2	Βασική	0.84 [0.76, 0.90]	0.00	0.00	0.16	–	–	7.85	0.0	0.0
	Όριο KL	0.58 [0.48, 0.67]	0.05	0.33	0.04	23.0	25.6	7.58	3.9	4.4
	CNN	0.00 [0.00, 0.04]	0.25	0.73	0.02	18.5	22.7	–	25.0	0.0
	CNN + KL	0.00 [0.00, 0.04]	0.28	0.71	0.01	17.6	22.0	–	21.9	8.8
Σ3	Βασική	0.75 [0.66, 0.82]	0.00	0.00	0.25	–	–	7.60	0.0	0.0
	Όριο KL	0.02 [0.01, 0.07]	0.03	0.92	0.03	13.3	16.2	6.05	35.4	37.3
	CNN	0.00 [0.00, 0.04]	0.18	0.69	0.13	18.6	22.7	–	23.2	0.0
	CNN + KL	0.00 [0.00, 0.04]	0.28	0.60	0.12	16.9	21.3	–	15.9	83.6

Πίνακας 4.7: *Αξιολόγηση ασφάλειας κλειστού βρόχου, ρύθμιση P2 (τυχαία εμπόδια), 100 ανεξάρτητα επεισόδια ανά διαμόρφωση. Τα ποσοστά εκφράζονται ως κλάσματα επεισοδίων· στάση εμποδίου είναι η ασφαλής στάση εντός 25 m από το εμπόδιο, πρόωρη στάση η ασφαλής στάση σε μεγαλύτερη απόσταση, ενώ η στήλη "άλλο" συγκεντρώνει εξόδους λωρίδας, απώλειες waypoint, ολοκληρώσεις διαδρομής και λήξεις χρόνου. Περιθώριο στάσης και απόσταση έναρξης πέδησης είναι διάμεσοι επί των στάσεων εμποδίου, η ταχύτητα πρόσκρουσης μέσος όρος επί των συγκρούσεων, ενώ πέδηση > 25 m και συναγερμός KL είναι ποσοστά καρέ.*

Σεν.	Διαμόρφωση	Συγκρούσεις [95% ΔΕ]	Στάση εμπ.	Πρόωρη στάση	Άλλο	Περιθ. (m)	Έναρξη πέδ. (m)	Πρόσκρ. (m/s)	Πέδηση >25 m (%)	Συναγ. KL (%)
Σ1	Βασική	0.96 [0.90, 0.98]	0.00	0.00	0.04	–	–	7.46	0.0	0.0
	Όριο KL	0.93 [0.86, 0.97]	0.01	0.00	0.06	5.0	2.7	7.42	0.0	0.1
	CNN	0.64 [0.54, 0.73]	0.28	0.08	0.00	17.1	21.4	7.36	5.0	0.0
	CNN + KL	0.73 [0.64, 0.81]	0.20	0.06	0.01	17.5	21.0	7.20	5.5	0.7
Σ2	Βασική	0.82 [0.73, 0.88]	0.00	0.00	0.18	–	–	7.75	0.0	0.0
	Όριο KL	0.68 [0.58, 0.76]	0.04	0.26	0.02	17.2	21.6	7.86	3.3	3.7
	CNN	0.30 [0.22, 0.40]	0.15	0.53	0.02	17.3	20.9	7.81	19.8	0.0
	CNN + KL	0.30 [0.22, 0.40]	0.11	0.53	0.06	11.2	14.0	7.43	18.9	10.3
Σ3	Βασική	0.56 [0.46, 0.65]	0.00	0.00	0.44	–	–	7.52	0.0	0.0
	Όριο KL	0.00 [0.00, 0.04]	0.00	0.96	0.04	–	–	–	45.1	45.1
	CNN	0.21 [0.14, 0.30]	0.10	0.57	0.12	16.2	18.6	7.77	18.4	0.0
	CNN + KL	0.14 [0.09, 0.22]	0.09	0.59	0.18	17.9	21.2	7.57	14.6	72.9

4.8.1 Μοναδικό όχημα-εμπόδιο (P1)

Χωρίς εποπτεία, ο πράκτορας συγκρούεται με το σταθμευμένο όχημα σε 98, 84 και 75 από τα 100 επεισόδια στα Σ1, Σ2 και Σ3 αντίστοιχα, με μέση ταχύτητα πρόσκρουσης $\sim$ 7.5 m/s. Με τον ταξινομητή CNN, μόνο του ή στο πλήρες σύστημα, *καμία* σύγκρουση δεν σημειώνεται σε κανένα σενάριο ($[0.00, 0.04]$). Στο Σ1, 91 και 94 επεισόδια καταλήγουν σε στάση εμποδίου, με διάμεσο περιθώριο στάσης 18.1 και 18.0 m μετά από έναρξη πέδησης σε διάμεση απόσταση $\sim$22 m από το εμπόδιο, ενώ η πέδηση μακριά από το εμπόδιο καταλαμβάνει μόλις το 4.8% και 4.4% των καρέ. Καθώς η ανακατασκευή αναφοράς υποβαθμίζεται, οι

αποφευχθείσες συγκρούσεις προέρχονται όλο και περισσότερο από πρόωρες στάσεις: 73 και 71 επεισόδια στο Σ2, 69 και 60 στο Σ3, με πέδηση μακριά από το εμπόδιο στο 22–25% των καρέ στο Σ2 και στο 16–23% στο Σ3. Πρόκειται για τη μορφή που παίρνει σε κλειστό βρόχο η πτώση της ακρίβειας σημάνσεων της Ενότητας 4.7: το κόστος της υποβάθμισης δεν είναι συγκρούσεις αλλά συντηρητικές, άκαιρες στάσεις.

4.8.2 Το όριο KL ως αυτόνομος μηχανισμός

Στο Σ1 το αυτόνομο όριο KL εγείρει συναγερμό στο πολύ 0.1% των καρέ και το ποσοστό συγκρούσεών του συμπίπτει με της βασικής γραμμής εντός των διαστημάτων: όπως προβλέπει η ανάλυση της Ενότητας 4.7, όταν το μοντέλο κόσμου είναι καλά προσαρμοσμένο, ο επόπτης εγκυρότητας δεν προσφέρει καμία προστασία έναντι του μεμονωμένου εμποδίου. Στο Σ3, αντίθετα, ακινητοποιεί το όχημα πρόωρα σε 92 (P1) και 96 (P2) επεισόδια, μετά από 46 και 38 βήματα κατά μέσο όρο, με συναγερμούς που εγείρονται από την άγνωστη πόλη ανεξαρτήτως παρουσίας εμποδίου. Το όριο παρακολουθεί δηλαδή την οικειότητα της σκηνής, που είναι ακριβώς ο ρόλος του ως επόπτη εγκυρότητας, και είναι ακατάλληλο ως αυτόνομος ανιχνευτής εμποδίων.

4.8.3 Ρύθμιση εμπιστοσύνης δύο επιπέδων

Στα Σ1 και Σ2 ο συναγερμός KL είναι ενεργός στο 0.7–1.4% και 8.8–10.3% των καρέ αντίστοιχα, και το πλήρες σύστημα συμπεριφέρεται όπως ο ταξινομητής μόνος του: τα ποσοστά συγκρούσεων ταυτίζονται στο P1 και στο P2/Σ2 και βρίσκονται εντός των αμοιβαίων διαστημάτων στο P1/Σ1. Στο Σ3 ο συναγερμός είναι ενεργός στο 83.6% (P1) και 72.9% (P2) των καρέ και η ρύθμιση εμπιστοσύνης δρα: στο P1 οι πρόωρες στάσεις μειώνονται από 69 σε 60 και οι στάσεις εμποδίου αυξάνονται από 18 σε 28, ενώ στο P2 οι συγκρούσεις μειώνονται από 21 σε 14 ($[0.14, 0.30]$ και $[0.09, 0.22]$). Οι διαφορές αυτές βρίσκονται εντός των διαστημάτων εμπιστοσύνης των 100 ανεξάρτητων επεισοδίων και υποδεικνύουν την *κατεύθυνση* της επίδρασης της ρύθμισης, χωρίς να τη στοιχειοθετούν στατιστικά.

4.8.4 Ανάλυση ανά κλάση εμποδίου (P2)

Τα ποσοστά συγκρούσεων του P2 διαχωρίζονται καθαρά ανά κλάση εμποδίου. Στο Σ1, ο ταξινομητής μόνος του σταματά για 26 από τα 31 οχήματα-εμπόδια και δεν συγκρούεται με κανένα από αυτά, ενώ το πλήρες σύστημα σταματά για 19 από τα 22 με μία μόνο σύγκρουση. Τα στατικά αντικείμενα, όπως κράνη, βαλίτσες οργάνων και ποτιστήρια, είναι μικρά σε σχέση με το παράθυρο 24×24 του διαδρόμου στην ανάλυση 64×64 της αναφοράς: ο επόπτης σταματά για 2 από τα 69 αντικείμενα (μόνο ταξινομητής), και τα μικρά αντικείμενα ευθύνονται για όλες πλην μίας από τις συγκρούσεις του P2/Σ1 των δύο εποπτευόμενων

διαμορφώσεων. Ο περιορισμός είναι της χωρικής ανάλυσης του παραθύρου παρακολούθησης, όχι της αρχιτεκτονικής.

4.9 Σύνοψη ευρημάτων

1. Ο πράκτορας DreamerV3 συγκλίνει πλήρως στη στατική διαδρομή (Σ1) και με διακύμανση στην τυχαία διαδρομή (Σ2), αλλά *δεν* επιτυγχάνει πλήρη σύγκλιση ανακατασκευής στις τυχαίες πόλεις (Σ3), όπου οι απώλειες ανακατασκευής αυξάνονται λόγω μη-στασιμότητας.

2. Ο επιβλεπόμενος ταξινομητής CNN υπερτερεί σταθερά του κατωφλίου KL σε ισορροπημένη ακρίβεια, F_1 και MCC, σε όλες τις έξι συνθήκες.

3. Το κατώφλι KL συμπεριφέρεται ως ανιχνευτής μετατόπισης κατανομής και όχι ως ανιχνευτής εμποδίου: αστοχεί τα εμπόδια όταν το μοντέλο είναι καλά προσαρμοσμένο και υπερενεργοποιείται όταν δεν είναι· ο MCC του παραμένει στην τύχη.

4. Η υποβάθμιση του ταξινομητή είναι "ασφαλής": διατηρεί ανάκληση και θυσιάζει ακρίβεια σημάνσεων, προτιμώντας τον ψευδή συναγερμό από την αστοχία.

5. Η απόδοση και των δύο ανιχνευτών συνδέεται αιτιακά με την πιστότητα ανακατασκευής του μοντέλου κόσμου· το στρώμα ασφαλείας υποβαθμίζεται ταχύτερα από την πολιτική οδήγησης.

6. Σε κλειστό βρόχο, ο επόπτης με τον ταξινομητή (μόνο του ή στο πλήρες σύστημα) εξαλείφει όλες τις συγκρούσεις με το μοναδικό όχημα-εμπόδιο και στα τρία σενάρια (0/100 έναντι 75–98/100 χωρίς εποπτεία), σταματώντας στο Σ1 σε διάμεση απόσταση 18 m από το εμπόδιο.

7. Η υποβάθμιση του στρώματος ασφαλείας εκδηλώνεται σε κλειστό βρόχο ως αυξανόμενο μερίδιο πρόωρων στάσεων στα Σ2–Σ3, δηλαδή ως συντηρητική και όχι επικίνδυνη αστοχία· το όριο KL μόνο του δεν προσφέρει προστασία έναντι του εμποδίου, και η ρύθμιση εμπιστοσύνης δύο επιπέδων δρα μόνο στο Σ3, με επίδραση εντός των διαστημάτων εμπιστοσύνης.

8. Τα μικρά στατικά αντικείμενα της ρύθμισης P2 βρίσκονται κάτω από τη διακριτική ικανότητα του παραθύρου παρακολούθησης 24×24 και ευθύνονται για σχεδόν όλες τις εναπομείνασες συγκρούσεις των εποπτευόμενων διαμορφώσεων.

5

Συμπεράσματα

Η παρούσα εργασία σχεδίασε, υλοποίησε και αξιολόγησε ένα ολοκληρωμένο σύστημα ανίχνευσης ανωμαλιών για πράκτορες αυτόνομης οδήγησης βασισμένους σε μοντέλα κόσμου. Συνοπτικά, αναπτύχθηκε ένα πλήρως λειτουργικό περιβάλλον CARLA-Gymnasium ειδικά διαμορφωμένο για τον αλγόριθμο DreamerV3 [16]· εκπαιδεύτηκε επιτυχώς ένας πράκτορας DreamerV3 ικανός να ολοκληρώνει διαδρομές υπό ονομαστικές συνθήκες· υλοποιήθηκαν και αξιολογήθηκαν σε πραγματικό χρόνο δύο συμπληρωματικές μέθοδοι ανίχνευσης ανωμαλιών, η υλοποίηση μεθόδου του κατωφλίου ανωμαλίας KL [38] εντός του DreamerV3, και ένας επιβλεπόμενος ταξινομητής CNN εκπαιδευμένος σε ζεύγη πραγματικής παρατήρησης-φαντασίας και διεξήχθη μια συστηματική συγκριτική αξιολόγησή τους σε έξι πειραματικές συνθήκες. Τέλος, οι δύο ανιχνευτές ενοποιήθηκαν σε ένα Σύστημα Παρατήρησης Ανωμαλιών δύο επιπέδων, το οποίο υλοποιήθηκε ως επόπτης ασφαλείας κλειστού βρόχου με προοδευτική πέδηση και αξιολογήθηκε έναντι του ανεξέλεγκτου πράκτορα και καθεμιάς από τις συνιστώσες του χωριστά. Το παρόν κεφάλαιο συνθέτει τα συμπεράσματα που απορρέουν από τα αποτελέσματα του Κεφαλαίου 4, αναλύει τη θεμελιώδη διαφορά των δύο ανιχνευτών και αποτιμά τον τρόπο με τον οποίο συνδυάζονται στο ενιαίο σύστημα παρατήρησης ασφαλείας.

5.1 Βασικά συμπεράσματα

Από τη συγκριτική αξιολόγηση στις έξι συνθήκες (2 ρυθμίσεις εμποδίων $\times 3$ σενάρια οδήγησης) και από την αξιολόγηση ασφάλειας κλειστού βρόχου προκύπτουν πέντε κεντρικά συμπεράσματα.

Πρώτον, ο επιβλεπόμενος ταξινομητής CNN αποτελεί έναν ουσιαστικά λειτουργικό ανιχνευτή εμποδίων: υπερτερεί σταθερά του κατωφλίου KL ως προς την ισορροπημένη ακρίβεια, το F_1 και τον συντελεστή MCC σε όλες τις συνθήκες ανεξαιρέτως, με απόδοση που κυμαίνεται από σχεδόν τέλεια (Σ1) έως αξιοποιήσιμη ακόμη και στις δυσμενέστερες συνθήκες. Αντιθέτως, ο MCC του κατωφλίου KL παραμένει ουσιαστικά στη γραμμή της τύχης παντού, γεγονός που υποδηλώνει ότι ο συγκεκριμένος ανιχνευτής δεν διαχωρίζει την παρουσία εμποδίου καλύτερα από μια τυχαία απόφαση.

Δεύτερον, η αποτυχία του κατωφλίου KL *δεν* είναι αποτυχία υλοποίησης αλλά αποτέλεσμα αναντιστοιχίας ανάμεσα στο σήμα που μετρά και στο έργο ως προς το οποίο αξιολογείται. Όπως αναλύεται στην Ενότητα 5.2, το κατώφλι KL μετρά την ολική "οικειότητα" της σκηνής και όχι την τοπική παρουσία ενός εμποδίου. Το γεγονός ότι ανιχνεύει επιθετικά την αλλαγή πόλης στο σενάριο Σ3, μια πραγματική μετατόπιση κατανομής, επιβεβαιώνει ότι λειτουργεί όπως σχεδιάστηκε, απλώς ως ανιχνευτής ανωμαλίας/μετατόπισης κατανομής και όχι ως ανιχνευτής εμποδίου.

Τρίτον, η υποβάθμιση του ταξινομητή CNN υπό αυξανόμενη δυσκολία είναι *ασφαλής* κατά κατεύθυνση: καθώς τα σενάρια δυσκολεύουν, ο ταξινομητής διατηρεί υψηλή ανάκληση και θυσιάζει ακρίβεια σημάνσεων, δηλαδή προτιμά τον ψευδή συναγερμό (περιττό φρενάρισμα) από την αστοχία ανίχνευσης (πρόσκρουση). Για έναν ελεγκτή ασφαλείας, αυτή είναι ακριβώς η επιθυμητή κατεύθυνση αποτυχίας.

Τέταρτον, και ενοποιητικά, η απόδοση *και των δύο* ανιχνευτών συνδέεται αιτιακά με την πιστότητα ανακατασκευής του μοντέλου κόσμου. Αμφότεροι στηρίζονται στην αξιοπιστία της "φαντασίας" του DreamerV3, και ακριβώς αυτή η πιστότητα καταρρέει στο σενάριο των τυχαίων πόλεων (Σ3). Η αποσύζευξη ελέγχου και ανακατασκευής που παρατηρήθηκε εκεί, ο πράκτορας εξακολουθεί να οδηγεί ενώ η ανακατασκευή υποβαθμίζεται, οδηγεί στο σημαντικότερο ποιοτικό συμπέρασμα της εργασίας: *το στρώμα ασφαλείας υποβαθμίζεται ταχύτερα από την πολιτική οδήγησης*, διότι η ανίχνευση απαιτεί πιστότητα ανακατασκευής που ο έλεγχος δεν απαιτεί. Η παρατήρηση αυτή έχει άμεση πρακτική σημασία: ένας πράκτορας μπορεί να δίνει την εντύπωση ότι "οδηγεί καλά" σε άγνωστο περιβάλλον, ενώ ταυτόχρονα έχει χάσει την ικανότητα να επιτηρεί τον εαυτό του.

Πέμπτον, σε κλειστό βρόχο ο επόπτης που οδηγείται από τον ταξινομητή εξαλείφει όλες τις συγκρούσεις με το μοναδικό όχημα-εμπόδιο και στα τρία σενάρια (0/100 έναντι 75–98/100 χωρίς εποπτεία), σταματώντας στο καλά προσαρμοσμένο σενάριο σε διάμεση απόσταση 18 m από το εμπόδιο. Η υποβάθμιση του στρώματος ασφαλείας υπό μετατόπιση κατανομής εκδηλώνεται ως αυξανόμενο μερίδιο πρόωρων στάσεων και όχι ως συγκρούσεις: ο μηχανισμός

αστοχεί προς τη *συντηρητική* και όχι προς την επικίνδυνη κατεύθυνση.

5.2 Δύο ανιχνευτές, δύο διαφορετικά σήματα

Το κεντρικό εννοιολογικό συμπέρασμα της εργασίας είναι ότι ο ταξινομητής CNN και το κατώφλι KL *δεν* αποτελούν δύο εναλλακτικές λύσεις στο ίδιο πρόβλημα· μετρούν δύο θεμελιωδώς διαφορετικά πράγματα. Η ισχυρή υπεροχή του ταξινομητή στις μετρικές δεν πρέπει, επομένως, να ερμηνευθεί ως "νίκη" της μιας μεθόδου έναντι της άλλης, αλλά ως ένδειξη ότι τα δύο σήματα είναι συμπληρωματικά.

Ο ταξινομητής CNN λειτουργεί ως *τοπικός, χωρικός* ανιχνευτής. Τροφοδοτείται με τη συνένωση του χάρτη δεικτών κλάσεων της πραγματικής παρατήρησης και του αντίστοιχου χάρτη της φανταζόμενης ανακατασκευής, και εκπαιδεύεται διακριτικά (discriminatively) ώστε να εντοπίζει τοπικές ασυμφωνίες κλάσης, μια περιοχή κλάσης (π.χ. *car*) που υπάρχει στην πραγματική εικόνα αλλά απουσιάζει από ό,τι προέβλεψε το μοντέλο. Με άλλα λόγια, απαντά στο ερώτημα: *"υπάρχει ένα μη αναμενόμενο αντικείμενο στην πορεία μου;"* Επειδή το σήμα του είναι χωρικά εντοπισμένο, ο ταξινομητής αγνοεί τη γενική μεταβλητότητα της σκηνής και εστιάζει στο εμπόδιο, εξ ου και η υψηλή του ανάκληση.

Το κατώφλι KL, αντίθετα, λειτουργεί ως *ολικός, κατανομικός* ανιχνευτής. Συνοψίζει την απόκλιση μεταξύ prior και posterior σε ολόκληρο τον λανθάνοντα χώρο 32×32 σε έναν μόνο βαθμωτό αριθμό "έκπληξης". Απαντά, συνεπώς, σε ένα εντελώς διαφορετικό ερώτημα: *"βρίσκομαι σε ένα περιβάλλον που το μοντέλο μου κατανοεί;"* Ένα μεμονωμένο εμπόδιο καταλαμβάνει ελάχιστο τμήμα της σκηνής και η συνεισφορά του στην ολική KL υπερκαλύπτεται από καθετί άλλο· μια αλλαγή πόλης όμως, μετατοπίζει ολόκληρη την κατανομή και ανιχνεύεται άμεσα.

Ο Πίνακας 5.1 συνοψίζει αυτή την αντιπαραβολή. Η κρίσιμη παρατήρηση είναι ότι οι δύο ανιχνευτές *αποτυγχάνουν σε ακριβώς αντίθετα καθεστώτα*: ο ταξινομητής είναι στη βέλτιστη απόδοσή του ακριβώς όταν το μοντέλο κόσμου είναι καλά προσαρμοσμένο (Σ1, Σ2), δηλαδή ακριβώς όταν το κατώφλι KL σιωπά, ενώ το κατώφλι KL ενεργοποιείται μαζικά ακριβώς όταν το μοντέλο κόσμου έχει αστοχήσει (Σ3), δηλαδή ακριβώς όταν αρχίζει να καταρρέει η ακρίβεια σημάνσεων του ταξινομητή. Αυτή η αντι-συσχέτιση είναι το θεμέλιο πάνω στο οποίο οικοδομείται η πρόταση ενοποίησης της επόμενης ενότητας.

5.3 Προς ένα ενοποιημένο Σύστημα Παρατήρησης Ανωμαλιών

Το σημαντικότερο επακόλουθο της παραπάνω ανάλυσης είναι ότι οι δύο ανιχνευτές δεν θα έπρεπε να αντιμετωπίζονται ως ανταγωνιστικοί, αλλά να συνδυάζονται σε ένα ενιαίο *Σύστημα Παρατήρησης Ανωμαλιών* (Anomaly Observation System). Η αντι-συσχέτιση των

Πίνακας 5.1: *Εννοιολογική αντιπαραβολή των δύο ανιχνευτών. Οι δύο μέθοδοι μετρούν διαφορετικά σήματα και αποτυγχάνουν σε αντίθετα καθεστώτα.*

Ιδιότητα	**Ταξινομητής CNN**	**Κατώφλι KL**
Φύση σήματος	Τοπικό, χωρικό	Ολικό, κατανομικό
Τι ανιχνεύει	Παρουσία εμποδίου	Μετατόπιση κατανομής / ανωμαλία
Ερώτημα	"Υπάρχει εμπόδιο στην πορεία;"	"Κατανοώ αυτό το περιβάλλον;"
Βέλτιστο καθεστώς	Καλά προσαρμοσμένο μοντέλο (Σ1, Σ2)	Απότομη αλλαγή σκηνής (Σ3)
Τρόπος αστοχίας	Αύξηση ψευδώς θετικών σε άγνωστες πόλεις	Αστοχία εμποδίων ή διαρκής συναγερμός
Εξάρτηση από το μοντέλο κόσμου	Έμμεση (μόνο για την ανακατασκευή αναφοράς)	Άμεση (εγγενώς δεμένο στο RSSM)

καθεστώτων αστοχίας τους τους καθιστά ιδανικούς συνεργάτες σε μια αρχιτεκτονική δύο επιπέδων, την οποία η παρούσα εργασία δεν περιορίστηκε να προτείνει, αλλά υλοποίησε και αξιολόγησε σε κλειστό βρόχο (Ενότητες 3.7 και 4.8).

Στην προτεινόμενη αρχιτεκτονική, ο ταξινομητής CNN λειτουργεί ως ο *πρωτεύων ανιχνευτής εμποδίων* κατά τη λειτουργία εντός κατανομής, παρέχοντας χωρικά εστιασμένη, υψηλής ανάκλησης ανίχνευση. Το κατώφλι KL λειτουργεί ως *επόπτης εγκυρότητας του μοντέλου* (model-validity monitor): παρακολουθεί συνεχώς αν ο πράκτορας βρίσκεται σε περιβάλλον που το μοντέλο κόσμου κατανοεί. Ο ρόλος του δεν είναι να ανιχνεύσει το εμπόδιο, αλλά να σηματοδοτήσει *πότε ο ίδιος ο ταξινομητής παύει να είναι αξιόπιστος*. Πράγματι, τα αποτελέσματα του Κεφαλαίου 4 δείχνουν ότι η ακρίβεια σημάνσεων του ταξινομητή καταρρέει ακριβώς στις τυχαίες πόλεις, όπου το κατώφλι KL υπερενεργοποιείται. Στην υλοποίηση, ένα παρατεταμένο ολικό σήμα KL υποβαθμίζει την εμπιστοσύνη στις σημάνσεις του ταξινομητή, απαιτώντας περισσότερες διαδοχικές σημάνσεις πριν από την έναρξη της προοδευτικής πέδησης (Ενότητα 3.7).

Με αυτόν τον τρόπο, το σύστημα καλύπτει *δύο ορθογώνιους άξονες ασφάλειας*: την τοπική παρουσία αντικειμένου (μέσω του CNN) και την ολική εγκυρότητα του μοντέλου κόσμου (μέσω του KL). Κανένας από τους δύο ανιχνευτές μόνος του δεν παρέχει αυτή την κάλυψη, ο ταξινομητής δεν "γνωρίζει" πότε η ανακατασκευή αναφοράς του είναι αναξιόπιστη, ενώ το κατώφλι KL δεν "βλέπει" το μεμονωμένο εμπόδιο. Η συνένωσή τους μετατρέπει την κύρια αδυναμία της κάθε μεθόδου στη δύναμη της άλλης. Η αξιολόγηση κλειστού βρόχου επιβεβαίωσε αυτόν τον καταμερισμό ρόλων: ο ταξινομητής μόνος του εξαλείφει τις συγκρούσεις με το όχημα-εμπόδιο, το όριο KL μόνο του είτε αδρανεί (Σ1) είτε ακινητοποιεί το όχημα μέσα σε λίγα δευτερόλεπτα ανεξαρτήτως εμποδίου (Σ3), και η ρύθμιση εμπιστοσύνης του πλήρους συστήματος δρα μόνο εκεί όπου εγείρεται ο συναγερμός (Σ3), με επίδραση προς την αναμενόμενη κατεύθυνση, αν και εντός των διαστημάτων εμπιστοσύνης των 100 επεισοδίων· η στατιστική της στοιχειοθέτηση απαιτεί μεγαλύτερο δείγμα (Ενότητα 5.7).

5.4 Διαστρωμάτωση και μεταφερσιμότητα των ανιχνευτών

Μια περαιτέρω συνέπεια της θεμελιώδους διαφοράς των δύο μεθόδων αφορά τη *μεταφερσιμότητά* τους σε άλλες αρχιτεκτονικές πρακτόρων. Το κατώφλι KL είναι εγγενώς δεμένο στο αναδρομικό μοντέλο χώρου καταστάσεων (RSSM) του DreamerV3: χωρίς prior και posterior κατανομές δεν ορίζεται καν, και επομένως μπορεί να χρησιμοποιηθεί *μόνο* με πράκτορες που διαθέτουν ρητό μοντέλο κόσμου.

Ο ταξινομητής CNN, αντίθετα, είναι αρχιτεκτονικά αποσυνδεδεμένος από τα εσωτερικά του αλγορίθμου ελέγχου: αποτελεί ένα αυτόνομο επιβλεπόμενο άρθρωμα που λειτουργεί επί ζευγών εικόνων (πραγματική παρατήρηση έναντι αναμενόμενης σκηνής). Αυτό σημαίνει ότι το ίδιο παράδειγμα ανίχνευσης μπορεί, κατ' αρχήν, να συνοδεύσει και έναν πράκτορα *χωρίς* μοντέλο κόσμου, για παράδειγμα έναν οδηγό εκπαιδευμένο με PPO [31], εφόσον παρέχεται μια αναπαράσταση αναφοράς της αναμενόμενης σκηνής (π.χ. από ένα ξεχωριστά εκπαιδευμένο προβλεπτικό μοντέλο που λειτουργεί παράλληλα με την πολιτική). Η διαστρωμάτωση αυτή είναι σημαντική πρακτικά: ο ταξινομητής δεν περιορίζεται στο οικοσύστημα των μοντέλων κόσμου, αλλά αποτελεί έναν δυνητικά γενικό μηχανισμό επιτήρησης ασφαλείας για ένα ευρύ φάσμα αυτόνομων πρακτόρων.

5.5 Παρατήρηση επί της λανθάνουσας ανίχνευσης

Ένα επιπλέον πρακτικό χαρακτηριστικό του ταξινομητή CNN αφορά την εμβέλεια και την ταχύτητα της απόκρισής του. Η ταξινόμηση εκτελείται *ανά χρονικό βήμα*, και η ανά ζώνη απόστασης ανάλυση της Ενότητας 4.5 δείχνει ότι ο ανιχνευτής λειτουργεί στο *κοντινό πεδίο* του παραθύρου παρακολούθησης: η ανάκλησή του είναι 0.99 στη ζώνη 10–20 m και πέφτει απότομα σε μεγαλύτερες αποστάσεις, στις οποίες το εμπόδιο δεν έχει ακόμη εισέλθει ουσιαστικά στον διάδρομο κίνησης. Σε κλειστό βρόχο, η απόκριση αυτή αποδεικνύεται έγκαιρη για τις συνθήκες της μελέτης: με ταχύτητα πλεύσης 8 m/s, η πέδηση ξεκινά σε διάμεση απόσταση $\sim$22 m από το εμπόδιο και το όχημα ακινητοποιείται με διάμεσο περιθώριο 18 m (Ενότητα 4.8). Η έγκαιρη απόκριση είναι, επομένως, ιδιότητα του συνδυασμού ανιχνευτή και προοδευτικής πέδησης στο κοντινό πεδίο, και όχι ισχυρισμός ανίχνευσης μεγάλης εμβέλειας.

5.6 Περιορισμοί

Τα συμπεράσματα της εργασίας θα πρέπει να ερμηνεύονται υπό το πρίσμα των ακόλουθων περιορισμών.

- **Φύση των εμποδίων.** Η αξιολόγηση περιορίστηκε σε *στατικά* εμπόδια. Η συμπεριφορά αμφότερων των ανιχνευτών έναντι δυναμικών εμποδίων (κινούμενα οχήματα,

πεζοί που διασχίζουν) παραμένει ανοιχτό ερώτημα.

- **Περιβάλλον προσομοίωσης.** Τόσο η παρατήρηση όσο και η αλήθεια βάσης προέρχονται από τη σημασιολογική τμηματοποίηση του CARLA, η οποία είναι εξ ορισμού καθαρή και χωρίς θόρυβο αισθητήρα. Το χάσμα προσομοίωσης-προς- πραγματικότητα (sim-to-real) δεν εξετάστηκε, και τα αποτελέσματα δεν θα πρέπει να εκληφθούν ως άμεσα μεταφέρσιμα σε πραγματικό υλικό.

- **Μη σύγκλιση στο Σ3.** Η αξιολόγηση στο σενάριο των τυχαίων πόλεων πραγματοποιείται επί ενός μοντέλου κόσμου του οποίου η ανακατασκευή δεν είχε συγκλίνει. Συνεπώς, οι μετρικές του Σ3 χαρακτηρίζουν τη συμπεριφορά των ανιχνευτών υπό ένα *ελλιπώς εκπαιδευμένο* μοντέλο, και όχι το εγγενές όριο της κάθε μεθόδου.

- **Μέγεθος εμποδίων και παράθυρο παρακολούθησης.** Το παράθυρο 24×24 επί της αναφοράς ανάλυσης 64×64 διακρίνει εμπόδια μεγέθους οχήματος· τα μικρά στατικά αντικείμενα της ρύθμισης P2 ανιχνεύονται σε ελάχιστα επεισόδια και ευθύνονται για σχεδόν όλες τις εναπομείνασες συγκρούσεις των εποπτευόμενων διαμορφώσεων (Ενότητα 4.8).

- **Πρωτόκολλο τοποθέτησης.** Τα εμπόδια τοποθετούνται σε ευθεία προσέγγιση (Ενότητα 3.1.4), ώστε να είναι κατ' αρχήν ορατά πριν από την προσέγγιση· εμπόδια αμέσως μετά από στροφές, τα οποία είναι εκ κατασκευής μη αποφεύξιμα στην ταχύτητα πλεύσης του πράκτορα, δεν αξιολογούνται.

- **Ανεξάρτητα δείγματα ανά διαμόρφωση.** Τα επεισόδια κάθε διαμόρφωσης του κλειστού βρόχου αντλούνται ανεξάρτητα, χωρίς κοινό σπόρο τυχαιότητας, ώστε η αξιολόγηση να καλύπτει τυχαίες διαδρομές και τυχαία γεγονότα και όχι μία αναπαραγώγιμη ακολουθία. Οι διαμορφώσεις συγκρίνονται επομένως μέσω διαστημάτων εμπιστοσύνης, και μικρές διαφορές, όπως η επίδραση της ρύθμισης εμπιστοσύνης στο Σ3, δεν στοιχειοθετούνται στατιστικά με 100 επεισόδια.

5.7 Μελλοντικές επεκτάσεις

Πέρα από την άρση των παραπάνω περιορισμών, η εργασία αναδεικνύει αρκετές συγκεκριμένες κατευθύνσεις μελλοντικής έρευνας.

1. **Στατιστική στοιχειοθέτηση της ρύθμισης εμπιστοσύνης.** Η αρχιτεκτονική δύο επιπέδων υλοποιήθηκε και αξιολογήθηκε στην παρούσα εργασία· η επίδραση της ρύθμισης εμπιστοσύνης στο Σ3, ωστόσο, παραμένει εντός των διαστημάτων εμπιστοσύνης των 100 επεισοδίων. Η επανάληψη της σύγκρισης πλήρους συστήματος έναντι μόνου ταξινομητή με σημαντικά μεγαλύτερο δείγμα ή με ζευγαρωμένους σπόρους

τυχαιότητας (ίδιες διαδρομές και εμπόδια σε όλες τις διαμορφώσεις) θα επέτρεπε τη στατιστική στοιχειοθέτηση ή απόρριψη του οφέλους της.

2. **Αξιολόγηση του ταξινομητή πέραν της ρύθμισης εκπαίδευσής του και βελτίωση της χωρικής ανάλυσης.** Η κάλυψη των μικρών εμποδίων, τα οποία βρίσκονται κάτω από τη διακριτική ικανότητα του παραθύρου 24×24, απαιτεί είτε μεγαλύτερη ανάλυση αναφοράς είτε προσαρμοστικό παράθυρο παρακολούθησης.

3. **Δυναμικά εμπόδια, sim-to-real και στατιστική επικύρωση.** Η επέκταση σε κινούμενα εμπόδια, η δοκιμή σε πιο ρεαλιστικές αισθητηριακές συνθήκες και η επανάληψη των πειραμάτων με πολλαπλές οδηγικές συνθήκες θα ενίσχυαν την εξωτερική εγκυρότητα των συμπερασμάτων.

5.8 Επίλογος

Η παρούσα εργασία ξεκίνησε από το ερώτημα του πώς θα έπρεπε ένας αυτόνομος πράκτορας οδήγησης να αντιδρά όταν έρχεται αντιμέτωπος με καταστάσεις εκτός του συνόλου εκπαίδευσής του. Η απάντηση που προέκυψε δεν είναι η ανάδειξη ενός "νικητή" ανιχνευτή, αλλά μια πιο διαφωτιστική διαπίστωση: ότι η ανίχνευση τοπικών εμποδίων και η ανίχνευση ολικής μετατόπισης κατανομής είναι δύο διαφορετικά προβλήματα, που απαιτούν διαφορετικά εργαλεία και αποτυγχάνουν υπό αντίθετες συνθήκες. Πέρα από τη διαπίστωση αυτή, η εργασία παρέδωσε απτά αποτελέσματα: ένα πλήρως λειτουργικό περιβάλλον CARLA-Gymnasium και έναν εκπαιδευμένο πράκτορα DreamerV3· δύο ανιχνευτές με σαφώς χαρτογραφημένες ιδιότητες, έναν ταξινομητή εμποδίων κοντινού πεδίου με ασφαλή κατά κατεύθυνση υποβάθμιση και μια υλοποίηση σε πραγματικό χρόνο της μεθόδου του θεωρητικά θεμελιωμένου κατωφλίου KL εντός του DreamerV3, του οποίου το πεδίο εφαρμογής προσδιορίστηκε με ακρίβεια ως ανίχνευση μετατόπισης κατανομής· και ένα Σύστημα Παρατήρησης Ανωμαλιών δύο επιπέδων, υλοποιημένο ως επόπτης ασφαλείας κλειστού βρόχου, το οποίο εξαλείφει όλες τις συγκρούσεις με το μοναδικό όχημα-εμπόδιο και στα τρία σενάρια, σταματώντας στο καλά προσαρμοσμένο σενάριο 18 m πριν από το εμπόδιο, και αστοχεί, όπου αστοχεί, προς τη συντηρητική κατεύθυνση. Το σύστημα αυτό είναι ικανό όχι μόνο να βλέπει τον κόσμο, αλλά και να γνωρίζει πότε έχει πάψει να τον κατανοεί, και να σταματά το όχημα όσο αυτό ακόμη προλαβαίνει.

Βιβλιογραφία

[1] Siddharth Ancha, Yaadhav Raaj, Peiyun Hu, Srinivasa G. Narasimhan, and David Held. Active perception using light curtains for autonomous driving. In *European Conference on Computer Vision (ECCV)*, 2020. 6

[2] Mayur R. Bachute and Javed M. Subhedar. Autonomous driving architectures: Insights of machine learning and deep learning algorithms. *Machine Learning with Applications*, 6:100164, 2021. 7

[3] Ruzena Bajcsy. Active perception. *Proceedings of the IEEE*, 76(8):966–1005, 1988. 5

[4] Ruzena Bajcsy, Yiannis Aloimonos, and John K. Tsotsos. Revisiting active perception. *Autonomous Robots*, 42:177–196, 2018. 6

[5] Richard Bellman. *Dynamic Programming*. Princeton University Press, 1957. 11, 12

[6] Federico Belotti et al. SheepRL: Distributed reinforcement learning accelerated by lightning fabric, 2023. GitHub repository, Eclectic-Sheep. 29

[7] Daniel Bogdoll, Maximilian Nitsche, and J. Marius Zöllner. Anomaly detection in autonomous driving: A survey. *arXiv preprint arXiv:2204.07974*, 2022. 1, 7, 21, 22, 57

[8] Greg Brockman, Vicki Cheung, Ludwig Pettersson, Jonas Schneider, John Schulman, Jie Tang, and Wojciech Zaremba. OpenAI gym. *arXiv preprint arXiv:1606.01540*, 2016. 20

[9] Marius Cordts, Mohamed Omran, Sebastian Ramos, Timo Rehfeld, Markus Enzweiler, Rodrigo Benenson, Uwe Franke, Stefan Roth, and Bernt Schiele. The Cityscapes dataset for semantic urban scene understanding. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 3213–3223, 2016. 9, 21

[10] Mike Daily, Swarup Medasani, Reinhold Behringer, and Mohan Trivedi. Self-driving cars. *Computer*, 50(12):18–23, 2017. 8

[11] Alexey Dosovitskiy, Germán Ros, Felipe Codevilla, Antonio López, and Vladlen Koltun. CARLA: An open urban driving simulator. In *Proceedings of the 1st Annual Conference on Robot Learning (CoRL)*, pages 1–16, 2017. 10

[12] Farama Foundation. Gymnasium documentation: Environment API. https://gymnasium.farama.org/api/env/, 2026. Accessed: 2026-03-20. 26

[13] Dechen Gao, Shuangyu Cai, Hanchu Zhou, Hang Wang, Iman Soltani, and Junshan Zhang. CarDreamer: Open-source learning platform for world model based autonomous driving. *arXiv preprint arXiv:2405.09111*, 2024. arXiv:2405.09111v2. 10, 19, 20

[14] Abhishek Gupta, Alagan Anpalagan, Ling Guan, and Ahmed Shaharyar Khwaja. Deep learning for object detection and scene perception in self-driving cars: Survey, challenges, and open issues. *Array*, 10:100057, 2021. 7, 9

[15] David Ha and Jürgen Schmidhuber. Recurrent world models facilitate policy evolution. In *Advances in Neural Information Processing Systems (NeurIPS)*, pages 2455–2467, 2018. 15

[16] Danijar Hafner, Jurgis Pasukonis, Jimmy Ba, and Timothy Lillicrap. Mastering diverse domains through world models. *arXiv preprint arXiv:2301.04104*, 2024. arXiv:2301.04104v2. 2, 15, 16, 18, 29, 41, 62

[17] Danijar Hafner, Jurgis Pasukonis, Jimmy Ba, and Timothy Lillicrap. Mastering diverse control tasks through world models. *Nature*, 640(8059):647–653, 2025. 15

[18] Kaiming He, Xiangyu Zhang, Shaoqing Ren, and Jian Sun. Deep residual learning for image recognition. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 770–778, 2016. 24

[19] Sergey Ioffe and Christian Szegedy. Batch normalization: Accelerating deep network training by reducing internal covariate shift. In *Proceedings of the 32nd International Conference on Machine Learning (ICML)*, pages 448–456, 2015. 24, 36

[20] Leslie Pack Kaelbling, Michael L. Littman, and Anthony R. Cassandra. Planning and acting in partially observable stochastic domains. *Artificial Intelligence*, 101(1–2):99–134, 1998. 13, 16, 20

[21] Diederik P. Kingma and Max Welling. Auto-encoding variational bayes. *arXiv preprint arXiv:1312.6114*, 2013. 14

[22] Venkata Satya Rahul Kosuru and Ashwin Kavasseri Venkitaraman. Advancements and challenges in achieving fully autonomous self-driving vehicles. *World Journal of Advanced Research and Reviews*, 18(01):161–167, 2023. iii, v, 1, 7

[23] Solomon Kullback and Richard A. Leibler. On information and sufficiency. *The Annals of Mathematical Statistics*, 22(1):79–86, 1951. 13, 14

[24] Yann LeCun, Léon Bottou, Yoshua Bengio, and Patrick Haffner. Gradient-based learning applied to document recognition. *Proceedings of the IEEE*, 86(11):2278–2324, 1998. 24, 36

[25] Tianchuang Meng, Jin Huang, Chee-Meng Chew, Diange Yang, and Zhihua Zhong. Configuration and design schemes of environmental sensing and vehicle computing systems for automated driving: A review. *IEEE Sensors Journal*, 23(14):15305–15322, 2023. 7, 8

[26] Vasilii Mosin, Miroslaw Staron, Yury Tarakanov, and Darko Durisic. Comparing autoencoder-based approaches for anomaly detection in highway driving scenario images. *SN Applied Sciences*, 4:259, 2022. 21

[27] Julia Nitsch, Masha Itkina, Ransalu Senanayake, Juan Nieto, Max Schmidt, Roland Siegwart, Mykel J. Kochenderfer, and Cesar Cadena. Out-of-distribution detection for automotive perception. *arXiv preprint arXiv:2011.01413*, 2021. arXiv:2011.01413v2. 7, 21, 22

[28] Martin L. Puterman. *Markov Decision Processes: Discrete Stochastic Dynamic Programming*. John Wiley & Sons, 1994. 11

[29] Joseph Redmon, Santosh Divvala, Ross Girshick, and Ali Farhadi. You only look once: Unified, real-time object detection. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 779–788, 2016. 9

[30] Stephan R. Richter, Zeeshan Hayder, and Vladlen Koltun. Playing for benchmarks. In *Proceedings of the IEEE International Conference on Computer Vision (ICCV)*, pages 2232–2241, 2017. 10

[31] John Schulman, Filip Wolski, Prafulla Dhariwal, Alec Radford, and Oleg Klimov. Proximal policy optimization algorithms. In *arXiv preprint arXiv:1707.06347*, 2017. 66

[32] Claude E. Shannon. A mathematical theory of communication. *Bell System Technical Journal*, 27(3):379–423, 1948. 13

[33] Richard S. Sutton and Andrew G. Barto. *Reinforcement Learning: An Introduction*. MIT Press, 2 edition, 2018. 11

[34] Moorissa Tjokro. How perception stack works in autonomous driving systems, 2022. Medium / Self-Driving Cars publication. https://medium.com/self-driving-cars/a-perception-framework-in-autonomous-driving-systems-3cdc0b59a3e6. 9

[35] Ronald J. Williams. Simple statistical gradient-following algorithms for connectionist reinforcement learning. *Machine Learning*, 8(3–4):229–256, 1992. 19

[36] Yuxiao Zhang, Alexander Carballo, Hanting Yang, and Kazuya Takeda. Perception and sensing for autonomous vehicles under adverse weather conditions: A survey. *ISPRS Journal of Photogrammetry and Remote Sensing*, 196:146–177, 2023. 8

[37] Zixu Zhang and Jaime F. Fisac. Safe occlusion-aware autonomous driving via game-theoretic active perception. In *Proceedings of Robotics: Science and Systems (RSS)*, 2021. 10

[38] Geigh Zollicoffer, Kenneth Eaton, Jonathan Balloch, Julia Kim, Wei Zhou, Robert Wright, and Mark Riedl. Novelty detection in reinforcement learning with world models. *Proceedings of the 42nd International Conference on Machine Learning (ICML)*, 2025. arXiv:2310.08731v4. iii, v, 3, 15, 21, 22, 23, 34, 41, 49, 57, 62, 75

Α

Ψευδοκώδικας Υλοποίησης

Το παρόν παράρτημα παραθέτει σε μορφή ψευδοκώδικα τους βασικούς αλγορίθμους της υλοποίησης. Τα ονόματα συναρτήσεων και μεταβλητών διατηρούνται κοντά στον πηγαίο κώδικα (`carla_env_dream.py`, `agent.py`, `utils.py`, `cnn_classifier.py`, `train_classifier.py`), ώστε η αντιστοίχιση ψευδοκώδικα-κώδικα να είναι άμεση.

Α΄.1 Περιβάλλον: αποκωδικοποίηση ενέργειας

Ο Αλγόριθμος 1 αντιστοιχεί στη μέθοδο `get_action` του περιβάλλοντος. Η διακριτή ενέργεια αποκωδικοποιείται στο καρτεσιανό γινόμενο τιμών επιτάχυνσης και διεύθυνσης τιμονιού. Οι θετικές επιταχύνσεις αποδίδονται ως γκάζι (`throttle`) και οι αρνητικές ως πέδηση (`brake`). Στη διαμόρφωση βασικής γραμμής δεν εφαρμόζεται καμία τροποποίηση του ελέγχου βάσει του σήματος ανωμαλίας· στις εποπτευόμενες διαμορφώσεις, η εντολή πέδησης του επόπτη (Αλγόριθμος 9) υπερισχύει της πέδησης της πολιτικής και μηδενίζει το γκάζι.

Α΄.2 Συνάρτηση ανταμοιβής

Ο Αλγόριθμος 2 συνοψίζει τη συνάρτηση ανταμοιβής (`getReward`), ως άθροισμα των επιμέρους όρων που περιγράφονται στην Ενότητα 3.1.5. Η ίδια μέθοδος συγκροτεί και το

Algorithm 1: Αποκωδικοποίηση ενέργειας (`get_action`)

Είσοδος: διακριτή ενέργεια $a \in \{0, \ldots, 14\}$
Έξοδος: εντολή ελέγχου `carla.VehicleControl`
$acc \leftarrow$ `discrete_acc`$[\, a \div n_{steer}\,]$ `// discrete_acc` $= [-2, 0, 2]$
$steer \leftarrow$ `discrete_steer`$[\, a \bmod n_{steer}\,]$
`// discrete_steer` $= [-0.6, -0.2, 0, 0.2, 0.6]$
εάν $acc > 0$ **τότε**
  $throttle \leftarrow \mathrm{clip}(acc/3,\ 0,\ 1)\cdot$ $brake \leftarrow 0$
τέλος
αλλιώς
  $throttle \leftarrow 0\cdot$ $brake \leftarrow \mathrm{clip}(-acc/3,\ 0,\ 1)$
τέλος
επίστρεψε `VehicleControl`$(throttle,\ steer{=}-steer,\ brake)$

12-διάστατο διάνυσμα κατάστασης (πέντε επόμενα waypoints σε συντεταγμένες οχήματος, ταχύτητα, γωνιακή απόκλιση).

Algorithm 2: Συνάρτηση ανταμοιβής (`getReward`)

Έξοδος: ανταμοιβή $r\cdot$ σημαίες `terminated`, `truncated`
$r_{spd} \leftarrow \big(v_{des} - |v_{\parallel} - v_{des}| - 2\min(v_{\perp}, 0.5)\big)\cdot w_{spd}$
εάν $d_{wp} > 15$ **τότε**
  $r_{wp} \leftarrow -2\,w_{wp}\cdot$ `terminated` $\leftarrow$ **αληθές** `// απομάκρυνση από waypoint`
τέλος
εάν $d_{wp} < 1.8$ **και** $|v| > 0$ **τότε**
  $r_{wp} \leftarrow w_{wp}\cdot$ προώθησε τη διαδρομή κατά ένα waypoint
τέλος
εάν *σύγκρουση* **τότε**
  $r_{col} \leftarrow -\,w_{col}\cdot$ `terminated` $\leftarrow$ **αληθές**
τέλος
εάν *παραβίαση συνεχούς λωρίδας* **τότε**
  εάν $d_{\perp} > 0.5$ **τότε**
    $r_{lane} \leftarrow -\,w_{lane}\cdot(d_{\perp} - 0.5)$
  αλλιώς
    $r_{lane} \leftarrow -\,w_{lane}$
  τέλος
  `terminated` $\leftarrow$ **αληθές** `// οι διακεκομμένες δεν τιμωρούνται`
τέλος
εάν *η διαδρομή εξαντλήθηκε* **τότε**
  $r_{dst} \leftarrow w_{dst}\cdot$ `terminated` $\leftarrow$ **αληθές**
τέλος
$r_{time} \leftarrow -\,w_{time}$
$r \leftarrow r_{wp} + r_{spd} + r_{col} + r_{lane} + r_{dst} + r_{time}$
εάν $step = total_timesteps$ **τότε**
  `truncated` $\leftarrow$ **αληθές**
τέλος
επίστρεψε r, `terminated`, `truncated`

Α΄.3 Ανίχνευση ανωμαλίας βάσει KL

Ο Αλγόριθμος 3 αντιστοιχεί στη μέθοδο `get_states` της κλάσης `PlayerDV3` και υλοποιεί το κατώφλι ανωμαλίας των Zollicoffer et al. [38] (Ενότητα 3.4). Η μέθοδος *δεν* επανεκτελεί τον GRU: διαβάζει την αναδρομική κατάσταση h_t και τα posterior logits $q_\phi(z_t \mid h_t, x_t)$ που έχει ήδη υπολογίσει η `get_actions`, και προσθέτει μόνο τις απαραίτητες κλήσεις `_transition`/`_representation`. Και οι τρεις όροι KL υπολογίζονται με κατανομές `OneHotCategoricalStraightThrough` (32×32), τυλιγμένες σε `Independent`. Η ανακατασκευή $\hat{o}_t$ που τροφοδοτεί τον ταξινομητή CNN παράγεται από την *πλήρη* λανθάνουσα κατάσταση (z_t, h_t) (posterior).

Algorithm 3: Ανίχνευση ανωμαλίας βάσει KL (`get_states`)

Είσοδος: αποθηκευμένη αναδρομική κατάσταση h_t και posterior logits $q_\phi(z_t \mid h_t, x_t)$ (από `get_actions`)· παρατήρηση o_t
Έξοδος: `prior_logits`, posterior logits, ανακατασκευή $\hat{o}_t$, σημαία `novel`

$e_t \leftarrow \text{encoder}(o_t)$
// Δίοδος πλήρους ιστορικού (διαβάζεται το αποθηκευμένο h_t)
`prior_logits` $\leftarrow$ `_transition`(h_t) // $p_\phi(z_t \mid h_t)$
// Δίοδος κενού ιστορικού
$h_0 \leftarrow \mathbf{0}$
`prior_logits_0` $\leftarrow$ `_transition`(h_0) // $p_\phi(z_t \mid h_0)$
`posterior_logits_0` $\leftarrow$ `_representation`$(h_0,\ e_t)$ // $p_\phi(z_t \mid h_0, x_t)$
// Τρεις όροι KL: βάση πάντα η πλήρης posterior
$KL_A \leftarrow \mathrm{KL}(q_\phi(z_t \mid h_t, x_t) \,\|\, \texttt{prior_logits})$
$KL_B \leftarrow \mathrm{KL}(q_\phi(z_t \mid h_t, x_t) \,\|\, \texttt{prior_logits_0})$
$KL_C \leftarrow \mathrm{KL}(q_\phi(z_t \mid h_t, x_t) \,\|\, \texttt{posterior_logits_0})$
$A,\ B,\ C \leftarrow \overline{KL_A},\ \overline{KL_B},\ \overline{KL_C}$ // μέσος όρος
$threshold \leftarrow B - C$
`novel` $\leftarrow (threshold < 0)\ \vee\ (A > threshold)$
// Ανακατασκευή για τον CNN από την πλήρη posterior λανθάνουσα κατάσταση
$latent \leftarrow \text{concat}(z_t,\ h_t)$
$\hat{o}_t \leftarrow \text{decoder}(latent)$
επίστρεψε `prior_logits`, posterior logits, $\hat{o}_t$, `novel`

Α΄.4 Προεπεξεργασία εικόνας

Ο Αλγόριθμος 4 αντιστοιχεί στη συνάρτηση `preprocess` (ισοδύναμα `process_image` στο `train_classifier.py`). Μετατρέπει μια σημασιολογική εικόνα, είτε πραγματική παρατήρηση είτε ανακατασκευή, σε ανάλυση 64×64 όπως την επεξεργάζεται το DreamerV3, σε χάρτη δεικτών κλάσεων, αποκόπτοντας μια σταθερή περιοχή ενδιαφέροντος (ROI) 24×24.

Algorithm 4: Προεπεξεργασία εικόνας σε χάρτη δεικτών κλάσεων (`preprocess`)

Είσοδος: σημασιολογική εικόνα x (έξοδος αισθητήρα ή αποκωδικοποιητή)
Έξοδος: χάρτης δεικτών κλάσεων $S \in \{1, \dots, 19\}^{24\times 24}$
$x \leftarrow x[0, 0]$ `// αφαίρεση διαστάσεων batch/time`
$x \leftarrow \mathrm{transpose}(x,\ \mathrm{CHW} \to \mathrm{HWC})$
$x \leftarrow \mathrm{clip}\big((x + 0.5) \cdot 255,\ 0,\ 255\big)$ ως `uint8`
$x \leftarrow x[\,34{:}58,\ 20{:}44\,]$ `// αποκοπή ROI` $\to 24 \times 24$ `(εστίαση στο οδόστρωμα)`
$x \leftarrow x[:, :, :: -1]$ `// BGR` $\to$ `RGB`
για κάθε *εικονοστοιχείο* (i, j) **κάνε**
  $S[i, j] \leftarrow \arg\min_c \|x[i, j] - \mathrm{PALETTE}[c]\|^2$ `// πλησιέστερο χρώμα CityScapes`
τέλος
επίστρεψε S

Α΄.5 Ανιχνευτές αληθούς ετικέτας

Η αληθής ετικέτα κάθε χρονικού βήματος προκύπτει από τη σύγκριση της πραγματικής παρατήρησης με τη φαντασία· καθώς το «παγωμένο» μοντέλο ανακατασκευάζει τη σκηνή *χωρίς* εμπόδιο, ένα εμπόδιο εκδηλώνεται ως περιοχή που υπάρχει στην κάμερα αλλά λείπει από την ανακατασκευή. Στη ρύθμιση μοναδικού εμποδίου (P1) χρησιμοποιείται ο Αλγόριθμος 5 (`detect_object`, ανά κλάση, π.χ. *car*), ενώ στη ρύθμιση τυχαίων εμποδίων (P2) ο Αλγόριθμος 6 (`detect_road_obstacle`), ανεξαρτήτως κλάσης. Η συνάρτηση `detect_obstacle` του κώδικα είναι βοηθητική (παραγωγή/έλεγχος συνόλου δεδομένων) και δεν συμμετέχει στην παραγωγή των ετικετών αξιολόγησης.

Algorithm 5: Αληθής ετικέτα ανά κλάση P1 (`detect_object`)

Είσοδος: χάρτες κλάσεων $S_{cam},\ S_{wm}$· κλάση στόχος c (π.χ. $14 = car$)
Έξοδος: πλήθος μη ανακατασκευασμένων περιοχών της κλάσης c
$missing \leftarrow 0$
για κάθε *συνεκτική περιοχή* R *του* $\{S_{cam} = c\}$ **κάνε**
  $ratio \leftarrow |R \cap \{S_{wm} = c\}| \,/\, |R|$
  εάν $ratio < 0.3$ **τότε**
    $missing \leftarrow missing + 1$ `// η φαντασία δεν την αναπαρήγαγε`
  τέλος
τέλος
επίστρεψε $missing$

Algorithm 6: Αληθής ετικέτα ανεξαρτήτως κλάσης P2 (`detect_road_obstacle`)

Είσοδος: χάρτες κλάσεων $S_{cam},\ S_{wm}$
Έξοδος: λίστα εμποδίων στο οδόστρωμα (ανεξαρτήτως κλάσης)
$corridor \leftarrow \mathrm{dilate}_2\big(\mathrm{road}(S_{cam}) \cup \mathrm{road}(S_{wm})\big)$ `// δυναμικός διάδρομος κίνησης, διαστολή 2 px`
$cam_obj \leftarrow \neg\,\mathrm{road}(S_{cam}) \wedge (S_{cam} \neq \texttt{sky})$
$wm_obj \leftarrow \mathrm{dilate}_1\big(\neg\,\mathrm{road}(S_{wm}) \wedge (S_{wm} \neq \texttt{sky})\big)$ `// διαστολή 1 px`

$novel \leftarrow cam_obj \wedge \neg\, wm_obj \wedge corridor$ `// αντικείμενο που η φαντασία δεν προέβλεψε`
ομαδοποίησε το *novel* σε συνεκτικές περιοχές· κράτησε όσες έχουν $\geq$ `min_pixels` $= 3$ εικονοστοιχεία
επίστρεψε τις περιοχές που απέμειναν

Α΄.6 Αρχιτεκτονική και εκπαίδευση του ταξινομητή CNN

Ο Αλγόριθμος 7 συνοψίζει την κατασκευή και εκπαίδευση του ταξινομητή (`cnn_classifier.py`, `train_classifier.py`). Ο ταξινομητής είναι δυαδικός με έξοδο στο $\{0, 1\}$· κατά την πρόβλεψη, η έξοδος της σιγμοειδούς συγκρίνεται με το κατώφλι απόφασης $\tau = 0.1485$, το οποίο επιλέγεται στο σύνολο επικύρωσης από την καμπύλη ROC με κατώτατο όριο ανάκλησης 0.81 (Ενότητες 3.5.4 και 4.3).

Α΄.7 Βρόχος αξιολόγησης πραγματικού χρόνου

Ο Αλγόριθμος 8 αντιστοιχεί στη συνάρτηση `test` (Ενότητα 3.6). Σε κάθε χρονικό βήμα συλλέγονται *ταυτόχρονα* η αληθής ετικέτα και οι αποφάσεις των δύο ανιχνευτών στα ίδια δεδομένα. Στην αρχή κάθε επεισοδίου, η αναδρομική κατάσταση του πράκτορα μηδενίζεται (`init_states`) και η πρώτη παρατήρηση λαμβάνεται από το `env.reset()`. Στη διαμόρφωση βασικής γραμμής οι αποφάσεις καταγράφονται μόνο για τη συγκριτική αξιολόγηση· στις εποπτευόμενες διαμορφώσεις τροφοδοτούν τον επόπτη του Αλγορίθμου 9, του οποίου η εντολή εφαρμόζεται από το περιβάλλον στο επόμενο βήμα.

Α΄.8 Επόπτης ασφαλείας κλειστού βρόχου

Ο Αλγόριθμος 9 συνοψίζει τον επόπτη της Ενότητας 3.7 (προοδευτική πέδηση με ανοχή κενών και ρύθμιση εμπιστοσύνης από το όριο KL). Οι τιμές των παραμέτρων στην παρούσα εργασία: $\delta = 0.25$, $g = 1$, $\beta = 0.9$, $\rho = 0.5$, $k = 3$. Στη διαμόρφωση *μόνο όριο KL* τη θέση της σήμανσης y_t παίρνει το $\texttt{novel}_t$ και η ρύθμιση εμπιστοσύνης αδρανοποιείται· στη διαμόρφωση *βασικής γραμμής* η έξοδος δεν εφαρμόζεται ποτέ στο όχημα.

Algorithm 7: Αρχιτεκτονική και εκπαίδευση του ταξινομητή CNN

Είσοδος: σύνολο ζευγών $(o,\ \hat{o})$ με ετικέτες $\{0, 1\}$
Έξοδος: εκπαιδευμένος ταξινομητής
// Αρχιτεκτονική (Keras Sequential), είσοδος $24 \times 24 \times 2$
Conv2D$(64, 5{\times}5, \text{relu}) \rightarrow$ BatchNorm $\rightarrow$ MaxPool$(2{\times}2)$
Conv2D$(64, 3{\times}3, \text{relu}) \rightarrow$ BatchNorm $\rightarrow$ MaxPool$(2{\times}2)$
Dropout$(0.5) \rightarrow$ Flatten
Dense$(128, \text{relu}) \rightarrow$ Dropout$(0.5) \rightarrow$ Dense$(1, \text{sigmoid})$
διαμόρφωση (compile) με Adam(10^{-3}) και απώλεια binary_crossentropy
// Σύνθεση συνόλου δεδομένων
ανάμειξη κανονικών (0) και ανώμαλων (1) ζευγών· διαχωρισμός $\approx 70\%/15\%/15\%$
κατά ολόκληρα επεισόδια (εκπαίδευση/επικύρωση/έλεγχος)
για κάθε *ζεύγος* $(o, \hat{o})$ **κάνε**
  $X \leftarrow \text{stack}\big(\text{preprocess}(o),\ \text{preprocess}(\hat{o})\big)$ // $24 \times 24 \times 2$
τέλος
εκπαίδευση με τα δεδομένα επικύρωσης ως validation set
επιλογή κατωφλίου τ στην επικύρωση: μεγαλύτερο τ με ανάκληση ≥ 0.81 (ROC)
$\Rightarrow \tau = 0.1485$
// Πρόβλεψη
$\hat{y} \leftarrow \sigma(z)\cdot$ label $\leftarrow [\,\hat{y} \geq \tau\,]$
επίστρεψε εκπαιδευμένο μοντέλο

Algorithm 8: Βρόχος αξιολόγησης πραγματικού χρόνου (`test`)

Είσοδος: παγωμένος πράκτορας `player`, ταξινομητής, περιβάλλον `env`, αριθμός επεισοδίων N

φόρτωσε τον ταξινομητή· $ep \leftarrow 0$

όσο $ep < N$ **κάνε**

- $o \leftarrow$ `env.reset()`· `player.init_states()` `// μηδενισμός ιστορικού ανά επεισόδιο`
- $ps \leftarrow 0$· `done` $\leftarrow$ **ψευδές**
- **όσο** ***όχι*** *done* **κάνε**
  - $a \leftarrow$ `player.get_actions`(o) `// ενημερώνει` h_t`, posterior`
  - o', r, `done`, `trunc` $\leftarrow$ `env.step`(a)
  - `prior`, `post`, $\hat{o}$, `novel` $\leftarrow$ `player.get_states`$(o,\ a,\ ps)$ `// όριο KL`
  - $S_{cam} \leftarrow$ preprocess$(o$`.semantic_camera`$)$
  - $S_{wm} \leftarrow$ preprocess$(\hat{o}$`.semantic_camera`$)$
  - $X \leftarrow \text{stack}(S_{cam},\ S_{wm}) \in \{1, \ldots, 19\}^{24\times24\times2}$
  - $y \leftarrow$ `classifier.predict`(X) `// ταξινομητής CNN`
  - $gt \leftarrow$ τελεστής της τρέχουσας ρύθμισης: `detect_object` (P1) ή `detect_road_obstacle` (P2) `// αληθής ετικέτα`
  - κατέγραψε gt, y **και** `novel` για τη συγκριτική αξιολόγηση
  - $b \leftarrow$ `supervisor.update`$(y,$ `novel`$)$· το περιβάλλον εφαρμόζει το b στο βήμα $t{+}1$ `// Αλγ. 9`
  - $o \leftarrow o'$· $ps \leftarrow ps + 1$
- **τέλος**
- $ep \leftarrow ep + 1$· βαθμολόγησε CNN **και** όριο KL έναντι της αληθούς ετικέτας

τέλος

Algorithm 9: Επόπτης ασφαλείας: προοδευτική πέδηση με ρύθμιση εμπιστοσύνης

Είσοδος: σήμανση ταξινομητή $y_t \in \{0,1\}\cdot$ σημαία $\texttt{novel}_t$ του ορίου KL
Έξοδος: εντολή πέδησης $b_t \in [0,1]$ (εφαρμόζεται στο βήμα $t{+}1$)
// Συναγερμός εγκυρότητας: εκθετική εξομάλυνση του δυαδικού σήματος
$r_t \leftarrow \beta\, r_{t-1} + (1-\beta)\,\texttt{novel}_t\cdot$ $\quad \texttt{alarm} \leftarrow [\, r_t > \rho\,]$
εάν $y_t = 1$ **τότε**
  $run \leftarrow run + 1\cdot$ $\; gap \leftarrow 0$
αλλιώς
  $gap \leftarrow gap + 1$
  εάν $gap > g$ **τότε**
    $run \leftarrow 0$ // το κενό υπερβαίνει την ανοχή: απελευθέρωση
  τέλος
τέλος
$k_{\mathit{eff}} \leftarrow$ **εάν** alarm **τότε** k **αλλιώς** 1 // ρύθμιση εμπιστοσύνης
εάν $run \geq k_{\mathit{eff}}$ **τότε**
  $b_t \leftarrow \min\bigl(1,\ \delta \cdot (run - k_{\mathit{eff}} + 1)\bigr)$ // προοδευτική κλιμάκωση
αλλιώς
  $b_t \leftarrow$ **εάν** $run > 0$ **ή** $gap \leq g$ **τότε** διατήρησε το τρέχον b **αλλιώς** 0
τέλος
εάν $b_t = 1$ **και** *το όχημα ακίνητο επί* 10 *διαδοχικά βήματα* **τότε**
  τερμάτισε το επεισόδιο ως *ασφαλή στάση*
τέλος
επίστρεψε b_t